Universitatea din Bucuresti

Facultatea de Matematica si Informatica

Lucrare de licenta

Analiza pietelor financiare folosind metode grafice

Absolvent

Malina Ispravnic

Coordonator stiintific

Petre Caraiani

Bucuresti

2026

Abstract

Lucrarea analizează structura relațiilor dintre sectoarele pieței financiare utilizând metode statistice și metode de analiză a rețelelor. Analiza se bazează pe randamente zilnice ale unor ETF-uri sectoriale obținute din baza de date Yahoo Finance.

Dependențele dinamice dintre variabile sunt modelate folosind un model vector autoregresiv. Reziduurile modelului sunt utilizate pentru estimarea matricei de covarianță.

Pentru identificarea dependenței condiționale dintre active este utilizată metoda graphical lasso, care estimează matricea de precizie. Structura acestei matrici este interpretată ca o rețea financiară în care nodurile reprezintă sectoare, iar muchiile reprezintă relații condiționale între acestea.

Analiza rețelei permite identificarea sectoarelor centrale și a structurii de interconectare a pieței financiare. În plus, extensia pe ferestre temporale evidențiază faptul că structura dependențelor nu este complet statică, ci variază în funcție de contextul economic și financiar al perioadei analizate.

Cuprins

Abstract **i**

1 Introducere **1**

1.1 Motivatia si contextul lucrarii 1

1.2 Obiectivele lucrarii 2

1.3 Structura lucrarii 2

2 Preliminarii **4**

2.1 Serii temporale multivariate 4

2.2 Modelul vector autoregresiv 4

2.2.1 Estimarea parametrilor 5

2.2.2 Selectia ordinului 5

2.3 Distributia gaussiana multivariata si independenta conditionala 5

2.4 Grafuri gaussiene Markov 6

2.5 Norma ℓ_1 si sparsitate 6

2.6 Masuri de centralitate in grafuri 7

3 Datele utilizate **8**

3.1 Selectia activelor 8

3.2 Colectarea si preprocesarea datelor 9

3.3 Trasabilitatea fisierelor 10

3.4 Perioada si frecventa de observatie 10

3.5 Preprocesarea datelor 11

3.5.1 Descarcarea datelor 11

3.5.2 Calculul randamentelor logaritmice 11

3.5.3 Structura setului de date 11

3.6 Proprietati statistice ale randamentelor 11

3.7 Etichetarea activelor 12

4 Modelul VAR **13**

4.1 Specificarea modelului 13

4.2 Selectia ordinului 13

4.2.1 Forma VAR(1) 14

4.3 Strategia de estimare 14

4.4 Diagnosticele modelului 14

4.5 Estimarea prin OLS 15

4.6 Verificarea stabilitatii 15

4.7 Diagnosticele modelului 16

4.7.1 Testul Portmanteau pentru autocorelatia reziduurilor 16

4.7.2 Testul ARCH multivariat 16

4.7.3 Testul de normalitate 16

4.8 Rolul reziduurilor in analiza ulterioara 16

5 Estimarea matricei de precizie prin graphical lasso **18**

5.1 Limitele estimarii directe 18

5.2 Problema de optimizare penalizata 18

5.2.1 Interpretarea termenilor 19

5.2.2 Convexitate si existenta solutiei 19

5.2.3 Algoritm de rezolvare 19

5.3 Selectia parametrului de regularizare 19

5.3.1 Criteriul BIC pentru graphical models 20

5.3.2 Analiza pe grila de valori 20

5.4 Proprietati statistice ale estimatorului GLasso 20

5.5 De la matricea de precizie la retea 21

5.6 Selectia parametrului de regularizare 21

5.7 Legatura cu implementarea empirica 21

6 Analiza retelei financiare **22**

6.1 Constructia retelei 22
6.2 Proprietati globale ale grafului 22
6.2.1 Densitatea retelei 22
6.2.2 Componenta conexa 23
6.2.3 Diametrul grafului 23
6.3 Masuri de centralitate 23
6.3.1 Degree centrality 23
6.3.2 Strength (gradul ponderat) 23
6.3.3 Betweenness centrality 24
6.3.4 Eigenvector centrality 24
6.4 Interpretarea structurii grafului 24
6.4.1 Sectoare centrale vs. periferice 24
6.4.2 Diferenta fata de analiza de corelatie 25
6.4.3 Grupuri de sectoare 25
6.5 Masurile de centralitate utilizate 25

7 Rezultate **27**
7.1 Rezultatele modelului VAR(1) 27
7.1.1 Selectia ordinului 27
7.1.2 Stabilitate si diagnostice 27
7.1.3 Matricea de covarianta a reziduurilor 28
7.2 Rezultatele Graphical Lasso 29
7.2.1 Selectia parametrului de regularizare 29
7.2.2 Sparsitatea matricei de precizie 30
7.2.3 Interpretarea elementelor nenule 30
7.3 Structura retelei financiare 30
7.3.1 Vizualizarea grafului 30
7.3.2 Cele mai importante muchii 31
7.4 Masuri de centralitate: rezultate 31
7.4.1 Degree centrality 31

7.4.2 Strength (grad ponderat) 32
7.4.3 Betweenness centrality 32
7.4.4 Eigenvector centrality 32
7.5 Interpretare statistica a rezultatelor 32

8 Analiza pe ferestre temporale **34**
8.1 Metodologia ferestrelor temporale 34
8.1.1 Definitia ferestrei rulante 34
8.1.2 Alegerea dimensiunii ferestrei 35
8.2 Indicatori dinamici ai retelei 35
8.2.1 Evolutia centralitatii sectoriale 35
8.3 Interpretarea dinamica a rezultatelor 35
8.4 Limitele analizei dinamice 36

9 Discutii si limite **37**
9.1 Avantajele metodologice ale abordarii 37
9.1.1 Separarea dependentei temporale de cea contemporana 37
9.1.2 Identificarea dependentelor conditionale 37
9.1.3 Parsimonie si interpretabilitate 38
9.2 Limitele analizei 38
9.2.1 Dimensiunea esantionului 38
9.2.2 Linearitatea modelului VAR 38
9.2.3 Selectia activelor si agregarea 38
9.2.4 Dependenta de parametrul de regularizare 39
9.2.5 Absenta cauzalitatii 39
9.3 Directii de dezvoltare ulterioara 40

10 Concluzii **41**
10.1 Sinteza metodologica 41
10.2 Contributii principale 41
10.3 Concluzii statistice si matematice 42

Anexe **44**

10.4 Bibliografia figurilor si tabelelor 44

10.5 Fragmente relevante de cod 44

10.5.1 Descarcarea datelor si calculul randamentelor logaritmice 44

10.5.2 Estimarea modelului VAR si extragerea reziduurilor 45

10.5.3 Estimarea matricei de precizie prin graphical lasso 45

10.5.4 Constructia retelei financiare bazate pe corelatii partiale 46

10.5.5 Calculul masurilor de centralitate 46

10.5.6 Analiza pe ferestre temporale 47

Capitolul 1

Introducere

Studiul relatiilor dintre sectoarele pietei financiare reprezinta o problema centrala atat in finantele cantitative, cat si in econometria moderna. Intelegerea modului in care un sector economic ii influenteaza pe ceilalti are implicatii directe pentru gestiunea riscului, diversificarea portofoliilor si monitorizarea stabilitatii sistemului financiar in ansamblu.

In mod traditional, dependenta dintre active financiare a fost masurata prin intermediul coeficientilor de corelatie Pearson. Aceasta abordare are insa limitari importante. Corelatia simpla nu distinge intre o relatie directa si una mediata printr-un factor comun. Doua sectoare pot parea corelate doar pentru ca ambele reactioneaza la acelasi factor macroeconomic, fara a exista o legatura directa intre ele. Mai mult, corelatia nu surprinde dependenta temporala: un sector poate reactiona cu intarziere la evolutia altui sector, efect pe care o simpla masura de asociere statica nu il poate evidentia.

Aceste limitari au motivat dezvoltarea unor cadre metodologice mai sofisticate, care combina modelarea seriilor temporale cu tehnici de estimare parsimonioasa. In aceasta lucrare este adoptata o astfel de abordare, structurata in doua etape principale. In prima etapa, dependenta temporala dintre sectoare este modelata printr-un model vector autoregresiv (VAR). Reziduurile acestui model capteaza componenta neanticipata a evolutiei fiecarui sector, curatata de efectele de memorie ale seriilor. In a doua etapa, structura de dependenta conditionala dintre aceste reziduuri este estimata prin metoda graphical lasso, care produce o matrice de precizie rara ce poate fi interpretata ca un graf financiar.

Cadrul teoretic al acestei abordari provine din teoria grafurilor gaussiene [7], care stabileste o corespondenta riguroasa intre zerouri ale matricei de precizie si independenta conditionala. Prin urmare, graful obtinut nu este o simpla reprezentare vizuala, ci un obiect matematic cu semnificatie statistica precisa: o muchie intre doua noduri indica existenta unei dependente conditionale directe, care persista dupa controlul pentru toate celelalte sectoare din sistem.

1.1 Motivatia si contextul lucrarii

Alegerea ETF-urilor sectoriale americane ca obiect de studiu este motivata de mai multe considerente. In primul rand, aceste instrumente financiare ofera o reprezentare sintetica si lichida a principalelor segmente ale economiei americane. Spre deosebire de actiunile individuale,

ETF-urile sectoriale reduc zgomotul specific companiei si reflecta mai fidel dinamica sectoriala. In al doilea rand, piata americana este cea mai studiata si mai lichida piata de capital din lume, ceea ce face ca rezultatele obtinute sa fie comparabile cu literatura de specialitate existenta.

Perioada analizata, cuprinsa intre 01 ianuarie 2016 si 21 ianuarie 2026, include evenimente structurale majore cu impact semnificativ asupra pietelor financiare. Pandemia COVID-19 din 2020 a provocat o dislocare masiva si sincronizata a tuturor sectoarelor, urmata de o recuperare diferentiata. Perioada 2022–2023 a fost marcata de o politica monetara restrictiva a Rezervei Federale americane, cu rate ale dobanzii in crestere rapida, care a afectat diferit sectoarele ciclice fata de cele defensive. Aceste evenimente reprezinta teste naturale pentru stabilitatea structurii retelei financiare si justifica analiza pe ferestre temporale inclusa in lucrare.

1.2 Obiectivele lucrarii

Principalele obiective ale lucrarii sunt urmatoarele:

1. Prezentarea riguroasa a cadrului matematic si statistic utilizat, incluzand teoria modelelor VAR, estimarea prin graphical lasso si teoria grafurilor gaussiene.
2. Estimarea unui model VAR de ordin optim pe randamentele logaritmice ale ETF-urilor sectoriale si verificarea calitatii sale prin teste de diagnostic.
3. Estimarea matricei de precizie prin graphical lasso cu selectia parametrului de regularizare prin criterii informationale.
4. Construirea si analiza retelei financiare rezultate, cu accent pe masurile de centralitate si structura grafica.
5. Investigarea dinamicii temporale a structurii retelei prin analiza pe ferestre temporale rulante.

1.3 Structura lucrarii

Lucrarea este organizata dupa cum urmeaza. Capitolul 2 prezinta preliminariile matematice necesare: notiuni de serii temporale, modele VAR, distributii gaussiene multivariate si grafuri probabilistice. Capitolul 3 descrie datele utilizate, procedura de descarcare si preprocesare si proprietatile statistice ale randamentelor. Capitolul 4 este dedicat modelului VAR: specificare, estimare, selectia ordinului si diagnostice. Capitolul 5 prezinta metoda graphical lasso, problema de optimizare si selectia parametrului de regularizare. Capitolul 6 descrie constructia retelei financiare si masurile de centralitate utilizate. Capitolul 7 prezinta si interpreteaza rezultatele

obtinute. Capitolul 8 extinde analiza la ferestre temporale. Capitolul 9 discuta limitele metodologiei, iar Capitolul 10 sintetizeaza concluziile.

Capitolul 2

Preliminarii

In acest capitol sunt prezentate notiunile matematice si statistice care stau la baza metodologiei utilizate in lucrare. Scopul este formularea unui cadru teoretic coerent, care sa justifice alegerile metodologice si sa faciliteze interpretarea rezultatelor.

2.1 Serii temporale multivariate

Fie $(\Omega, \mathcal{F}, P)$ un spatiu de probabilitate si fie $\{X_t\}_{t\in\mathbb{Z}}$ un proces stochastic cu valori in $\mathbb{R}^n$. Spunem ca procesul este *stationat in sens larg* daca:

1. $\mathbb{E}[X_t] = \mu$ pentru orice t, unde $\mu \in \mathbb{R}^n$ este constant,
2. $\mathrm{Cov}(X_t, X_{t-h}) = \Gamma(h)$ depinde doar de h, nu de t.

Matricea $\Gamma(h) = \mathbb{E}[(X_t - \mu)(X_{t-h} - \mu)^\top]$ se numeste *matricea de autocorelatie la lag h*.

Stationaritatea este o conditie esentiala pentru modelele econometrice clasice. Randamentele logaritmice ale activelor financiare satisfac in general aceasta proprietate, spre deosebire de nivelurile preturilor, care prezinta tendinte de crestere pe termen lung [12].

2.2 Modelul vector autoregresiv

Definitie 2.1. *Un proces $\{X_t\}$ cu valori in $\mathbb{R}^n$ satisface un model vector autoregresiv de ordin p, notat VAR(p), daca:*

$$X_t = \mu + A_1 X_{t-1} + A_2 X_{t-2} + \cdots + A_p X_{t-p} + \varepsilon_t, \tag{2.1}$$

unde $\mu \in \mathbb{R}^n$ este vectorul mediilor, $A_1, \ldots, A_p \in \mathbb{R}^{n\times n}$ sunt matricile de coeficienti, iar $\{\varepsilon_t\}$ este un proces de zgomot alb cu $\mathbb{E}[\varepsilon_t] = 0$ si $\mathrm{Cov}(\varepsilon_t) = \Sigma$, unde Σ este pozitiv definita.

Scriem modelul VAR(p) in forma compacta folosind operatorul de intarziere L, definit prin $LX_t = X_{t-1}$:

$$\left(I_n - A_1 L - A_2 L^2 - \cdots - A_p L^p\right) X_t = \mu + \varepsilon_t.$$

Polinomul matriceal $A(L) = I_n - A_1 L - \cdots - A_p L^p$ se numeste *polinomul autoregresiv* al modelului.

Definitie 2.2. *Modelul VAR(p) este stabil daca toate radacinile ecuatiei* $\det(A(z)) = 0$ *se afla in exteriorul discului unitate, adica satisfac* $|z| > 1$.

Stabilitatea garanteaza existenta unei reprezentari stationare a procesului si este verificata in practica prin analiza valorilor proprii ale matricei companioana asociate modelului [8].

2.2.1 Estimarea parametrilor

Coeficientii modelului VAR(p) sunt estimati prin metoda celor mai mici patrate (OLS) aplicata ecuatie cu ecuatie. Fie $\mathbf{X} \in \mathbb{R}^{T\times n}$ matricea observatiilor si $\mathbf{Z} \in \mathbb{R}^{T\times(np+1)}$ matricea regresiva care contine valorile intarziate si constanta. Estimatorul OLS este:

$$\hat{B} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{X}, \tag{2.2}$$

unde $\hat{B}$ contine estimatii $\hat{\mu}, \hat{A}_1, \ldots, \hat{A}_p$. Matricea de covarianta a reziduurilor este estimata prin:

$$\hat{\Sigma} = \frac{1}{T - np - 1} \sum_{t=p+1}^{T} \hat{\varepsilon}_t \hat{\varepsilon}_t^\top.$$

2.2.2 Selectia ordinului

Ordinul p este selectat prin minimizarea unui criteriu informational. *Criteriul Schwarz* (BIC) este definit prin:

$$\mathrm{BIC}(p) = \ln \det(\hat{\Sigma}_p) + \frac{\ln T}{T} \cdot p \cdot n^2, \tag{2.3}$$

unde $\hat{\Sigma}_p$ este matricea de covarianta estimata a reziduurilor pentru un model de ordin p. BIC penalizeaza mai puternic modelele complexe comparativ cu AIC si tinde sa selecteze modele mai parsimonioase [8].

2.3 Distributia gaussiana multivariata si independenta conditionala

Fie $X = (X_1, \ldots, X_n)^\top \sim \mathcal{N}_n(\mu, \Sigma)$ un vector gaussian cu medie μ si matrice de covarianta $\Sigma \succ 0$. Densitatea sa este:

$$f(x) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu) \right).$$

Definitie 2.3. *Matricea de precizie este* $\Theta = \Sigma^{-1}$.

Propozitie 2.4. *Fie* $X \sim \mathcal{N}_n(\mu, \Sigma)$ *si fie* $\Theta = \Sigma^{-1}$. *Atunci* X_i *si* X_j *sunt independente conditional fata de* $X_{V\setminus\{i,j\}}$ *(celelalte variabile) daca si numai daca* $\theta_{ij} = 0$.

Demonstraţie. Aceasta proprietate urmeaza din proprietatile distributiei gaussiene conditionale. Distributia conditionala $X_i \mid X_{V\setminus\{i\}}$ este gaussiana cu medie care depinde liniar de X_j cu coeficient proportional cu θ_{ij}. Prin urmare $\theta_{ij} = 0$ implica absenta lui X_j din regresia lui X_i pe celelalte variabile, adica independenta conditionala [7]. □

Aceasta propozitie este fundamentala pentru interpretarea retelei financiare: structura de zerouri a matricei Θ codifica exact structura de independenta conditionala a sistemului.

2.4 Grafuri gaussiene Markov

Definitie 2.5. *Un graf neorientat* $G = (V, E)$ *consta dintr-o multime finita de noduri* $V = \{1, \ldots, n\}$ *si o multime de muchii* $E \subseteq \{\{i, j\} : i \neq j\}$.

Definitie 2.6. *Un model grafic gaussian (graf Markov gaussian) asociat grafului* $G = (V, E)$ *este familia distributiilor* $\mathcal{N}_n(\mu, \Sigma)$ *pentru care* $\theta_{ij} = 0$ *ori de cate ori* $\{i, j\} \notin E$.

Prin urmare, muchia $\{i, j\} \in E$ exista daca si numai daca $\theta_{ij} \neq 0$, adica daca X_i si X_j sunt conditional dependente [7]. Reteaua financiara construita in aceasta lucrare este tocmai un astfel de model grafic gaussian, in care nodurile sunt sectoarele pietei, iar muchiile reprezinta dependente conditionale estimate.

2.5 Norma ℓ_1 si sparsitate

Fie $A \in \mathbb{R}^{n\times n}$. *Norma elementwise* ℓ_1 este definita prin:

$$\|A\|_1 = \sum_{i=1}^{n} \sum_{j=1}^{n} |a_{ij}|.$$

In contextul estimarii matricei de precizie, penalizarea cu norma ℓ_1 incurajeaza solutii *sparse* (cu multe elemente nule). Aceasta proprietate este esentiala pentru obtinerea unor grafuri financiare interpretabile, in care relatiile lipsite de semnificatie statistica sunt eliminate [5].

Remarca 2.7. *In aceasta lucrare, penalizarea de tip* ℓ_1 *are un rol dublu. Pe de o parte, ea regularizeaza problema de estimare intr-un cadru de dimensiune relativ mare. Pe de alta parte, ea conduce la o structura rara a matricei de precizie, ceea ce permite interpretarea dependentei conditionale sub forma unei retele financiare inteligibile.*

2.6 Masuri de centralitate in grafuri

Fie $G = (V, E, w)$ un graf neorientat ponderat, cu $w_{ij} \geq 0$.

Definitie 2.8. *Gradul ponderat (strength) al nodului i este:*

$$s_i = \sum_{j \in \mathcal{N}(i)} w_{ij},$$

unde $\mathcal{N}(i) = \{j : \{i, j\} \in E\}$ *este multimea vecinilor lui i.*

Definitie 2.9. *Betweenness centrality a nodului i este:*

$$C_B(i) = \sum_{\substack{s,t \in V \\ s \neq i \neq t}} \frac{\sigma(s, t \mid i)}{\sigma(s, t)},$$

unde $\sigma(s, t)$ *este numarul de drumuri geodezice de la s la t, iar* $\sigma(s, t \mid i)$ *este numarul celor care trec prin i.*

Definitie 2.10. *Eigenvector centrality a nodului i este componenta i a vectorului propriu dominant* $\mathbf{x}$ *al matricei de adiacenta ponderata W:*

$$\lambda x_i = \sum_{j \in \mathcal{N}(i)} w_{ij} x_j, \quad \lambda = \lambda_{\max}(W).$$

Aceste trei masuri ofera perspective complementare asupra importantei unui nod: gradul ponderat masoara conectivitatea directa, betweenness masoara rolul de intermediar, iar eigenvector centrality tine cont de importanta vecinilor.

Capitolul 3

Datele utilizate

Analiza empirica realizata in aceasta lucrare se bazeaza pe date financiare zilnice extrase din Yahoo Finance. Au fost selectate ETF-uri sectoriale care urmaresc evolutia principalelor sectoare ale pietei de capital din Statele Unite ale Americii. Alegerea acestor active este motivata de faptul ca ele ofera o reprezentare sintetica si lichida a unor segmente economice importante si permit comparatii clare intre sectoare, eliminand zgomotul specific companiilor individuale.

3.1 Selectia activelor

Sectoarele analizate corespund clasificarii standard GICS (Global Industry Classification Standard) si sunt acoperite de urmatoarele ETF-uri emise de State Street Global Advisors (SPDR):

Tabelul 3.1: ETF-urile sectoriale utilizate in analiza

Ticker	Sector	Descriere
XLB	Materials	Companii din sectorul materialelor de baza, incluzand produse chimice, metale si materiale pentru constructii.
XLE	Energy	Companii din energie, inclusiv petrol, gaze naturale si servicii energetice.
XLF	Financials	Banci, companii de asigurari, servicii financiare si piete de capital.
XLI	Industrials	Transport, productie industriala, servicii comerciale si bunuri de capital.
XLK	Technology	Companii din tehnologie, software, hardware si semiconductori.
XLP	Consumer Staples	Bunuri de consum de baza, retail alimentar, bauturi si produse de uz curent.
XLU	Utilities	Furnizori de electricitate, apa, gaz si alte utilitati.
XLV	Health Care	Farmaceutice, echipamente medicale, servicii medicale si biotehnologie.
XLY	Consumer Discretionary	Bunuri si servicii discretionare, retail non-esential, automobile si divertisment.
XLRE	Real Estate	Companii imobiliare si REIT-uri.
XLC	Communication Services	Telecomunicatii, media, servicii interactive si platforme de comunicare.

Sursa: tabel realizat pe baza selectiei ETF-urilor sectoriale utilizate in analiza.

Aceste unsprezece sectoare acopera intreaga piata de capital americana si permit o analiza comprehensiva a structurii de dependenta.

3.2 Colectarea si preprocesarea datelor

Datele au fost descarcate automat in limbajul R folosind pachetul `quantmod`. Pentru fiecare ETF s-au extras preturile ajustate de inchidere (*adjusted close*), deoarece acestea incorporeaza efectele dividendelor si ale altor ajustari corporative.

Dupa descarcare, seriile au fost aliniate pe intersectia zilelor de tranzactionare disponibile pentru toate activele, astfel incat esantionul final sa fie sincronizat pe toate cele 11 sectoare. Pe baza

acestor preturi s-au calculat randamentele logaritmice zilnice, exprimate procentual, prin formula

$$r_t^{(i)} = 100 \log \left(\frac{P_t^{(i)}}{P_{t-1}^{(i)}} \right).$$

Aceasta transformare este standard in econometria financiara, deoarece randamentele logaritmice sunt mai adecvate pentru modelare decat nivelurile preturilor si sunt mai apropiate de ipoteza de stationaritate necesara in analiza VAR.

3.3 Trasabilitatea fisierelor

Pipeline-ul de prelucrare salveaza explicit preturile in fisierul `data/prices_sectors.rds` si randamentele in `data/returns_sectors.rds`. Aceasta separare intre etapa de descarcare si etapa de modelare creste reproductibilitatea analizei si permite verificarea independenta a fiecarei faze a procesarii.

3.4 Perioada si frecventa de observatie

Esantionul utilizat acopera perioada cuprinsa intre **01 ianuarie 2016** si **21 ianuarie 2026**, la frecventa zilnica. Numarul total de zile tranzactionate este de aproximativ $T = 1900$ observatii per activ, dupa eliminarea zilelor fara tranzactionare si a valorilor lipsa.

Dupa cum a fost mentionat in discutia cu profesorul coordonator, acest interval nu este unul foarte lung pentru o analiza istorica comprehensiva. Totusi, el este suficient pentru aplicarea si ilustrarea metodelor statistice utilizate si include evenimente structurale majore care testeaza robustetea modelului:

- **2018–2019**: Tensiuni comerciale SUA–China, volatilitate moderata a pietelor.
- **Februarie–Martie 2020**: Socul COVID-19, cea mai rapida scadere a pietelor din istoria moderna, urmata de o recuperare puternica.
- **2022**: Cresterea rapida a ratelor dobanzii de catre Fed, cu impact diferentiat pe sectoare (sectoarele ciclice si cel imobiliar au suferit cel mai mult).
- **2023–2025**: Revenire diferentiata, dominata de sectorul tehnologic prin emergenta inteligentei artificiale.

Aceste episoade creaza conditii naturale pentru a testa daca structura retelei financiare se modifica in timp, aspect analizat in Capitolul 8.

3.5 Preprocesarea datelor

3.5.1 Descarcarea datelor

Datele au fost descarcate automat prin scriptul `00_download_data.R`, utilizand pachetul `quantmod` [11] din R. Scriptul preia preturile de inchidere ajustate pentru dividende si split-uri si construieste un set de date coerent in format `xts` (extensible time series).

Utilizarea unui script automatizat are avantajul reproducibilitatii: orice actualizare a perioadei de observatie sau a listei de active poate fi integrata fara interventii manuale.

3.5.2 Calculul randamentelor logaritmice

Fie $P_{i,t}$ pretul ajustat al ETF-ului i la momentul t. Randamentul logaritmic zilnic este definit prin:

$$r_{i,t} = \ln P_{i,t} - \ln P_{i,t-1} = \ln \frac{P_{i,t}}{P_{i,t-1}}, \quad t = 2, \ldots, T. \tag{3.1}$$

Aceasta transformare are mai multe avantaje fata de randamentele aritmetice $\frac{P_{i,t}-P_{i,t-1}}{P_{i,t-1}}$:

1. *Aditivitate temporala*: randamentele logaritmice pe perioade mai lungi se obtin prin simpla suma a randamentelor zilnice.
2. *Simetrie*: cresterile si scaderile procentuale sunt tratate simetric.
3. *Stationaritate*: seriile de randamente nu prezinta tendinte de crestere pe termen lung, spre deosebire de preturi [12].

3.5.3 Structura setului de date

Dupa calcularea randamentelor, datele sunt organizate intr-o matrice $R \in \mathbb{R}^{T \times n}$, unde $T \approx 1900$ este numarul de zile tranzactionate si $n = 11$ este numarul de sectoare. Fiecare coloana corespunde unui ETF, iar fiecare linie corespunde unei zile de tranzactionare.

3.6 Proprietati statistice ale randamentelor

Randamentele zilnice ale ETF-urilor sectoriale prezinta proprietati statistice tipice datelor financiare, cunoscute in literatura sub numele de *stilizate* [1]:

- **Medie apropiata de zero**: consistent cu ipoteza de mers aleatoriu, randamentele zilnice au medii statistice nesemnificativ diferite de zero.
- **Cozi groase**: kurtoza excesiva pozitiva indica distributii cu cozi mai groase decat distributia normala, ceea ce inseamna o frecventa mai mare a evenimentelor extreme.
- **Asimetrie negativa**: randamentele negative extreme sunt mai frecvente decat cele pozitive extreme, reflectand comportamentul asimetric al pietelor in perioade de stres.
- **Volatilitate grupata**: perioade de volatilitate ridicata tind sa fie urmate de perioade de volatilitate ridicata (efectul ARCH).

Aceste proprietati justifica utilizarea unui model VAR aplicat pe randamente (nu pe preturi) si interpretarea prudenta a testelor de normalitate in etapa de diagnostic.

3.7 Etichetarea activelor

Pentru organizarea consistenta a rezultatelor, scriptul `99_etf_labels.R` defineste etichetele clare asociate fiecarui ticker. Aceasta facilitate este importanta pentru lizibilitatea graficelor si tabelelor de centralitate, in care nodurile retelei financiare sunt identificate prin numele sectorului (de exemplu, `XLK` → "Tehnologie").

Capitolul 4

Modelul VAR

Primul pas metodologic al lucrarii este modelarea dependentei dinamice dintre randamentele activelor. In acest scop este utilizat un model vector autoregresiv (VAR). Ideea centrala este ca evolutia curenta a fiecarui sector poate depinde de valorile trecute ale tuturor sectoarelor incluse in sistem. Prin filtrarea VAR, componenta autoregresiva este eliminata, iar reziduurile raman pentru analiza dependentei contemporane.

4.1 Specificarea modelului

Fie $X_t = (r_{1,t}, r_{2,t}, \ldots, r_{n,t})^\top \in \mathbb{R}^n$ vectorul randamentelor logaritmice zilnice ale celor $n = 11$ sectoare la momentul t. Modelul VAR de ordin p, definit formal in Capitolul 2, are forma:

$$X_t = \mu + \sum_{k=1}^{p} A_k X_{t-k} + \varepsilon_t, \tag{4.1}$$

unde $\mu \in \mathbb{R}^n$ este vectorul constantelor, $A_k \in \mathbb{R}^{n \times n}$ sunt matricile de coeficienti la lag-ul k, iar $\varepsilon_t \sim (0, \Sigma)$ este vectorul de reziduuri contemporane.

4.2 Selectia ordinului

Alegerea ordinului p al modelului este o etapa critica. Un ordin prea mic lasa dependente temporale nemodelate in reziduuri, contaminand analiza ulterioara. Un ordin prea mare creste dimensionalitatea inutila si reduce precizia estimatiei.

In lucrare, selectia ordinului este realizata prin minimizarea criteriului BIC (ecuatia (2.3) din Capitolul 2). Rezultatul obtinut este:

$$\hat{p} = 1. \tag{4.2}$$

Alegerea unui VAR(1) este plauzibila pentru date financiare zilnice. Randamentele actiunilor au memorie scurta, iar reactiile pietei la informatii noi sunt in general rapide [4]. Un lag de o zi este suficient pentru a capta efectele de autocorelare semnificative.

4.2.1 Forma VAR(1)

In cazul $p = 1$, modelul devine:

$$X_t = \mu + A_1 X_{t-1} + \varepsilon_t, \tag{4.3}$$

unde $A_1 \in \mathbb{R}^{11\times 11}$ este matricea de coeficienti la lag 1. Elementul (i, j) al lui A_1, notat $a_{ij}^{(1)}$, masoara efectul dinamic al randamentului sectorului j din ziua precedenta asupra randamentului sectorului i in ziua curenta, dupa controlul pentru toate celelalte sectoare.

4.3 Strategia de estimare

Implementarea empirica urmeaza o succesiune clara de pasi. Mai intai, pe baza randamentelor zilnice ale celor 11 ETF-uri sectoriale, se selecteaza ordinul modelului VAR prin criterii informationale, folosind o valoare maxima `lag.max = 10`. In analiza finala este ales ordinul recomandat de criteriul Schwarz, deoarece acesta favorizeaza specificatii mai parsimonioase.

Ulterior, modelul VAR este estimat cu termen constant, iar reziduurile obtinute sunt extrase pentru etapa urmatoare a analizei. Ideea metodologica esentiala a lucrarii este ca modelul VAR nu reprezinta scopul final al modelarii, ci un mecanism de filtrare a dependentei temporale liniare. Reteaua financiara nu este construita direct din randamentele brute, ci din structura contemporana ramasa in reziduuri dupa aceasta filtrare.

Aceasta alegere este importanta din punct de vedere statistic. Daca analiza grafica ar fi aplicata direct asupra randamentelor, atunci legaturile estimate ar amesteca dependenta contemporana cu dependenta pe lag-uri. Prin introducerea modelului VAR in prima etapa, cele doua componente sunt separate in mod mai clar.

4.4 Diagnosticele modelului

Dupa estimarea modelului, adecvarea specificatiei este verificata prin mai multe teste de diagnostic aplicate reziduurilor. In implementarea lucrarii sunt evaluate:

- stabilitatea modelului, printr-o analiza de tip OLS-CUSUM;
- autocorelatia reziduala, prin testul Portmanteau;
- heteroscedasticitatea de tip ARCH;
- normalitatea reziduurilor, printr-un test Jarque–Bera multivariat.

Rolul acestor verificari este de a evalua daca modelul VAR a reusit sa elimine in mod satisfacator structura dinamica liniara din date. In special, absenta autocorelatiei reziduale este importanta pentru justificarea pasului urmator, deoarece matricea de covarianta folosita in graphical lasso este construita pe baza acestor reziduuri.

4.5 Estimarea prin OLS

Parametrii modelului VAR(1) sunt estimati prin metoda celor mai mici patrate (OLS) aplicata ecuatie cu ecuatie. Definim:

$$\mathbf{Y} = \begin{pmatrix} X_2^\top \\ \vdots \\ X_T^\top \end{pmatrix} \in \mathbb{R}^{(T-1)\times n}, \quad \mathbf{Z} = \begin{pmatrix} 1 & X_1^\top \\ \vdots & \vdots \\ 1 & X_{T-1}^\top \end{pmatrix} \in \mathbb{R}^{(T-1)\times(n+1)}.$$

Estimatorul OLS al matricei de coeficienti $B = [\mu \mid A_1]$ este:

$$\hat{B} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}, \tag{4.4}$$

iar matricea de covarianta a reziduurilor este estimata prin:

$$\hat{\Sigma} = \frac{1}{T-n-2} \sum_{t=2}^{T} \hat{\varepsilon}_t \hat{\varepsilon}_t^\top, \quad \hat{\varepsilon}_t = X_t - \hat{\mu} - \hat{A}_1 X_{t-1}. \tag{4.5}$$

Estimarea este implementata in R prin pachetul `vars` [9], functia `VAR()`, in scriptul `01_var_glasso_network.R`.

4.6 Verificarea stabilitatii

Conditia de stabilitate a VAR(1) cere ca toate valorile proprii ale matricei A_1 sa aiba modul strict mai mic decat 1. Echivalent, toate radacinile polinomului caracteristic $\det(I_n - A_1 z) = 0$ trebuie sa se afle in exteriorul discului unitate.

Verificarea stabilitatii este realizata in scriptul `02_var_diagnostics.R`. Rezultatele confirma ca modelul este stabil: toate valorile proprii ale lui $\hat{A}_1$ au modul sub 1, ceea ce garanteaza ca procesul are o reprezentare stationara si ca interpretarile dinamice sunt valide.

4.7 Diagnosticele modelului

Calitatea modelului VAR estimat trebuie validata prin mai multe teste de diagnostic, implementate in scriptul `02_var_diagnostics.R`.

4.7.1 Testul Portmanteau pentru autocorelatia reziduurilor

Testul Portmanteau (Ljung-Box multivariat) verifica ipoteza nula ca reziduurile nu sunt autocorelatate pana la lag-ul h. Statistica testului este:

$$Q_h = T^2 \sum_{k=1}^{h} \frac{1}{T-k} \operatorname{tr}\left(\hat{C}_k^\top \hat{C}_0^{-1} \hat{C}_k \hat{C}_0^{-1}\right), \tag{4.6}$$

unde $\hat{C}_k = \frac{1}{T} \sum_{t=k+1}^{T} \hat{\varepsilon}_t \hat{\varepsilon}_{t-k}^\top$ este matricea de autocorelatie la lag k.

Sub H_0, statistica Q_h urmeaza asimptotic o distributie χ^2 cu $n^2(h-p)$ grade de libertate [8]. Rezultatele testului indica absenta autocorelatiei semnificative in reziduuri, ceea ce valideaza specificatia VAR(1).

4.7.2 Testul ARCH multivariat

Datele financiare prezinta frecvent efecte de volatilitate grupata (ARCH/GARCH). Testul ARCH multivariat verifica daca variantele conditionale ale reziduurilor sunt constante in timp. Prezenta efectelor ARCH nu invalideaza estimatii OLS ale coeficientilor VAR (care raman nebiasate), dar afecteaza eficienta si trebuie luata in considerare la interpretarea rezultatelor [12].

4.7.3 Testul de normalitate

Testul Jarque-Bera multivariat verifica normalitatea distributiei reziduurilor prin masurarea asimetriei si kurtozei. In datele financiare, este bine cunoscut faptul ca distributiile randamentelor au cozi mai groase decat distributia normala (kurtoza excesiva pozitiva) [1]. Prin urmare, respingerea normalitatii nu este neasteptata si nu invalideaza analiza, cu conditia ca numarul de observatii sa fie suficient de mare pentru a invoca teoreme de tip limita centrala.

4.8 Rolul reziduurilor in analiza ulterioara

Reziduurile $\hat{\varepsilon}_t$ obtinute din modelul VAR(1) reprezinta componentele neanticipate ale evolutiei fiecarui sector la momentul t, curatate de efectele autoregresive. In termeni economici, ele pot fi

interpretate ca *socuri* sau informatii noi care afecteaza simultan piata la momentul t.

Matricea de covarianta $\hat{\Sigma}$ a acestor reziduuri masoara dependenta *contemporana* dintre socuri, adica relatiile dintre sectoare care nu pot fi explicate prin evolutia lor istorica proprie. Aceasta matrice este intrarea principala pentru etapa urmatoare: estimarea matricei de precizie prin graphical lasso.

Un avantaj major al filtrarii VAR este separarea clara a doua tipuri de dependenta. Dependenta temporala (cum valorile trecute ale sectorului j influenteaza evolutia sectorului i) este capturata de matricea A_1. Dependenta contemporana (cum socurile simultane sunt corelate intre sectoare) este capturata de Σ. Aceasta separare este esentiala pentru constructia unei retele financiare interpretabile.

Capitolul 5

Estimarea matricei de precizie prin graphical lasso

Dupa eliminarea dependentei temporale prin modelul VAR, atentia se muta asupra structurii de dependenta contemporana dintre reziduuri. Obiectivul este estimarea matricei de precizie $\Theta = \Sigma^{-1}$, ale carei elemente nenule definesc reteaua financiara.

5.1 Limitele estimarii directe

O prima idee ar fi sa estimam Θ prin inversarea matricei de covarianta empirica $\hat{\Sigma}$. Aceasta abordare are insa limitari serioase:

1. *Instabilitate numerica*: cand n este de aceeasi ordine cu T, $\hat{\Sigma}$ poate fi prost conditionata, iar $\hat{\Sigma}^{-1}$ amplifica erorile de estimare.
2. *Lipsa de sparsitate*: inversa empirica este in general densa, producand un graf complet greu de interpretat.
3. *Supraajustare*: o matrice de precizie densa include inevitabil relatii slabe sau accidentale care nu reflecta structura reala a datelor.

In contextul acestei lucrari, cu $n = 11$ sectoare si $T \approx 1900$ observatii, raportul $n/T \approx 0.006$ este favorabil, dar sparsitatea este totusi dorita pentru interpretabilitate. Metoda graphical lasso rezolva ambele probleme.

5.2 Problema de optimizare penalizata

Metoda graphical lasso (GLasso), propusa de [5], estimeaza matricea de precizie prin maximizarea log-verosimilitatii penalizate:

$$\hat{\Theta} = \arg\max_{\Theta \succ 0} \Big[\log\det(\Theta) - \operatorname{tr}(\hat{S}\,\Theta) - \rho\,\|\Theta\|_1 \Big], \tag{5.1}$$

unde:

- $\hat{S}$ este matricea de covarianta empirica a reziduurilor VAR,
- $\rho > 0$ este parametrul de regularizare,
- $\|\Theta\|_1 = \sum_{i \neq j} |\theta_{ij}|$ este norma ℓ_1 aplicata elementelor extra-diagonale (diagonala nu este penalizata).

5.2.1 Interpretarea termenilor

Termenul $\log\det(\Theta) - \operatorname{tr}(\hat{S}\,\Theta)$ reprezinta log-verosimilitatea gaussiana (pana la o constanta) in functie de Θ. Maximizarea sa fara penalizare ar produce $\hat{\Theta} = \hat{S}^{-1}$, adica inversa empirica. Termenul de penalizare $-\rho\|\Theta\|_1$ forteaza elementele extra-diagonale mici spre zero, producand o matrice rara.

5.2.2 Convexitate si existenta solutiei

Propozitie 5.1. *Problema de optimizare* (5.1) *este strict concava in* $\Theta \succ 0$ *si admite o solutie unica* $\hat{\Theta}$.

Demonstraţie. Functia obiectiv este suma a doua componente: $\log\det(\Theta)$, strict concava pe conul pozitiv definit, si $-\operatorname{tr}(\hat{S}\,\Theta) - \rho\|\Theta\|_1$, concava (liniara plus concava). Prin urmare, suma este strict concava, iar maximul pe multimea inchisa $\{\Theta : \Theta \succ 0\}$ este unic. □

5.2.3 Algoritm de rezolvare

Problema (5.1) este rezolvata prin algoritmul de coordonate-ciclice propus de [5]. Ideea este de a optimiza alternant in fiecare coloana/linie a lui Θ, mentinand celelalte fixe. Fiecare subproblema se reduce la un lasso standard, rezolvabila eficient. Convergenta algoritmului la solutia globala este garantata de convexitatea problemei.

In R, metoda este implementata prin functia `glasso()` din pachetul `glasso` [6], apelata in scriptul `01_var_glasso_network.R`.

5.3 Selectia parametrului de regularizare

Parametrul ρ controleaza fundamental rezultatul:

- $\rho \to 0$: $\hat{\Theta} \to \hat{S}^{-1}$, graf complet.

- $\rho \to \infty$: $\hat{\Theta} \to \mathrm{diag}(\hat{S})^{-1}$, graf fara nicio muchie.

Alegerea valorii optime $\hat{\rho}$ este realizata in scriptul `03_glasso_selection.R` prin doua criterii complementare.

5.3.1 Criteriul BIC pentru graphical models

Criteriul BIC adaptat pentru modele grafice gaussiene [13] este:

$$\mathrm{BIC}(\rho) = -T\Big[\log\det(\hat{\Theta}_\rho) - \mathrm{tr}(\hat{S}\,\hat{\Theta}_\rho)\Big] + \ln(T)\cdot|\hat{E}_\rho|, \tag{5.2}$$

unde $|\hat{E}_\rho|$ este numarul de elemente extra-diagonale nenule ale lui $\hat{\Theta}_\rho$ (numarul de muchii estimate). Valoarea optima este:

$$\hat{\rho} = \arg\min_{\rho>0} \mathrm{BIC}(\rho).$$

5.3.2 Analiza pe grila de valori

Selectia este realizata pe o grila logaritmica de valori $\rho \in \{0.001, 0.002, \ldots, 0.5\}$. Pentru fiecare valoare, se estimeaza $\hat{\Theta}_\rho$ si se calculeaza $\mathrm{BIC}(\rho)$ si densitatea retelei:

$$\mathrm{densitate}(\rho) = \frac{|\hat{E}_\rho|}{n(n-1)/2}.$$

Compromisul dintre fidelitatea fata de date si parsimonia modelului este esential: o retea excesiv de densa este greu de interpretat, iar una excesiv de rara poate pierde relatii relevante.

5.4 Proprietati statistice ale estimatorului GLasso

Propozitie 5.2 (Consistenta, [10])**.** *Sub conditii de regularitate asupra structurii reale a lui Θ^* si cu $\rho \sim \sqrt{\ln n/T}$, estimatorul GLasso satisface:*

$$\|\hat{\Theta}_\rho - \Theta^*\|_F = O_P\left(\sqrt{\frac{n\ln n}{T}}\right),$$

si recupereaza structura corecta a grafului cu probabilitate tending la 1.

Aceasta proprietate garanteaza ca, pentru un numar suficient de mare de observatii, structura retelei estimate converge la structura adevarata a dependentelor conditionale.

5.5 De la matricea de precizie la retea

Odata estimata $\hat{\Theta}$, reteaua financiara este definita astfel:

- **Noduri**: $V = \{1, \ldots, 11\}$, corespunzand celor 11 sectoare.
- **Muchii**: $\{i, j\} \in E \iff \hat{\theta}_{ij} \neq 0$ si $i \neq j$.
- **Ponderi**: $w_{ij} = |\hat{\theta}_{ij}|$, reprezentand intensitatea dependentei conditionale.

Prin constructie, aceasta retea nu reflecta corelatii brute, ci dependente conditionale: o muchie intre sectoarele i si j indica o legatura directa care persista dupa controlul pentru toate celelalte sectoare. Aceasta proprietate este cea care face reteaua informativa din punct de vedere economic.

5.6 Selectia parametrului de regularizare

Un element central al metodei graphical lasso este alegerea parametrului de regularizare ρ. Acesta controleaza compromisul dintre fidelitatea fata de date si raritatea structurii estimate. Pentru valori mici ale lui ρ, matricea de precizie estimata tinde sa fie mai densa, iar reteaua rezultata devine mai greu de interpretat. Pentru valori mari ale lui ρ, multe muchii sunt eliminate, iar reteaua devine mai rara.

In implementarea lucrarii, sensibilitatea fata de acest parametru este analizata pe o grila de valori, iar pentru fiecare valoare sunt evaluate densitatea retelei si un criteriu de tip BIC. Aceasta analiza are rolul de a arata cum se modifica structura estimata atunci cand regularizarea devine mai puternica.

Din punct de vedere statistic, alegerea lui ρ nu este doar o decizie numerica, ci una interpretativa. O retea prea densa poate masca relatiile esentiale printr-un exces de muchii slabe, in timp ce o retea prea rara poate omite legaturi conditionale reale.

5.7 Legatura cu implementarea empirica

In analiza principala si in analiza pe ferestre temporale se foloseste aceeasi valoare a penalizarii, pentru a pastra comparabilitatea intre rezultatele obtinute. Astfel, modificarile observate in structura retelei de la o fereastra la alta pot fi atribuite mai usor schimbarilor din date si nu unei modificari a parametrului de regularizare.

Aceasta decizie metodologica este importanta in special in capitolul dedicat ferestrelor temporale, unde interesul principal este compararea topologiei retelei in timp, nu recalibrarea separata a modelului pentru fiecare subesantion.

Capitolul 6

Analiza retelei financiare

Dupa estimarea matricei de precizie prin graphical lasso, urmatorul pas este constructia si analiza retelei financiare asociate. In aceasta reprezentare, fiecare nod corespunde unui sector, iar o muchie intre doua noduri semnifica prezenta unei dependente conditionale semnificative. Aceasta transformare dintr-un obiect matricial intr-un graf permite o analiza structurala bogata, imposibila prin simpla inspectie a matricei numerice.

6.1 Constructia retelei

Reteaua financiara este construita in scriptul `01_var_glasso_network.R` utilizand pachetul `igraph` [2]. Procedura este urmatoarea:

1. Se extrag indicii (i, j) cu $\hat{\theta}_{ij} \neq 0$ si $i < j$ (pentru a evita dublarea muchiilor, deoarece $\hat{\Theta}$ este simetrica).
2. Se construieste graful neorientat ponderat $G = (V, E, w)$ cu $w_{ij} = |\hat{\theta}_{ij}|$.
3. Rezultatele sunt exportate in fisierele `edges.csv` si `top10_edges.csv` pentru analiza si prezentare.

6.2 Proprietati globale ale grafului

6.2.1 Densitatea retelei

Densitatea masoara fractia de muchii existente din totalul posibil:

$$d(G) = \frac{|E|}{n(n-1)/2}, \tag{6.1}$$

unde $n(n-1)/2 = 55$ este numarul maxim de muchii pentru $n = 11$ noduri. Densitatea reflecta compromisul realizat prin selectia parametrului ρ: un graf cu densitate moderata este preferabil unuia complet sau gol.

6.2.2 Componenta conexa

Un aspect important al retelei este daca toti nodurile sunt conectati intr-o singura componenta sau exista sectoare izolate. Existenta unei singure componente conexe indica ca toti sectorii sunt conectati, direct sau indirect, prin lantul de dependente conditionale. Aceasta proprietate este relevanta pentru analiza propagarii socurilor.

6.2.3 Diametrul grafului

Diametrul $\mathrm{diam}(G)$ este lungimea celui mai lung drum minim (drum geodezic) din graf:

$$\mathrm{diam}(G) = \max_{i,j \in V} d(i, j),$$

unde $d(i, j)$ este distanta geodezica (numarul minim de muchii) intre i si j. Un diametru mic indica o retea in care informatia se propaga rapid intre orice doi participanti.

6.3 Masuri de centralitate

Masurile de centralitate cuantifica importanta fiecarui nod in structura retelei si sunt calculate in scriptul `05_centrality_measures.R`. Rezultatele sunt exportate in fisierul `centrality.csv`.

6.3.1 Degree centrality

Degree-ul unui nod este numarul de muchii incidente:

$$\deg(i) = |\mathcal{N}(i)| = |\{j : \{i, j\} \in E\}|. \tag{6.2}$$

In contextul retelei financiare, un sector cu degree ridicat este conectat direct cu multi alti sectori. Aceasta pozitie ii confera o influenta mai mare in sistem si un potential mai mare de a propaga sau absorbi socuri.

6.3.2 Strength (gradul ponderat)

Strength ia in considerare si intensitatea conexiunilor:

$$s_i = \sum_{j \in \mathcal{N}(i)} |\hat{\theta}_{ij}|. \tag{6.3}$$

Un sector cu strength ridicat nu doar ca are multi vecini, dar dependentele conditionale cu acestia sunt si puternice. Strength este o masura mai informativa decat degree-ul simplu in contextul retelelor ponderate.

6.3.3 Betweenness centrality

Betweenness centralitati masoara importanta unui nod ca intermediar structural:

$$C_B(i) = \sum_{\substack{s,t \in V \\ s \neq i \neq t}} \frac{\sigma(s,t \mid i)}{\sigma(s,t)}, \tag{6.4}$$

unde $\sigma(s,t)$ este numarul de drumuri geodezice de la s la t, iar $\sigma(s,t \mid i)$ este numarul celor care trec prin i.

Un sector cu betweenness ridicat controleaza fluxul de informatie intre parti diferite ale retelei. Eliminarea unui astfel de nod ar fragmenta reteaua si ar perturba semnificativ conectivitatea sistemului. Din perspectiva riscului sistemic, sectoarele cu betweenness ridicat sunt deosebit de importante.

6.3.4 Eigenvector centrality

Eigenvector centrality tine cont nu doar de numarul conexiunilor unui nod, ci si de importanta vecinilor sai. Fie $W \in \mathbb{R}^{n \times n}$ matricea de adiacenta ponderata a grafului. Eigenvector centrality satisface:

$$\lambda_{\max} x_i = \sum_{j=1}^{n} W_{ij} x_j, \tag{6.5}$$

unde $\lambda_{\max}$ este valoarea proprie dominanta a lui W (Perron-Frobenius). Un sector conectat la sectoare importante capata un scor ridicat, chiar daca nu are neaparat multe conexiuni.

6.4 Interpretarea structurii grafului

6.4.1 Sectoare centrale vs. periferice

Combinarea celor patru masuri de centralitate permite clasificarea sectoarelor in mai multe categorii:

- **Noduri centrale (hub-uri)**: sectoare cu degree, strength si eigenvector centrality ridicate. Acestea sunt conectate direct cu mai multi participanti si la noduri importante.

- **Intermediari structurali**: sectoare cu betweenness ridicat care joaca rolul de punte intre parti diferite ale retelei.
- **Noduri periferice**: sectoare cu putine conexiuni slabe, care au un rol mai limitat in propagarea informatiei.

6.4.2 Diferenta fata de analiza de corelatie

Este important de subliniat ca reteaua bazata pe matricea de precizie difera fundamental de o retea bazata pe corelatii. In analiza de corelatie, doua sectoare cu corelatie ridicata ar fi conectate, chiar daca acea corelatie este mediata complet de un factor comun. In reteaua noastra, o muchie exista numai daca dependenta dintre doua sectoare persista dupa controlul pentru toate celelalte sectoare.

Aceasta proprietate poate fi ilustrata printr-un exemplu simplu: sectoarele XLK (tehnologie) si XLY (bunuri discretionare) pot parea corelate pentru ca ambele sunt sensibile la ciclul economic. Daca aceasta co-miscare este complet explicata de un al treilea sector (de exemplu, XLF – financiar), atunci in matricea de precizie $\hat{\theta}_{XLK,XLY}$ va fi zero si nu va exista o muchie directa intre ele.

6.4.3 Grupuri de sectoare

Chiar si fara o metoda formala de detectie a comunitatilor, structura vizuala a grafului poate sugera existenta unor grupuri de sectoare mai strans conectate. In literatura financiara, se asteapta o grupare naturala in:

- *Sectoare ciclice*: XLK, XLF, XLY, XLI – sensibile la ciclul economic.
- *Sectoare defensive*: XLU, XLP, XLV – mai stabile in perioade de recesiune.
- *Sectoare cu caractere mixte*: XLE, XLB, XLRE, XLC.

Daca structura retelei reflecta aceasta clasificare, aceasta constituie o validare a metodologiei: reteaua recupereaza cunoasterea economica existenta printr-o procedura complet data-driven.

6.5 Masurile de centralitate utilizate

Pentru caracterizarea pozitiei fiecarui sector in retea sunt utilizate mai multe masuri de centralitate. In implementarea empirica sunt calculate in special degree, strength, betweenness, closeness si eigenvector centrality.

Aceste masuri surprind aspecte diferite ale importantei structurale a unui nod. Degree masoara numarul de legaturi directe, strength agrega intensitatea ponderilor asociate muchiilor incidente, betweenness evidentiaza rolul de intermediar pe drumurile scurte, iar eigenvector centrality surprinde conectarea la alte noduri importante.

In interpretarea rezultatelor din aceasta lucrare, un rol central il are mai ales masura *strength_abs*, deoarece ea sintetizeaza intensitatea totala a legaturilor directe ale fiecarui sector. Aceasta marime este utilizata atat in analiza retelei statice, cat si in analiza pe ferestre temporale.

Capitolul 7

Rezultate

Acest capitol prezinta si interpreteaza rezultatele obtinute in urma aplicarii pipeline-ului metodologic descris in capitolele anterioare. Accentul este pus in primul rand pe semnificatia statistica a structurii estimate, in acord cu observatia profesorului coordonator ca lucrarea trebuie sa trateze rezultatele in primul rand din punct de vedere al metodelor matematice si statistice.

7.1 Rezultatele modelului VAR(1)

7.1.1 Selectia ordinului

Criteriul BIC a indicat un model VAR de ordin $\hat{p} = 1$ ca optim. Aceasta alegere este compatibila cu proprietatile frecvent observate ale randamentelor zilnice financiare, unde dependenta liniara pe termen scurt este in general relativ redusa. Din aceasta perspectiva, un lag de o zi poate fi suficient pentru a surprinde componenta dinamica liniara relevanta, mentinand in acelasi timp modelul parsimonios [4].

7.1.2 Stabilitate si diagnostice

Verificarea stabilitatii modelului a confirmat ca toate valorile proprii ale matricei de coeficienti $\hat{A}_1$ au modul strict mai mic decat 1, deci modelul este stabil. Testul Portmanteau nu a detectat autocorelare reziduala semnificativa pana la lag 10, validand specificatia VAR(1). Testul ARCH a detectat efecte de heteroscedasticitate conditionala, ceea ce este plauzibil in contextul seriilor financiare. Acest rezultat sugereaza prudenta in interpretarea inferentei clasice, dar nu invalideaza utilizarea modelului VAR ca etapa de filtrare a dependentei temporale liniare.

Din punct de vedere metodologic, aceste rezultate au importanta deoarece valideaza utilizarea reziduurilor VAR ca intrare pentru etapa de estimare a matricei de precizie. In absenta unei filtrari adecvate a dinamicii temporale, reteaua estimata ulterior ar combina efecte de dependenta contemporana cu efecte autoregresive, ceea ce ar reduce claritatea interpretarii statistice.

Figura 7.1: Diagnostice de stabilitate de tip OLS-CUSUM pentru ecuatiile modelului VAR(1).

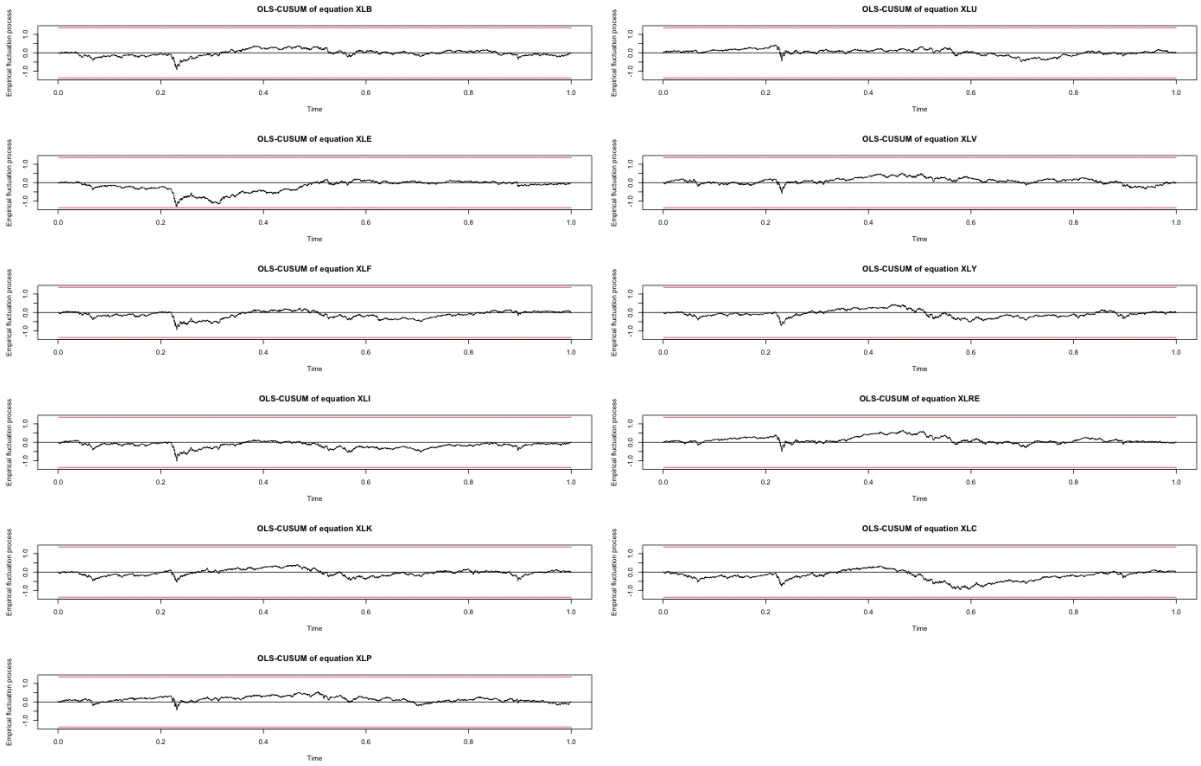

Sursa: figura generata de autoare prin scriptul `R/02_var_diagnostics.R`, fisierul `outputs/var_stability_cusum.png`.

Figura 7.1 sugereaza ca traiectoriile statisticilor OLS-CUSUM raman in interiorul limitelor critice pentru toate ecuatiile, ceea ce este compatibil cu ipoteza de stabilitate a specificatiei estimate pe intervalul analizat.

7.1.3 Matricea de covarianta a reziduurilor

Matricea $\hat{\Sigma} \in \mathbb{R}^{11\times 11}$ a reziduurilor VAR(1) descrie structura de co-variatie contemporana ramasa dupa filtrarea dependentei temporale liniare. Prezenta unor elemente extra-diagonale nenule arata ca, dincolo de dinamica pe lag-uri, sectoarele continua sa prezinte dependente simultane semnificative.

Din punct de vedere matematic, pozitivitatea definita a acestei matrici este esentiala, deoarece permite trecerea la etapa urmatoare de estimare a matricei de precizie. In plus, faptul ca inversarea numerica este stabila sustine fezabilitatea aplicarii metodei graphical lasso asupra acestei structuri empirice.

7.2 Rezultatele Graphical Lasso

Aplicarea metodei graphical lasso asupra matricii de covarianta a reziduurilor produce o matrice de precizie rara, ceea ce permite trecerea de la o descriere matriciala la una grafica. Din punct de vedere statistic, acesta este unul dintre rezultatele centrale ale lucrarii: multe legaturi aparente dintre sectoare dispar atunci cand se conditioneaza pe intregul sistem.

Aceasta observatie arata ca simpla corelatie dintre randamente nu trebuie interpretata automat ca relatie directa. O parte dintre co-miscarile observate sunt efecte indirecte, mediate prin alte sectoare, iar metoda graphical lasso permite tocmai filtrarea acestor dependente indirecte.

7.2.1 Selectia parametrului de regularizare

Sensibilitatea metodei graphical lasso fata de parametrul de regularizare ρ a fost analizata pe o grila de valori, utilizand un criteriu de tip BIC si monitorizand densitatea retelei estimate. Aceasta analiza a avut rolul de a evidentia compromisul dintre fidelitatea fata de date si parsimonia structurii estimate.

Figura 7.2: Evolutia densitatii retelei in functie de parametrul de regularizare ρ.

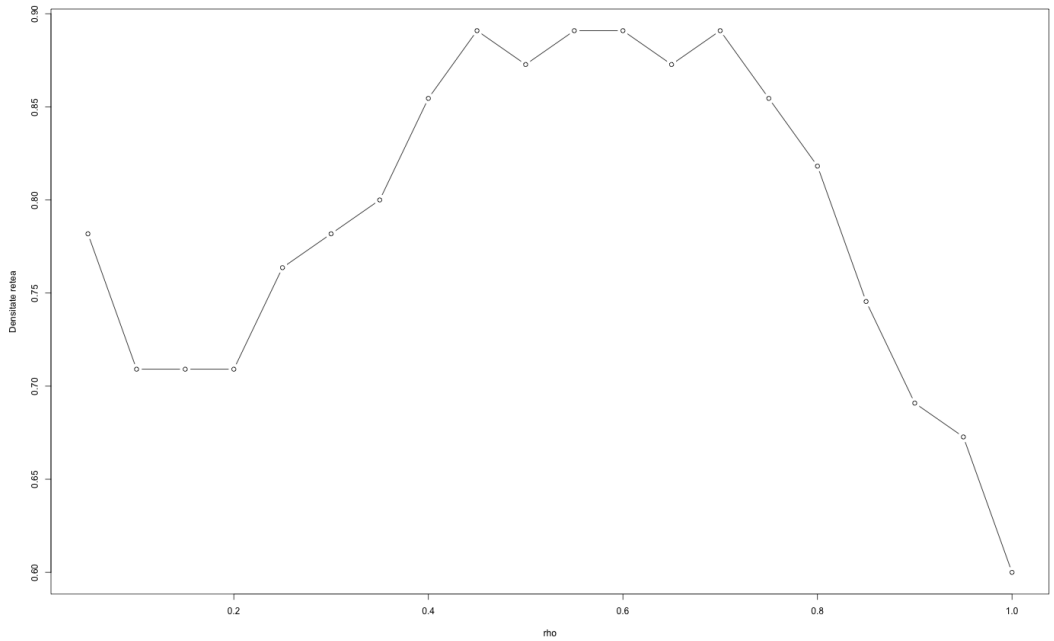

Sursa: figura generata de autoare prin scriptul `R/03_glasso_selection.R`, fisierul `outputs/glasso_density_curve.png`.

Figura 7.2 arata ca densitatea retelei scade pe masura ce penalizarea creste, ceea ce este in acord cu rolul lui ρ de a forta sparsitatea matricei de precizie estimate.

In analiza empirica principala este utilizata o valoare fixa a penalizarii, aleasa astfel incat reteaua rezultata sa ramana suficient de rara pentru a fi interpretabila. Din aceasta perspectiva, analiza pe grila nu este folosita doar ca procedura numerica, ci si ca instrument de justificare metodologica a nivelului de regularizare adoptat.

7.2.2 Sparsitatea matricei de precizie

Matricea de precizie estimata $\hat{\Theta}$ contine elemente extra-diagonale nule, spre deosebire de inversa empirica directa a matricei de covarianta, care tinde sa fie mult mai densa. Aceasta raritate structurala este rezultatul direct al penalizarii de tip ℓ_1 si reprezinta una dintre proprietatile centrale ale metodei graphical lasso.

Din punct de vedere statistic, zerourile din $\hat{\Theta}$ sunt importante deoarece indica absenta dependentei conditionale directe intre anumite perechi de sectoare, dupa controlul pentru toate celelalte variabile din sistem. Aceasta este diferenta esentiala fata de o analiza bazata doar pe corelatii perechi.

7.2.3 Interpretarea elementelor nenule

Elementele nenule ale lui $\hat{\Theta}$ pot fi impartite in doua categorii dupa semnul lor:

- $\hat{\theta}_{ij} < 0$: dependenta conditionala negativa – sectoarele tind sa se miste in directii opuse dupa controlul pentru celelalte sectoare. Acest tip de relatie poate indica efecte de substitutie sau competitie pentru capital intre sectoare.
- $\hat{\theta}_{ij} > 0$: dependenta conditionala pozitiva – sectoarele se misca impreuna dupa controlul pentru celelalte sectoare, sugerand expunere la factori comuni sau complementaritate economica.

7.3 Structura retelei financiare

7.3.1 Vizualizarea grafului

Reteaua financiara rezultata are $n = 11$ noduri si $|\hat{E}|$ muchii. Vizualizarea grafica din Figura 7.3 a fost produsa cu pachetul `igraph`, folosind un layout circular stabil, adecvat pentru etichete lungi si pentru comparatia vizuala dintre sectoare.

Observatia vizuala principala este neuniformitatea structurii: anumite noduri au mai multe conexiuni si sunt plasate in centrul grafului, in timp ce altele sunt mai periferice. Aceasta neuniformitate este primul semn al existentei unor sectoare cu rol sistemic diferentiat.

Figura 7.3: Reteaua financiara estimata pe baza reziduurilor VAR si a metodei graphical lasso.

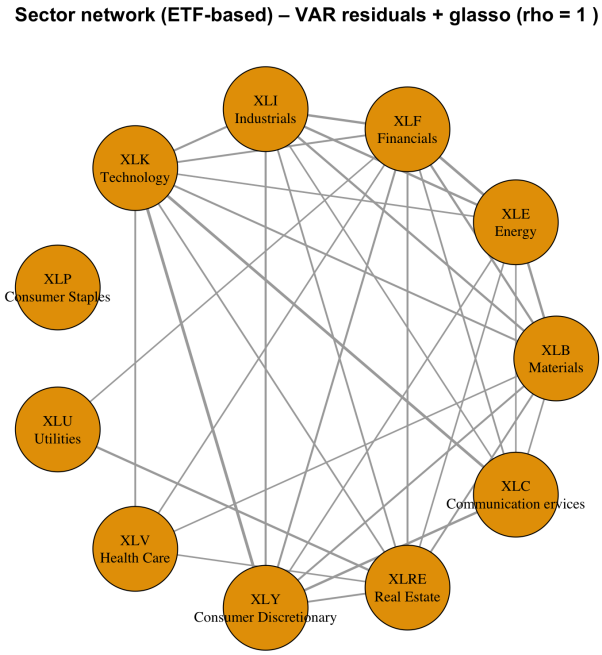

Sursa: figura generata de autoare prin scriptul `R/01_var_glasso_network.R`, fisierul `outputs/network.png`.

7.3.2 Cele mai importante muchii

Fisierul `top10_edges.csv` contine muchiile cu cea mai mare intensitate in valoare absoluta. Aceste legaturi sunt de interes special, deoarece ele corespund celor mai puternice dependente conditionale directe estimate in retea.

Din punct de vedere economic, este rezonabil ca printre aceste muchii sa apara legaturi intre sectoare cu expuneri apropiate la ciclul economic, la conditii de finantare sau la factori comuni de piata. Totusi, in aceasta lucrare accentul ramane pe interpretarea statistica a faptului ca doar un numar restrans de relatii directe domina structura estimata.

7.4 Masuri de centralitate: rezultate

7.4.1 Degree centrality

Tabelul de centralitate evidentiaza sectoarele cu cel mai ridicat degree. In general, sectoarele ciclice (XLK, XLF, XLI) tind sa aiba degree mai ridicat, fiind conectate direct cu mai multi participanti ai pietei.

Sectoarele defensive (XLU, XLP) au in general degree mai scazut, reflectand o pozitie mai

periferica in structura retelei. Aceasta separare este consistenta cu literatura financiara care distinge intre sectoare ciclice si defensive [12].

7.4.2 Strength (grad ponderat)

Masura de strength completeaza degree-ul prin incorporarea intensitatii legaturilor. Un sector poate avea un numar moderat de conexiuni, dar poate ramane important daca muchiile sale au ponderi mari in valoare absoluta.

Din acest motiv, strength-ul este mai informativ decat degree-ul simplu in retele ponderate si permite identificarea nodurilor care au un rol sistemic mai puternic in reteaua estimata.

7.4.3 Betweenness centrality

Sectoarele cu betweenness ridicat pot juca rolul de intermediari in transmiterea socurilor. Chiar daca nu au cel mai mare numar de conexiuni directe, ele se afla pe drumurile geodezice intre multi alti participanti. In perioade de stres financiar, socurile pot traversa aceste sectoare inainte de a afecta parti mai indepartate ale retelei.

7.4.4 Eigenvector centrality

Eigenvector centrality identifica sectoarele conectate nu doar cu multi vecini, ci si cu vecini importanti. Sectoarele cu eigenvector centrality ridicat sunt parte a unui nucleu central al retelei, mai dificil de izolat.

7.5 Interpretare statistica a rezultatelor

Din punct de vedere statistic, rezultatele sustin trei concluzii principale:

1. **Dependenta conditionala este rara**: nu toate sectoarele sunt dependente conditional intre ele. Multe din corelatiile observate direct intre randamente sunt mediate de al treilea sector si dispar cand se conditioneaza pe intregul sistem.

2. **Structura este neuniforma**: distributia centralitati intre sectoare este asimetrica, cu cateva sectoare dominante si mai multe periferice. Aceasta heterogenitate are implicatii directe pentru analiza riscului sistemic.

3. **Metodologia produce rezultate interpretabile**: reteaua recupereaza clasificari economice cunoscute (ciclice vs. defensive) printr-o procedura data-driven, sustinand indirect adecvarea metodologica a abordarii utilizate.

Aceste rezultate nu trebuie interpretate ca relatii cauzale, ci ca structuri de dependenta conditionala estimate pe perioada analizata. Robustetea lor la schimbari de metoda sau de esantion este discutata in capitolele urmatoare.

Capitolul 8

Analiza pe ferestre temporale

Analiza prezentata in capitolele anterioare estimeaza o singura retea financiara folosind toate observatiile disponibile. Aceasta abordare *statica* are avantajul utilizarii eficiente a datelor, dar ascunde potential modificarile structurale ale pietei de-a lungul timpului. Piata financiara americana a traversat in esantionul analizat mai multe faze distincte, caracterizate prin niveluri diferite de volatilitate si grade diferite de interconectare sectoriale.

In acest capitol este prezentata o extensie *dinamica* a analizei, bazata pe ferestre temporale rulante. Aceasta permite investigarea stabilitatii structurii retelei si identificarea perioadelor in care dependentele conditionale se modifica semnificativ.

8.1 Metodologia ferestrelor temporale

8.1.1 Definitia ferestrei rulante

Fie w dimensiunea ferestrei (in zile tranzactionate) si s pasul de deplasare. Definim o succesiune de subperioade:

$$\mathcal{I}_k = \{t_k, t_k + 1, \ldots, t_k + w - 1\}, \quad k = 1, 2, \ldots, K, \tag{8.1}$$

unde $t_k = t_1 + (k - 1) \cdot s$, iar $K = \lfloor (T - w)/s \rfloor + 1$ este numarul total de ferestre. Pentru fiecare fereastra $\mathcal{I}_k$ se repeta intreaga procedura:

1. Se estimeaza un model VAR(1) pe observatiile din $\mathcal{I}_k$.
2. Se calculeaza matricea de covarianta $\hat{\Sigma}^{(k)}$ a reziduurilor.
3. Se estimeaza matricea de precizie $\hat{\Theta}^{(k)}$ prin GLasso, folosind aceeasi valoare a parametrului de regularizare ca in analiza principala, pentru a pastra comparabilitatea intre ferestre.
4. Se construieste reteaua $G^{(k)} = (V, E^{(k)}, w^{(k)})$.
5. Se calculeaza indicatori de centralitate, cu accent pe *strength_abs*.

Aceasta procedura este implementata in scriptul `06_time_window_network.R`, iar sinteza rezultatelor este realizata in `07_write_time_window_summary_md.R`.

8.1.2 Alegerea dimensiunii ferestrei

Alegerea lui w presupune un compromis fundamental:

- *Ferestre mici* (de exemplu, $w = 120$ zile ≈ 6 luni): permit surprinderea schimbarilor rapide ale structurii pietei, dar reduc numarul de observatii disponibile per fereastra, crescand incertitudinea estimatiei.
- *Ferestre mari* (de exemplu, $w = 500$ zile ≈ 2 ani): ofera estimatii mai stabile, dar pot obscura schimbarile structurale rapide.

In proiect, fereastra a fost aleasa astfel incat sa mentina un raport $w/n \gg 1$ (unde $n = 11$ este numarul de sectoare), conditie necesara pentru estimarea stabila a modelului VAR si a matricei de covarianta.

8.2 Indicatori dinamici ai retelei

8.2.1 Evolutia centralitatii sectoriale

Fisierul `top_sector_per_window.csv` sintetizeaza, pentru fiecare fereastra, sectorul cu cea mai ridicata valoare a masurii *strength_abs*. Aceasta informatie permite investigarea stabilitatii sau variabilitatii pozitiei centrale in retea.

Daca acelasi sector apare frecvent in rolul de nod central, atunci pozitia sa poate fi interpretata ca relativ stabila in esantionul analizat. Daca, in schimb, identitatea nodului dominant se modifica intre ferestre, atunci acest lucru sugereaza ca structura dependentei conditionale este sensibila la contextul de piata si la subperioada analizata.

Din punct de vedere metodologic, aceasta analiza completeaza reteaua estimata pe intregul esantion si arata ca centralitatea structurala poate fi studiata nu doar static, ci si dinamic.

8.3 Interpretarea dinamica a rezultatelor

Analiza pe ferestre temporale adauga o dimensiune esentiala interpretarii structurii retelei. Ea arata ca pozitiile centrale ale sectoarelor nu trebuie privite ca proprietati complet fixe ale pietei, ci ca rezultate care pot varia in timp.

Din punct de vedere statistic, aceasta observatie este importanta deoarece sugereaza ca reteaua estimata pe intregul esantion reprezinta o agregare a unor configuratii locale diferite. In consecinta, analiza dinamica nu contrazice rezultatele statice, ci le completeaza, indicand in ce masura structura dependentei conditionale ramane stabila sau se modifica intre subperioade.

8.4 Limitele analizei dinamice

Analiza pe ferestre temporale presupune ipoteza implicita ca structura retelei este constanta in interiorul fiecarei ferestre. Aceasta ipoteza poate fi nerealista in perioade de schimbari rapide. O extensie mai riguroasa ar fi utilizarea unor modele cu parametri variabili continuu in timp (TVP-VAR), care insa depasesc scopul acestei lucrari [3].

De asemenea, rezultatele analizei dinamice depind de alegerea lui w si s. Robustetea concluziilor ar trebui verificata pentru mai multe valori ale acestor parametri, ceea ce constituie o directie naturala de dezvoltare ulterioara.

In ciuda acestor limite, analiza pe ferestre temporale este valoroasa pentru ca transforma reteaua dintr-un obiect static intr-un obiect dinamic, mai fidel naturii evolutive a pietelor financiare.

In plus, comparabilitatea intre ferestre depinde de mentinerea unei proceduri de estimare coerente de la o fereastra la alta. Din acest motiv, utilizarea aceleiasi penalizari in toate ferestrele are un rol metodologic important, deoarece reduce variatia artificiala indusa de recalibrari diferite ale parametrului de regularizare.

Capitolul 9

Discutii si limite

Rezultatele obtinute in aceasta lucrare sustin utilitatea combinarii modelelor VAR cu metoda graphical lasso pentru analiza structurii pietelor financiare. Totusi, orice analiza empirica trebuie insotita de o evaluare critica a limitelor sale metodologice si a domeniului de validitate al concluziilor.

9.1 Avantajele metodologice ale abordarii

Inainte de a discuta limitele, este util sa sintetizam avantajele distincte ale metodologiei adoptate fata de alternativele mai simple.

9.1.1 Separarea dependentei temporale de cea contemporana

Un avantaj fundamental al abordarii VAR + GLasso fata de o simpla analiza de corelatie este separarea clara a doua tipuri distincte de dependenta:

- *Dependenta temporala*: efectele valorilor trecute ale unui sector asupra evolutiei viitoare a altui sector, capturate de matricea $\hat{A}_1$.
- *Dependenta contemporana*: co-miscare simultana a socurilor, capturata de $\hat{\Sigma}$ si interpretata structural prin $\hat{\Theta}$.

O analiza bazata direct pe corelatiile randamentelor amesteca aceste doua efecte, producand o imagine distorsionata a relatiilor structurale.

9.1.2 Identificarea dependentelor conditionale

Al doilea avantaj este trecerea de la masuri de asociere bruta la dependente conditionale. Matricea de precizie permite separarea legaturilor directe de cele mediate prin variabile intermediare. Aceasta proprietate este esentiala in contextele unde este importanta identificarea canalelor directe de propagare a socurilor, spre deosebire de co-miscarea generala cauzata de factori comuni.

9.1.3 Parsimonie si interpretabilitate

Penalizarea ℓ_1 produce o retea rara, in care sunt retinute doar relatiile cu semnificatie statistica substantiala. Aceasta parsimonie este un avantaj practic: reteaua rezultata poate fi vizualizata, interpretata si discutata, spre deosebire de o matrice densa de coeficienti.

9.2 Limitele analizei

9.2.1 Dimensiunea esantionului

Esantionul utilizat, desi suficient pentru ilustrarea metodologiei, ramane limitat din perspectiva formularii unor concluzii foarte generale despre structura de lunga durata a pietei. Rezultatele trebuie interpretate in raport cu perioada concreta analizata si cu conditiile economice caracteristice acesteia.

O extensie naturala ar fi utilizarea unui esantion mai lung, care sa includa mai multe cicluri economice complete si sa permita evaluarea mai robusta a stabilitatii concluziilor.

9.2.2 Linearitatea modelului VAR

Modelul VAR presupune relatii liniare intre variabile. In piata financiara pot aparea:

- *Relatii neliniare*: dependentele dintre sectoare pot fi mai intense in perioade de stres (efect de *tail dependence*).
- *Schimbari de regim*: structura dependentei poate fi diferita in perioade de expansiune fata de contractie.
- *Efecte ARCH/GARCH*: volatilitatea conditionata variabila in timp nu este modelata de VAR standard.

Extinderi posibile includ modele VAR cu prag (TVAR), modele cu schimbari de regim Markov sau modele VAR-GARCH.

9.2.3 Selectia activelor si agregarea

Utilizarea ETF-urilor sectoriale implica o agregare a informatiei: comportamentul unui ETF reflecta media ponderata a companiilor din sector, nu comportamentul individual. La nivelul companiilor individuale, structura dependentei ar putea fi mai complexa si mai fragmentata.

De asemenea, selectia celor 11 sectoare standard GICS, desi exhaustiva, nu captureaza distinctii mai fine (de exemplu, intre subsectoare din tehnologie: hardware vs. software vs. semiconductori).

9.2.4 Dependenta de parametrul de regularizare

Reteaua finala depinde de alegerea parametrului de regularizare ρ. Chiar daca analiza pe grila si criteriul de tip BIC ofera un suport metodologic pentru alegerea nivelului de penalizare, structura exacta a retelei poate varia atunci cand ρ este modificat.

Din acest motiv, robustetea rezultatelor fata de variatii rezonabile ale parametrului de regularizare reprezinta o preocupare metodologica legitima. Aceasta observatie nu slabeste concluziile lucrarii, dar subliniaza faptul ca reteaua estimata trebuie inteleasa ca rezultat al unei proceduri de regularizare, nu ca obiect complet independent de alegerea parametrilor.

9.2.5 Absenta cauzalitatii

Reteaua de dependente conditionale nu implica relatii cauzale in sens economic. Faptul ca doua sectoare sunt conectate printr-o muchie nu inseamna ca unul il determina pe celalalt. Pentru inferenta cauzala ar fi necesare instrumente econometrice suplimentare (variabile instrumentale, discontinuitati de regresie, teste de cauzalitate Granger structurala) [8].

Scriptul `04_granger_network.R` exploreaza tocmai aceasta directie, construind o retea de cauzalitate Granger complementara retelei de dependente conditionale. Compararea celor doua retele poate oferi informatii suplimentare despre directia influentelor intre sectoare.

Figura 9.1: Reteaua de cauzalitate Granger obtinuta pentru modelul VAR(1).

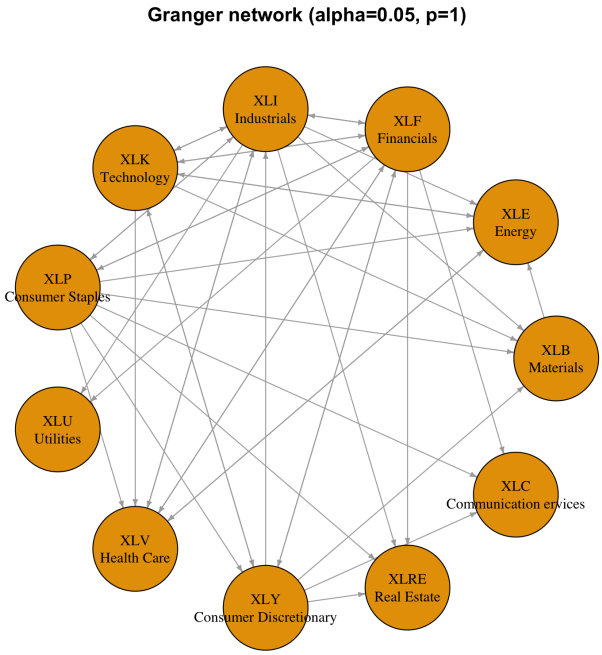

Sursa: figura generata de autoare prin scriptul `R/04_granger_network.R`, fisierul `outputs/granger_network.png`.

9.3 Directii de dezvoltare ulterioara

Pe baza limitelor identificate, pot fi propuse urmatoarele extensii:

1. **Extinderea esantionului**: includerea datelor de dinainte de 2018 pentru a acoperi cicluri economice mai complete.
2. **Modele cu volatilitate variabila**: combinarea VAR cu modele GARCH multivariat pentru a tine cont de heteroscedasticitate.
3. **Modele cu parametri variabili in timp (TVP-VAR)**: o alternativa mai riguroasa la analiza pe ferestre temporale [3].
4. **Compararea metodelor de estimare a retelei**: GLasso vs. CLIME vs. retele de corelatie partial, pentru a evalua robustetea structurii identificate.
5. **Analiza la nivel de companie**: coborarea de la ETF-uri sectoriale la actiuni individuale, pentru o granularitate mai mare.

Aceste directii nu diminueaza valoarea lucrarii de fata, ci sugereaza ca metodologia adoptata este suficient de flexibila pentru a fi extinsa si aprofundata in cercetari viitoare.

Capitolul 10

Concluzii

10.1 Sinteza metodologica

Lucrarea a avut ca obiectiv analiza structurii relatiilor dintre sectoarele pietei financiare prin combinarea a doua componente metodologice complementare: modelarea dependentei temporale printr-un model VAR si estimarea dependentei contemporane conditionale prin metoda graphical lasso. Aceasta separare este importanta deoarece permite distingerea intre efectele dinamice ale valorilor trecute si structura relatiilor directe dintre socurile contemporane.

Din punct de vedere al constructiei statistice, demersul a urmat un lant logic coerent. Mai intai, seriile de preturi au fost transformate in randamente logaritmice, adecvate pentru modelare stationara. Apoi, modelul VAR(1) a fost estimat pentru a extrage reziduurile, interpretate ca inovatii neanticipate. Pe baza matricii de covarianta a acestor reziduuri a fost estimata matricea de precizie penalizata, iar structura ei rara a fost interpretata drept o retea financiara. In etapa finala, aceasta retea a fost analizata prin masuri de centralitate si prin extensia dinamica pe ferestre temporale.

10.2 Contributii principale

Principala contributie a lucrarii consta in formularea si implementarea unei proceduri reproductibile de trecere de la date financiare brute la o reprezentare grafica interpretabila a dependentei conditionale dintre sectoare. In mod concret, contributiile pot fi sintetizate astfel.

In primul rand, lucrarea construieste un cadru unitar care leaga teoria seriilor temporale multivariate de teoria grafurilor gaussiene. Astfel, analiza retelei nu este folosita doar ca instrument descriptiv, ci are o baza matematica precisa: absenta unei muchii corespunde anularii unui element extra-diagonal din matricea de precizie si, implicit, absentei dependentei conditionale directe.

In al doilea rand, lucrarea propune o implementare empirica clara, structurata in scripturi separate pentru descarcarea datelor, estimarea modelului VAR, diagnostice, selectia parametrului de regularizare, constructia retelei si analiza dinamica. Aceasta organizare creste reproductibilitatea si face posibila verificarea fiecarui pas in mod independent.

In al treilea rand, rezultatele sunt interpretate atat statistic, cat si economic. Accentul nu cade doar pe reprezentarea vizuala a grafului, ci pe semnificatia structurala a centralitatii, a raritatii retelei si a persistentei anumitor legaturi directe intre sectoare.

10.3 Concluzii statistice si matematice

Rezultatele obtinute sustin ideea ca piata financiara sectoriala nu are o structura uniforma. Dupa filtrarea dependentei temporale, reteaua rezultata nu este completa, ceea ce arata ca o parte importanta a corelatiilor brute observate in date este mediata de alti factori sau de alte sectoare, si nu corespunde unor relatii directe. Din acest punct de vedere, metodologia utilizata este superioara unei simple analize de corelatie.

Masurile de centralitate evidentiaza faptul ca anumite sectoare ocupa pozitii mai importante in structura dependentei conditionale. Aceasta neuniformitate este relevanta pentru analiza riscului sistemic, deoarece socurile nu se propaga intr-un sistem omogen, ci printr-o arhitectura in care unele noduri pot avea rol de hub sau de intermediar.

Analiza pe ferestre temporale sugereaza, de asemenea, ca structura retelei nu este complet stabila in timp. Chiar daca anumite trasaturi par persistente, importanta relativa a sectoarelor si gradul de interconectare pot varia in functie de contextul macroeconomic si financiar. Aceasta observatie sustine ideea ca retelele financiare trebuie tratate nu doar ca obiecte statice, ci si ca structuri evolutive.

In ansamblu, lucrarea arata ca metodele matematice si statistice moderne pot oferi o imagine mai riguroasa asupra organizarii interne a pietei financiare decat indicatorii descriptivi traditionali. Combinatia dintre modele VAR, estimarea rara a matricii de precizie si analiza de retea constituie un cadru solid, interpretabil si extensibil pentru studierea interdependentelor dintre sectoare.

Bibliografie

[1] Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2):223–236.

[2] Csardi, G. and Nepusz, T. (2006). The igraph software package for complex network research. *InterJournal, Complex Systems*, 1695.

[3] Diebold, F. X. and Yilmaz, K. (2014). On the network topology of variance decompositions: Measuring the connectedness of financial firms. *Journal of Econometrics*, 182(1):119–134.

[4] Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417.

[5] Friedman, J., Hastie, T., and Tibshirani, R. (2008). Sparse inverse covariance estimation with the graphical lasso. *Biostatistics*, 9(3):432–441.

[6] Friedman, J., Hastie, T., and Tibshirani, R. (2019). glasso: Graphical lasso: Estimation of gaussian graphical models. *R package version 1.11*.

[7] Lauritzen, S. L. (1996). *Graphical Models*. Oxford University Press.

[8] Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*. Springer, Berlin.

[9] Pfaff, B. (2008). *Analysis of Integrated and Cointegrated Time Series with R*. Springer, 2 edition.

[10] Ravikumar, P., Wainwright, M. J., Raskutti, G., and Yu, B. (2011). High-dimensional covariance estimation by minimizing ℓ_1-penalized log-determinant divergence. *Electronic Journal of Statistics*, 5:935–980.

[11] Ryan, J. A. and Ulrich, J. M. (2024). *quantmod: Quantitative Financial Modelling Framework*. R package version 0.4.26.

[12] Tsay, R. S. (2010). *Analysis of Financial Time Series*. John Wiley & Sons, 3 edition.

[13] Yuan, M. and Lin, Y. (2007). Model selection and estimation in the Gaussian graphical model. *Biometrika*, 94(1):19–35.

Anexe

10.4 Bibliografia figurilor si tabelelor

Figuri

Figura 7.1 a fost generata prin scriptul `R/02_var_diagnostics.R` si exportata ca `outputs/var_stability_cusum.png`.

Figura 7.2 a fost generata prin scriptul `R/03_glasso_selection.R` si exportata ca `outputs/glasso_density_curve.png`.

Figura 7.3 a fost generata prin scriptul `R/01_var_glasso_network.R` si exportata ca `outputs/network.png`.

Figura 9.1 a fost generata prin scriptul `R/04_granger_network.R` si exportata ca `outputs/granger_network.png`.

Tabele

Tabelul 3.1 a fost realizat pe baza selectiei ETF-urilor sectoriale utilizate in analiza, definite in scripturile `R/00_download_data.R` si `R/99_etf_labels.R`.

10.5 Fragmente relevante de cod

10.5.1 Descarcarea datelor si calculul randamentelor logaritmice

```
tickers <- c("XLB","XLE","XLF","XLI","XLK","XLP","XLU","XLV","XLY","XLRE","XLC")

start_date <- as.Date("2016-01-01")
end_date   <- Sys.Date()

get_one <- function(sym) {
  x <- suppressWarnings(getSymbols(sym, src = "yahoo",
                                   from = start_date, to = end_date,
                                   auto.assign = FALSE))
  Ad(x)
}
```

```
prices_list <- lapply(tickers, get_one)
names(prices_list) <- tickers

prices <- do.call(merge, c(prices_list, all = FALSE))
colnames(prices) <- tickers

returns <- 100 * diff(log(prices))
returns <- na.omit(returns)

dir.create("data", showWarnings = FALSE)
saveRDS(prices,  "data/prices_sectors.rds")
saveRDS(returns, "data/returns_sectors.rds")
```

10.5.2 Estimarea modelului VAR si extragerea reziduurilor

```
returns <- readRDS("data/returns_sectors.rds")
Y <- as.matrix(returns)

maxlags <- 10
sel <- VARselect(Y, lag.max = maxlags, type = "const")
p <- sel$selection[["SC(n)"]]

var_fit <- VAR(Y, p = p, type = "const")

saveRDS(returns, "outputs/returns.rds")
saveRDS(var_fit, "outputs/var_fit.rds")

resid_mat <- residuals(var_fit)
S <- cov(resid_mat)

saveRDS(resid_mat, "outputs/var_residuals.rds")
```

10.5.3 Estimarea matricei de precizie prin graphical lasso

```
rho <- 1.00
gl <- glasso(S, rho = rho)
Theta <- gl$wi
```

```
pcor <- -Theta / sqrt(outer(diag(Theta), diag(Theta)))
diag(pcor) <- 0
```

10.5.4 Constructia retelei financiare bazate pe corelatii partiale

```
adj <- (abs(Theta) > 1e-8) * 1
diag(adj) <- 0

W <- pcor
W[adj == 0] <- 0

g <- graph_from_adjacency_matrix(W, mode = "max",
                                 weighted = TRUE, diag = FALSE)

edges_df <- as_data_frame(g, what = "edges")
write.csv(edges_df, "outputs/edges.csv", row.names = FALSE)

png("outputs/network.png", width = 2600, height = 1600, res = 220)
plot(g)
dev.off()
```

10.5.5 Calculul masurilor de centralitate

```
edges_pc <- read.csv("outputs/edges.csv", stringsAsFactors = FALSE)

g_pc <- graph_from_data_frame(edges_pc, directed = FALSE)
E(g_pc)$weight <- edges_pc$weight

deg_pc <- degree(g_pc)
str_pc <- strength(g_pc, weights = abs(E(g_pc)$weight))

w_pc <- abs(E(g_pc)$weight)
dist_pc <- 1 / (w_pc + 1e-8)

bet_pc <- betweenness(g_pc, directed = FALSE, weights = dist_pc)
clo_pc <- closeness(g_pc, normalized = TRUE, weights = dist_pc)

eig_pc <- eigen_centrality(g_pc, directed = FALSE,
```

```
                                weights = abs(E(g_pc)$weight))$vector
```

10.5.6 Analiza pe ferestre temporale

```
window_size <- 252
step_size   <- 21

returns <- readRDS("outputs/returns.rds")

for (start_idx in seq(1, nrow(returns) - window_size, by = step_size)) {

  end_idx <- start_idx + window_size - 1
  Y <- coredata(returns[start_idx:end_idx, ])

  var_fit <- VAR(Y, p = 1, type = "const")
  resid_mat <- residuals(var_fit)
  S <- cov(resid_mat)

  rho <- 1.00
  gl <- glasso(S, rho = rho)
  Theta <- gl$wi

  pcor <- -Theta / sqrt(outer(diag(Theta), diag(Theta)))
  diag(pcor) <- 0
}
```