Universitatea din Bucuresti

Facultatea de Matematica si Informatica

Lucrare de licenta

Analiza pietelor financiare folosind metode grafice

Absolvent

Malina Ispravnic

Coordonator stiintific

Petre Caraiani

Bucuresti

2026

Abstract

Lucrarea analizează structura relațiilor dintre sectoarele pieței financiare utilizând metode statistice și metode de analiză a rețelelor. Analiza se bazează pe randamente zilnice ale unor ETF-uri sectoriale obținute din baza de date Yahoo Finance.

Dependențele dinamice dintre variabile sunt modelate folosind un model vector autoregresiv. Reziduurile modelului sunt utilizate pentru estimarea matricei de covarianță.

Pentru identificarea dependenței condiționale dintre active este utilizată metoda graphical lasso, care estimează matricea de precizie. Structura acestei matrici este interpretată ca o rețea financiară în care nodurile reprezintă sectoare, iar muchiile reprezintă relații condiționale între acestea.

Analiza rețelei permite identificarea sectoarelor centrale și a structurii de interconectare a pieței financiare. În plus, extensia pe ferestre temporale evidențiază faptul că structura dependențelor nu este complet statică, ci variază în funcție de contextul economic și financiar al perioadei analizate.

Cuprins

Abstract **i**

1 Introducere **1**

1.1 Motivatia si contextul lucrarii 1

1.2 Obiectivele lucrarii 2

1.3 Structura lucrarii 2

2 Preliminarii **4**

2.1 Serii temporale multivariate 4

2.2 Modelul vector autoregresiv 4

2.2.1 Estimarea parametrilor 5

2.2.2 Selectia ordinului 5

2.3 Distributia gaussiana multivariata si independenta conditionala 6

2.4 Grafuri gaussiene Markov 6

2.5 Norma ℓ_1 si sparsitate 7

2.6 Masuri de centralitate in grafuri 7

3 Datele utilizate **9**

3.1 Selectia activelor 9

3.2 Colectarea si preprocesarea datelor 10

3.3 Trasabilitatea fisierelor 11

3.4 Perioada si frecventa de observatie 11

3.5 Preprocesarea datelor 12

3.5.1 Descarcarea datelor 12

3.5.2 Calculul randamentelor logaritmice 12

3.5.3 Structura setului de date 13

3.6 Proprietati statistice ale randamentelor 13

3.7 Etichetarea activelor 13

4 Modelul VAR **14**

4.1 Specificarea modelului 14

4.2 Selectia ordinului 14

4.2.1 Forma VAR(1) 15

4.3 Strategia de estimare 15

4.4 Strategia de diagnostic 15

4.5 Estimarea prin OLS 16

4.6 Verificarea stabilitatii 16

4.7 Diagnosticele modelului 17

4.7.1 Testul Portmanteau pentru autocorelatia reziduurilor 17

4.7.2 Testul ARCH multivariat 17

4.7.3 Testul de normalitate 17

4.8 Rolul reziduurilor in analiza ulterioara 17

5 Estimarea matricei de precizie prin graphical lasso **19**

5.1 Limitele estimarii directe 19

5.2 Problema de optimizare penalizata 19

5.2.1 Interpretarea termenilor 20

5.2.2 Convexitate si existenta solutiei 20

5.2.3 Algoritm de rezolvare 20

5.3 Selectia parametrului de regularizare 20

5.3.1 Criteriul BIC pentru graphical models 21

5.3.2 Analiza pe grila de valori 21

5.4 Proprietati statistice ale estimatorului GLasso 21

5.5 De la matricea de precizie la retea 22

5.6 Legatura cu implementarea empirica 22

6 Analiza retelei financiare **23**

6.1 Constructia retelei 23

6.2 Proprietati globale ale grafului 23
6.2.1 Densitatea retelei 23
6.2.2 Componenta conexa 24
6.2.3 Diametrul grafului 24
6.3 Masuri de centralitate 24
6.3.1 Degree centrality 24
6.3.2 Strength (gradul ponderat) 24
6.3.3 Betweenness centrality 25
6.3.4 Eigenvector centrality 25
6.4 Interpretarea structurii grafului 25
6.4.1 Sectoare centrale vs. periferice 25
6.4.2 Diferenta fata de analiza de corelatie 26
6.4.3 Grupuri de sectoare 26

7 Rezultate **27**
7.1 Rezultatele modelului VAR(1) 27
7.1.1 Selectia ordinului 27
7.1.2 Stabilitate si diagnostice 27
7.1.3 Matricea de covarianta a reziduurilor 28
7.2 Rezultatele Graphical Lasso 29
7.2.1 Selectia parametrului de regularizare 29
7.2.2 Sparsitatea matricei de precizie 30
7.2.3 Interpretarea elementelor nenule 30
7.3 Structura retelei financiare 30
7.3.1 Vizualizarea grafului 30
7.3.2 Cele mai importante muchii 31
7.4 Masuri de centralitate: rezultate 31
7.4.1 Degree centrality 31
7.4.2 Strength (grad ponderat) 32
7.4.3 Betweenness centrality 32

7.4.4 Eigenvector centrality 32
7.5 Ranking sectorial: reteaua partial-corr 32
7.6 Ranking sectorial: reteaua Granger 33
7.7 Interpretare statistica a rezultatelor 34

8 Analiza pe ferestre temporale 36
8.1 Metodologia ferestrelor temporale 36
8.1.1 Definitia ferestrei rulante 36
8.1.2 Alegerea dimensiunii ferestrei 37
8.2 Indicatori dinamici ai retelei 37
8.2.1 Evolutia strength-ului sectorial (reteaua partial-corr) 37
8.2.2 Evolutia PageRank-ului sectorial (reteaua Granger) 38
8.2.3 Evolutia out-degree-ului (reteaua Granger) 39
8.3 Analiza pe sub-esantioane 39
8.3.1 Motivatie si definirea perioadelor 39
8.3.2 Reteaua partial-corr: stabilitatea ierarhiei 40
8.3.3 Reteaua Granger: rotatia ierarhiei predictive 41
8.4 Interpretarea dinamica a rezultatelor 42
8.5 Limitele analizei dinamice 43

9 Discutii si limite 44
9.1 Avantajele metodologice ale abordarii 44
9.1.1 Separarea dependentei temporale de cea contemporana 44
9.1.2 Identificarea dependentelor conditionale 44
9.1.3 Parsimonie si interpretabilitate 45
9.2 Limitele analizei 45
9.2.1 Dimensiunea esantionului 45
9.2.2 Linearitatea modelului VAR 45
9.2.3 Selectia activelor si agregarea 45
9.2.4 Dependenta de parametrul de regularizare 46

9.2.5 Absenta cauzalitatii 46
9.3 Directii de dezvoltare ulterioara 47

10 Concluzii **48**
10.1 Sinteza metodologica 48
10.2 Contributii principale 49
10.3 Concluzii statistice si matematice 49
10.4 Concluzie finala 51

Bibliografie **52**

Anexe **54**
10.5 Bibliografia figurilor si tabelelor 54
10.6 Fragmente relevante de cod 54
10.6.1 Descarcarea datelor si calculul randamentelor logaritmice 54
10.6.2 Estimarea modelului VAR si extragerea reziduurilor 55
10.6.3 Estimarea matricei de precizie prin graphical lasso 55
10.6.4 Constructia retelei financiare bazate pe corelatii partiale 56
10.6.5 Calculul masurilor de centralitate 56
10.6.6 Analiza pe ferestre temporale 57

Capitolul 1

Introducere

Studiul relatiilor dintre sectoarele pietei financiare reprezinta o problema centrala atat in finantele cantitative, cat si in econometria moderna. Intelegerea modului in care un sector economic ii influenteaza pe ceilalti are implicatii directe pentru gestiunea riscului, diversificarea portofoliilor si monitorizarea stabilitatii sistemului financiar in ansamblu.

In mod traditional, dependenta dintre active financiare a fost masurata prin intermediul coeficientilor de corelatie Pearson. Aceasta abordare are insa limitari importante. Corelatia simpla nu distinge intre o relatie directa si una mediata printr-un factor comun. Doua sectoare pot parea corelate doar pentru ca ambele reactioneaza la acelasi factor macroeconomic, fara a exista o legatura directa intre ele. Mai mult, corelatia nu surprinde dependenta temporala: un sector poate reactiona cu intarziere la evolutia altui sector, efect pe care o simpla masura de asociere statica nu il poate evidentia.

Aceste limitari au motivat dezvoltarea unor cadre metodologice mai sofisticate, care combina modelarea seriilor temporale cu tehnici de estimare parsimonioasa. In aceasta lucrare este adoptata o astfel de abordare, structurata in doua etape principale. In prima etapa, dependenta temporala dintre sectoare este modelata printr-un model vector autoregresiv (VAR). Reziduurile acestui model capteaza componenta neanticipata a evolutiei fiecarui sector, curatata de efectele de memorie ale seriilor. In a doua etapa, structura de dependenta conditionala dintre aceste reziduuri este estimata prin metoda graphical lasso, care produce o matrice de precizie rara ce poate fi interpretata ca un graf financiar.

Cadrul teoretic al acestei abordari provine din teoria grafurilor gaussiene Lauritzen (1996), care stabileste o corespondenta riguroasa intre zerouri ale matricei de precizie si independenta conditionala. Prin urmare, graful obtinut nu este o simpla reprezentare vizuala, ci un obiect matematic cu semnificatie statistica precisa: o muchie intre doua noduri indica existenta unei dependente conditionale directe, care persista dupa controlul pentru toate celelalte sectoare din sistem.

1.1 Motivatia si contextul lucrarii

Alegerea ETF-urilor sectoriale americane ca obiect de studiu este motivata de mai multe considerente. In primul rand, aceste instrumente financiare ofera o reprezentare sintetica si

lichida a principalelor segmente ale economiei americane. Spre deosebire de actiunile individuale, ETF-urile sectoriale reduc zgomotul specific companiei si reflecta mai fidel dinamica sectoriala. In al doilea rand, piata americana este cea mai studiata si mai lichida piata de capital din lume, ceea ce face ca rezultatele obtinute sa fie comparabile cu literatura de specialitate existenta.

Perioada analizata, cuprinsa intre 01 ianuarie 2016 si 21 ianuarie 2026, include evenimente structurale majore cu impact semnificativ asupra pietelor financiare. Pandemia COVID-19 din 2020 a provocat o dislocare masiva si sincronizata a tuturor sectoarelor, urmata de o recuperare diferentiata. Perioada 2022-2023 a fost marcata de o politica monetara restrictiva a Rezervei Federale americane, cu rate ale dobanzii in crestere rapida, care a afectat diferit sectoarele ciclice fata de cele defensive. Aceste evenimente reprezinta teste naturale pentru stabilitatea structurii retelei financiare si justifica analiza pe ferestre temporale inclusa in lucrare.

1.2 Obiectivele lucrarii

Principalele obiective ale lucrarii sunt urmatoarele:

1. Prezentarea riguroasa a cadrului matematic si statistic utilizat, incluzand teoria modelelor VAR, estimarea prin graphical lasso si teoria grafurilor gaussiene.
2. Estimarea unui model VAR de ordin optim pe randamentele logaritmice ale ETF-urilor sectoriale si verificarea calitatii sale prin teste de diagnostic.
3. Estimarea matricei de precizie prin graphical lasso cu selectia parametrului de regularizare prin criterii informationale.
4. Construirea si analiza retelei financiare rezultate, cu accent pe masurile de centralitate si structura grafica.
5. Investigarea dinamicii temporale a structurii retelei prin analiza pe ferestre temporale rulante.

1.3 Structura lucrarii

Lucrarea este organizata dupa cum urmeaza. Capitolul 2 prezinta preliminariile matematice necesare: notiuni de serii temporale, modele VAR, distributii gaussiene multivariate si grafuri probabilistice. Capitolul 3 descrie datele utilizate, procedura de descarcare si preprocesare si proprietatile statistice ale randamentelor. Capitolul 4 este dedicat modelului VAR: specificare, estimare, selectia ordinului si diagnostice. Capitolul 5 prezinta metoda graphical lasso, problema de optimizare si selectia parametrului de regularizare. Capitolul 6 descrie constructia retelei

financiare si masurile de centralitate utilizate. Capitolul 7 prezinta si interpreteaza rezultatele obtinute. Capitolul 8 extinde analiza la ferestre temporale. Capitolul 9 discuta limitele metodologiei, iar Capitolul 10 sintetizeaza concluziile.

Capitolul 2

Preliminarii

In acest capitol sunt prezentate notiunile matematice si statistice care stau la baza metodologiei utilizate in lucrare. Scopul este formularea unui cadru teoretic coerent, care sa justifice alegerile metodologice si sa faciliteze interpretarea rezultatelor.

2.1 Serii temporale multivariate

Fie $(\Omega, \mathcal{F}, P)$ un spatiu de probabilitate si fie $\{X_t\}_{t\in\mathbb{Z}}$ un proces stochastic cu valori in $\mathbb{R}^n$. Spunem ca procesul este *stationat in sens larg* daca:

1. $\mathbb{E}[X_t] = \mu$ pentru orice t, unde $\mu \in \mathbb{R}^n$ este constant,
2. $\mathrm{Cov}(X_t, X_{t-h}) = \Gamma(h)$ depinde doar de h, nu de t.

Matricea $\Gamma(h) = \mathbb{E}[(X_t - \mu)(X_{t-h} - \mu)^\top]$ se numeste *matricea de autocorelatie la lag h*.

Stationaritatea este o conditie esentiala pentru modelele econometrice clasice. Randamentele logaritmice ale activelor financiare satisfac in general aceasta proprietate, spre deosebire de nivelurile preturilor, care prezinta tendinte de crestere pe termen lung (Tsay, 2010).

2.2 Modelul vector autoregresiv

Definitie 2.1. *Un proces $\{X_t\}$ cu valori in $\mathbb{R}^n$ satisface un model vector autoregresiv de ordin p, notat VAR(p), daca:*

$$X_t = \mu + A_1 X_{t-1} + A_2 X_{t-2} + \cdots + A_p X_{t-p} + \varepsilon_t, \tag{2.1}$$

unde $\mu \in \mathbb{R}^n$ este vectorul mediilor, $A_1, \ldots, A_p \in \mathbb{R}^{n\times n}$ sunt matricile de coeficienti, iar $\{\varepsilon_t\}$ este un proces de zgomot alb cu $\mathbb{E}[\varepsilon_t] = 0$ si $\mathrm{Cov}(\varepsilon_t) = \Sigma$, unde Σ este pozitiv definita (Lütkepohl, 2005).

Scriem modelul VAR(p) in forma compacta folosind operatorul de intarziere L, definit prin $LX_t = X_{t-1}$:

$$\left(I_n - A_1 L - A_2 L^2 - \cdots - A_p L^p\right) X_t = \mu + \varepsilon_t.$$

Polinomul matriceal $A(L) = I_n - A_1 L - \cdots - A_p L^p$ se numeste *polinomul autoregresiv* al modelului (Lütkepohl, 2005).

Definitie 2.2. *Modelul VAR(p) este stabil daca toate radacinile ecuatiei* $\det(A(z)) = 0$ *se afla in exteriorul discului unitate, adica satisfac* $|z| > 1$ *(Lütkepohl, 2005).*

Stabilitatea garanteaza existenta unei reprezentari stationare a procesului si este verificata in practica prin analiza valorilor proprii ale matricei companioana asociate modelului (Lütkepohl, 2005).

2.2.1 Estimarea parametrilor

Coeficientii modelului VAR(p) sunt estimati prin metoda celor mai mici patrate (OLS) aplicata ecuatie cu ecuatie. Fie $\mathbf{X} \in \mathbb{R}^{T \times n}$ matricea observatiilor si $\mathbf{Z} \in \mathbb{R}^{T \times (np+1)}$ matricea regresiva care contine valorile intarziate si constanta. Estimatorul OLS este:

$$\hat{B} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{X}, \tag{2.2}$$

unde $\hat{B}$ contine estimatii $\hat{\mu}, \hat{A}_1, \ldots, \hat{A}_p$ conform estimarii OLS ecuatie cu ecuatie pentru modelele VAR (Lütkepohl, 2005). Matricea de covarianta a reziduurilor este estimata prin:

$$\hat{\Sigma} = \frac{1}{T - np - 1} \sum_{t=p+1}^{T} \hat{\varepsilon}_t \hat{\varepsilon}_t^\top.$$

2.2.2 Selectia ordinului

Ordinul p este selectat prin minimizarea unui criteriu informational. *Criteriul Schwarz* (BIC) este definit prin:

$$\mathrm{BIC}(p) = \ln \det(\hat{\Sigma}_p) + \frac{\ln T}{T} \cdot p \cdot n^2, \tag{2.3}$$

unde $\hat{\Sigma}_p$ este matricea de covarianta estimata a reziduurilor pentru un model de ordin p (Lütkepohl, 2005). BIC penalizeaza mai puternic modelele complexe comparativ cu AIC si tinde sa selecteze modele mai parsimonioase (Lütkepohl, 2005).

2.3 Distributia gaussiana multivariata si independenta conditionala

Fie $X = (X_1, \ldots, X_n)^\top \sim \mathcal{N}_n(\mu, \Sigma)$ un vector gaussian cu medie μ si matrice de covarianta $\Sigma \succ 0$. Densitatea sa este:

$$f(x) = \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)\right).$$

Definitie 2.3. *Matricea de precizie este $\Theta = \Sigma^{-1}$ (Lauritzen, 1996).*

Propozitie 2.4. *Fie $X \sim \mathcal{N}_n(\mu, \Sigma)$ si fie $\Theta = \Sigma^{-1}$. Atunci X_i si X_j sunt independente conditional fata de $X_{V\setminus\{i,j\}}$ (celelalte variabile) daca si numai daca $\theta_{ij} = 0$ (Lauritzen, 1996).*

Demonstraţie. Aceasta proprietate urmeaza din proprietatile distributiei gaussiene conditionale. Distributia conditionala $X_i \mid X_{V\setminus\{i\}}$ este gaussiana cu medie care depinde liniar de X_j cu coeficient proportional cu θ_{ij}. Prin urmare $\theta_{ij} = 0$ implica absenta lui X_j din regresia lui X_i pe celelalte variabile, adica independenta conditionala (Lauritzen, 1996). □

Aceasta propozitie este fundamentala pentru interpretarea retelei financiare: structura de zerouri a matricei Θ codifica exact structura de independenta conditionala a sistemului.

2.4 Grafuri gaussiene Markov

Definitie 2.5. *Un graf neorientat $G = (V, E)$ consta dintr-o multime finita de noduri $V = \{1, \ldots, n\}$ si o multime de muchii $E \subseteq \{\{i, j\} : i \neq j\}$.*

Definitie 2.6. *Un model grafic gaussian (graf Markov gaussian) asociat grafului $G = (V, E)$ este familia distributiilor $\mathcal{N}_n(\mu, \Sigma)$ pentru care $\theta_{ij} = 0$ ori de cate ori $\{i, j\} \notin E$ (Lauritzen, 1996).*

Prin urmare, muchia $\{i, j\} \in E$ exista daca si numai daca $\theta_{ij} \neq 0$, adica daca X_i si X_j sunt conditional dependente (Lauritzen, 1996). Reteaua financiara construita in aceasta lucrare este tocmai un astfel de model grafic gaussian, in care nodurile sunt sectoarele pietei, iar muchiile reprezinta dependente conditionale estimate.

2.5 Norma ℓ_1 si sparsitate

Fie $A \in \mathbb{R}^{n\times n}$. *Norma elementwise* ℓ_1 este definita prin:

$$\|A\|_1 = \sum_{i=1}^{n}\sum_{j=1}^{n} |a_{ij}|.$$

In contextul estimarii matricei de precizie, penalizarea cu norma ℓ_1 incurajeaza solutii *sparse* (cu multe elemente nule). Aceasta proprietate este esentiala pentru obtinerea unor grafuri financiare interpretabile, in care relatiile lipsite de semnificatie statistica sunt eliminate (Friedman et al., 2008).

Remarca 2.7. *In aceasta lucrare, penalizarea de tip ℓ_1 are un rol dublu. Pe de o parte, ea regularizeaza problema de estimare intr-un cadru de dimensiune relativ mare. Pe de alta parte, ea conduce la o structura rara a matricei de precizie, ceea ce permite interpretarea dependentei conditionale sub forma unei retele financiare inteligibile.*

2.6 Masuri de centralitate in grafuri

Fie $G = (V, E, w)$ un graf neorientat ponderat, cu $w_{ij} \geq 0$.

Definitie 2.8. *Gradul ponderat (strength) al nodului i este:*

$$s_i = \sum_{j\in\mathcal{N}(i)} w_{ij},$$

unde $\mathcal{N}(i) = \{j : \{i, j\} \in E\}$ este multimea vecinilor lui i.

Definitie 2.9. *Betweenness centrality a nodului i este (Freeman, 1977):*

$$C_B(i) = \sum_{\substack{s,t\in V\\ s\neq i\neq t}} \frac{\sigma(s, t \mid i)}{\sigma(s, t)},$$

unde $\sigma(s, t)$ este numarul de drumuri geodezice de la s la t, iar $\sigma(s, t \mid i)$ este numarul celor care trec prin i.

Definitie 2.10. *Eigenvector centrality a nodului i este componenta i a vectorului propriu dominant* **x** *al matricei de adiacenta ponderata W (Bonacich, 1987):*

$$\lambda x_i = \sum_{j\in\mathcal{N}(i)} w_{ij}x_j, \quad \lambda = \lambda_{\max}(W).$$

Aceste trei masuri ofera perspective complementare asupra importantei unui nod: gradul ponderat masoara conectivitatea directa, betweenness masoara rolul de intermediar, iar eigenvector centrality tine cont de importanta vecinilor.

Capitolul 3

Datele utilizate

Analiza empirica realizata in aceasta lucrare se bazeaza pe date financiare zilnice extrase din Yahoo Finance. Au fost selectate ETF-uri sectoriale care urmaresc evolutia principalelor sectoare ale pietei de capital din Statele Unite ale Americii. Alegerea acestor active este motivata de faptul ca ele ofera o reprezentare sintetica si lichida a unor segmente economice importante si permit comparatii clare intre sectoare, eliminand zgomotul specific companiilor individuale.

3.1 Selectia activelor

Sectoarele analizate corespund clasificarii standard GICS (Global Industry Classification Standard) (MSCI and S&P Dow Jones Indices, 2024) si sunt acoperite de urmatoarele ETF-uri emise de State Street Global Advisors (SPDR):

Tabelul 3.1: ETF-urile sectoriale utilizate in analiza

Ticker	Sector	Descriere
XLB	Materials	Companii din sectorul materialelor de baza, incluzand produse chimice, metale si materiale pentru constructii.
XLE	Energy	Companii din energie, inclusiv petrol, gaze naturale si servicii energetice.
XLF	Financials	Banci, companii de asigurari, servicii financiare si piete de capital.
XLI	Industrials	Transport, productie industriala, servicii comerciale si bunuri de capital.
XLK	Technology	Companii din tehnologie, software, hardware si semiconductori.
XLP	Consumer Staples	Bunuri de consum de baza, retail alimentar, bauturi si produse de uz curent.
XLU	Utilities	Furnizori de electricitate, apa, gaz si alte utilitati.
XLV	Health Care	Farmaceutice, echipamente medicale, servicii medicale si biotehnologie.
XLY	Consumer Discretionary	Bunuri si servicii discretionare, retail non-esential, automobile si divertisment.
XLRE	Real Estate	Companii imobiliare si REIT-uri.
XLC	Communication Services	Telecomunicatii, media, servicii interactive si platforme de comunicare.

Sursa: tabel realizat pe baza selectiei ETF-urilor sectoriale utilizate in analiza.

Aceste unsprezece sectoare ofera o acoperire larga a pietei de capital americane si permit o analiza comprehensiva a structurii de dependenta.

3.2 Colectarea si preprocesarea datelor

Datele au fost descarcate automat in limbajul R folosind pachetul `quantmod`. Pentru fiecare ETF s-au extras preturile ajustate de inchidere (*adjusted close*), deoarece acestea incorporeaza efectele dividendelor si ale altor ajustari corporative.

Dupa descarcare, seriile au fost aliniate pe intersectia zilelor de tranzactionare disponibile pentru toate activele, astfel incat esantionul final sa fie sincronizat pe toate cele 11 sectoare. Pe baza acestor preturi s-au calculat randamentele logaritmice zilnice, exprimate procentual, prin formula

(Tsay, 2010)

$$r_t^{(i)} = 100 \log \left(\frac{P_t^{(i)}}{P_{t-1}^{(i)}} \right).$$

Aceasta transformare este standard in econometria financiara, deoarece randamentele logaritmice sunt mai adecvate pentru modelare decat nivelurile preturilor si sunt mai apropiate de ipoteza de stationaritate necesara in analiza VAR (Tsay, 2010).

Aceasta alegere metodologica este esentiala pentru coerenta analizei, deoarece toate variabilele sunt observate simultan in fiecare moment de timp, ceea ce permite interpretarea directa a matricii de covarianta si a matricii de precizie fara ajustari suplimentare.

3.3 Trasabilitatea fisierelor

Pipeline-ul de prelucrare salveaza explicit preturile in fisierul `data/prices_sectors.rds` si randamentele in `data/returns_sectors.rds`. Aceasta separare intre etapa de descarcare si etapa de modelare creste reproductibilitatea analizei si permite verificarea independenta a fiecarei faze a procesarii.

3.4 Perioada si frecventa de observatie

Esantionul utilizat acopera perioada cuprinsa intre 01 ianuarie 2016 si 21 ianuarie 2026, la frecventa zilnica, rezultand aproximativ $T = 1900$ observatii per activ dupa alinierea seriilor si eliminarea valorilor lipsa.

Din punct de vedere statistic, dimensiunea esantionului este adecvata pentru metodele utilizate. In particular, in raport cu numarul de variabile ($n = 11$), avem un regim in care $T \gg n$, ceea ce asigura stabilitatea estimarii modelului VAR si a matricii de covarianta empirice. In acest context, utilizarea metodei graphical lasso nu este determinata de o problema de tip high-dimensional ($p \gg n$), ci de necesitatea obtinerii unei reprezentari rare (sparse) si interpretabile a structurii de dependenta conditionala.

Alegerea perioadei reflecta si constrangerea de disponibilitate comuna a datelor pentru toate ETF-urile sectoriale incluse in analiza. Seriile au fost aliniate pe intersectia zilelor de tranzactionare, ceea ce garanteaza comparabilitatea observatiilor si evita introducerea unor proceduri de imputare care ar putea distorsiona estimarea dependentei conditionale.

Aceasta alegere metodologica este esentiala pentru coerenta analizei, deoarece toate variabilele sunt observate simultan in fiecare moment de timp, ceea ce permite interpretarea directa a matricii de covarianta si a matricii de precizie fara ajustari suplimentare.

Intervalul analizat include mai multe regimuri de piata relevante, ceea ce permite investigarea stabilitatii structurii retelei in conditii diferite de volatilitate si corelatie. Dintre acestea, pot fi mentionate urmatoarele episoade:

- **2018-2019**: tensiuni comerciale SUA-China si cresterea incertitudinii macrofinanciare.
- **Februarie-martie 2020**: socul COVID-19, urmat de o crestere brusca a volatilitatii si de o corelare accentuata intre sectoare.
- **2022**: ciclul de inasprire monetara al Fed, cu efecte diferentiate asupra sectoarelor sensibile la dobanda.
- **2023-2025**: reasezare sectoriala si consolidarea rolului sectorului tehnologic in dinamica pietei.

Aceste episoade creeaza un cadru empiric relevant pentru a testa daca structura retelei financiare se modifica in timp, aspect analizat in Capitolul 8.

3.5 Preprocesarea datelor

3.5.1 Descarcarea datelor

Datele au fost descarcate automat prin scriptul `00_download_data.R`, utilizand pachetul `quantmod` (Ryan and Ulrich, 2024) din R. Scriptul preia preturile de inchidere ajustate pentru dividende si split-uri si construieste un set de date coerent in format `xts` (extensible time series).

Utilizarea unui script automatizat are avantajul reproducibilitatii: orice actualizare a perioadei de observatie sau a listei de active poate fi integrata fara interventii manuale.

3.5.2 Calculul randamentelor logaritmice

Fie $P_{i,t}$ pretul ajustat al ETF-ului i la momentul t. Randamentul logaritmic zilnic este definit prin:

$$r_{i,t} = \ln P_{i,t} - \ln P_{i,t-1} = \ln \frac{P_{i,t}}{P_{i,t-1}}, \quad t = 2, \ldots, T. \tag{3.1}$$

Aceasta transformare are mai multe avantaje fata de randamentele aritmetice $\frac{P_{i,t}-P_{i,t-1}}{P_{i,t-1}}$:

1. *Aditivitate temporala*: randamentele logaritmice pe perioade mai lungi se obtin prin simpla suma a randamentelor zilnice.

2. *Simetrie*: cresterile si scaderile procentuale sunt tratate simetric.
3. *Stationaritate*: seriile de randamente nu prezinta tendinte de crestere pe termen lung, spre deosebire de preturi (Tsay, 2010).

3.5.3 Structura setului de date

Dupa calcularea randamentelor, datele sunt organizate intr-o matrice $R \in \mathbb{R}^{T \times n}$, unde $T \approx 1900$ este numarul de zile tranzactionate si $n = 11$ este numarul de sectoare. Fiecare coloana corespunde unui ETF, iar fiecare linie corespunde unei zile de tranzactionare.

Aceasta reprezentare matriciala este esentiala pentru aplicarea modelelor multivariate, deoarece permite interpretarea dependentei dintre variabile atat in termeni de covarianta, cat si in termeni de dependenta conditionala prin matricea de precizie.

3.6 Proprietati statistice ale randamentelor

Randamentele zilnice ale ETF-urilor sectoriale prezinta proprietati statistice tipice datelor financiare, cunoscute in literatura sub numele de *stilizate* (Cont, 2001):

- **Medie apropiata de zero**: consistent cu ipoteza de mers aleatoriu, randamentele zilnice au medii statistice nesemnificativ diferite de zero.
- **Cozi groase**: kurtoza excesiva pozitiva indica distributii cu cozi mai groase decat distributia normala, ceea ce inseamna o frecventa mai mare a evenimentelor extreme.
- **Asimetrie negativa**: randamentele negative extreme sunt mai frecvente decat cele pozitive extreme, reflectand comportamentul asimetric al pietelor in perioade de stres.
- **Volatilitate grupata**: perioade de volatilitate ridicata tind sa fie urmate de perioade de volatilitate ridicata (efectul ARCH).

Aceste proprietati justifica utilizarea unui model VAR aplicat pe randamente (nu pe preturi) si interpretarea prudenta a testelor de normalitate in etapa de diagnostic.

3.7 Etichetarea activelor

Pentru organizarea consistenta a rezultatelor, scriptul `99_etf_labels.R` defineste etichetele clare asociate fiecarui ticker. Aceasta facilitate este importanta pentru lizibilitatea graficelor si tabelelor de centralitate, in care nodurile retelei financiare sunt identificate prin numele sectorului (de exemplu, `XLK` → “Tehnologie”).

Capitolul 4

Modelul VAR

Primul pas metodologic al lucrarii este modelarea dependentei dinamice dintre randamentele activelor. In acest scop este utilizat un model vector autoregresiv (VAR). Ideea centrala este ca evolutia curenta a fiecarui sector poate depinde de valorile trecute ale tuturor sectoarelor incluse in sistem. Prin filtrarea VAR, componenta autoregresiva este eliminata, iar reziduurile raman pentru analiza dependentei contemporane.

4.1 Specificarea modelului

Fie $X_t = (r_{1,t}, r_{2,t}, \ldots, r_{n,t})^\top \in \mathbb{R}^n$ vectorul randamentelor logaritmice zilnice ale celor $n = 11$ sectoare la momentul t. Modelul VAR de ordin p, definit formal in Capitolul 2, are forma (Lütkepohl, 2005):

$$X_t = \mu + \sum_{k=1}^{p} A_k X_{t-k} + \varepsilon_t, \tag{4.1}$$

unde $\mu \in \mathbb{R}^n$ este vectorul constantelor, $A_k \in \mathbb{R}^{n \times n}$ sunt matricile de coeficienti la lag-ul k, iar ε_t este un vector de reziduuri contemporane cu $\mathbb{E}[\varepsilon_t] = 0$ si $\mathrm{Cov}(\varepsilon_t) = \Sigma$.

4.2 Selectia ordinului

Alegerea ordinului p al modelului este o etapa critica. Un ordin prea mic lasa dependente temporale nemodelate in reziduuri, contaminand analiza ulterioara. Un ordin prea mare creste dimensionalitatea inutila si reduce precizia estimatiei.

In lucrare, selectia ordinului este realizata prin minimizarea criteriului BIC (ecuatia (2.3) din Capitolul 2). Rezultatul obtinut este:

$$\hat{p} = 1. \tag{4.2}$$

Alegerea unui VAR(1) este plauzibila pentru date financiare zilnice. Randamentele actiunilor au memorie scurta, iar reactiile pietei la informatii noi sunt in general rapide (Fama, 1970; Tsay, 2010). Un lag de o zi este suficient pentru a capta efectele de autocorelare semnificative.

4.2.1 Forma VAR(1)

In cazul $p = 1$, modelul devine:

$$X_t = \mu + A_1 X_{t-1} + \varepsilon_t, \tag{4.3}$$

unde $A_1 \in \mathbb{R}^{11\times 11}$ este matricea de coeficienti la lag 1. Elementul (i, j) al lui A_1, notat $a_{ij}^{(1)}$, masoara efectul dinamic al randamentului sectorului j din ziua precedenta asupra randamentului sectorului i in ziua curenta, dupa controlul pentru toate celelalte sectoare.

4.3 Strategia de estimare

Implementarea empirica urmeaza o succesiune clara de pasi. Mai intai, pe baza randamentelor zilnice ale celor 11 ETF-uri sectoriale, se selecteaza ordinul modelului VAR prin criterii informationale, folosind o valoare maxima `lag.max = 10`. In analiza finala este ales ordinul recomandat de criteriul Schwarz, deoarece acesta favorizeaza specificatii mai parsimonioase (Lütkepohl, 2005).

Ulterior, modelul VAR este estimat cu termen constant, iar reziduurile obtinute sunt extrase pentru etapa urmatoare a analizei. Ideea metodologica esentiala a lucrarii este ca modelul VAR nu reprezinta scopul final al modelarii, ci un mecanism de filtrare a dependentei temporale liniare. Reteaua financiara nu este construita direct din randamentele brute, ci din structura contemporana ramasa in reziduuri dupa aceasta filtrare.

Aceasta alegere este importanta din punct de vedere statistic. Daca analiza grafica ar fi aplicata direct asupra randamentelor, atunci legaturile estimate ar amesteca dependenta contemporana cu dependenta pe lag-uri. Prin introducerea modelului VAR in prima etapa, cele doua componente sunt separate in mod mai clar (Lütkepohl, 2005).

4.4 Strategia de diagnostic

Dupa estimarea modelului, adecvarea specificatiei este verificata prin mai multe teste de diagnostic aplicate reziduurilor. In implementarea lucrarii sunt evaluate:

- stabilitatea modelului, printr-o analiza de tip OLS-CUSUM;
- autocorelatia reziduala, prin testul Portmanteau;
- heteroscedasticitatea de tip ARCH;
- normalitatea reziduurilor, printr-un test Jarque-Bera multivariat.

Aceste proceduri de diagnostic sunt standard in analiza modelelor VAR (Lütkepohl, 2005; Tsay, 2010).

Rolul acestor verificari este de a evalua daca modelul VAR a reusit sa elimine in mod satisfacator structura dinamica liniara din date. In special, absenta autocorelatiei reziduale este importanta pentru justificarea pasului urmator, deoarece matricea de covarianta folosita in graphical lasso este construita pe baza acestor reziduuri.

4.5 Estimarea prin OLS

Parametrii modelului VAR(1) sunt estimati prin metoda celor mai mici patrate (OLS) aplicata ecuatie cu ecuatie. Definim:

$$\mathbf{Y} = \begin{pmatrix} X_2^\top \\ \vdots \\ X_T^\top \end{pmatrix} \in \mathbb{R}^{(T-1)\times n}, \quad \mathbf{Z} = \begin{pmatrix} 1 & X_1^\top \\ \vdots & \vdots \\ 1 & X_{T-1}^\top \end{pmatrix} \in \mathbb{R}^{(T-1)\times(n+1)}.$$

Estimatorul OLS al matricei de coeficienti $B = [\mu \mid A_1]$ este (Lütkepohl, 2005):

$$\hat{B} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}, \tag{4.4}$$

iar matricea de covarianta a reziduurilor este estimata prin:

$$\hat{\Sigma} = \frac{1}{T-n-2} \sum_{t=2}^{T} \hat{\varepsilon}_t \hat{\varepsilon}_t^\top, \quad \hat{\varepsilon}_t = X_t - \hat{\mu} - \hat{A}_1 X_{t-1}. \tag{4.5}$$

Estimarea este implementata in R prin pachetul `vars` (Pfaff, 2008), functia `VAR()`, in scriptul `01_var_glasso_network.R`.

4.6 Verificarea stabilitatii

Conditia de stabilitate a VAR(1) cere ca toate valorile proprii ale matricei A_1 sa aiba modul strict mai mic decat 1 (Lütkepohl, 2005). Echivalent, toate radacinile polinomului caracteristic $\det(I_n - A_1 z) = 0$ trebuie sa se afle in exteriorul discului unitate.

Verificarea stabilitatii este realizata in scriptul `02_var_diagnostics.R`. Rezultatele confirma ca modelul este stabil: toate valorile proprii ale lui $\hat{A}_1$ au modul sub 1, ceea ce garanteaza ca procesul are o reprezentare stationara si ca interpretarile dinamice sunt valide.

4.7 Diagnosticele modelului

Calitatea modelului VAR estimat trebuie validata prin mai multe teste de diagnostic, implementate in scriptul `02_var_diagnostics.R`.

4.7.1 Testul Portmanteau pentru autocorelatia reziduurilor

Testul Portmanteau (Ljung-Box multivariat) verifica ipoteza nula ca reziduurile nu sunt autocorelatate pana la lag-ul h. Statistica testului este:

$$Q_h = T^2 \sum_{k=1}^{h} \frac{1}{T-k} \operatorname{tr}\left(\hat{C}_k^\top \hat{C}_0^{-1} \hat{C}_k \hat{C}_0^{-1}\right), \tag{4.6}$$

unde $\hat{C}_k = \frac{1}{T} \sum_{t=k+1}^{T} \hat{\varepsilon}_t \hat{\varepsilon}_{t-k}^\top$ este matricea de autocorelatie la lag k.

Sub H_0, statistica Q_h urmeaza asimptotic o distributie χ^2 cu $n^2(h-p)$ grade de libertate (Lütkepohl, 2005). Rezultatele testului indica absenta autocorelatiei semnificative in reziduuri, ceea ce valideaza specificatia VAR(1).

4.7.2 Testul ARCH multivariat

Datele financiare prezinta frecvent efecte de volatilitate grupata (ARCH/GARCH). Testul ARCH multivariat verifica daca variantele conditionale ale reziduurilor sunt constante in timp. Prezenta efectelor ARCH nu invalideaza estimatii OLS ale coeficientilor VAR (care raman nebiasate), dar afecteaza eficienta si trebuie luata in considerare la interpretarea rezultatelor (Tsay, 2010).

4.7.3 Testul de normalitate

Testul Jarque-Bera multivariat verifica normalitatea distributiei reziduurilor prin masurarea asimetriei si kurtozei. In datele financiare, este bine cunoscut faptul ca distributiile randamentelor au cozi mai groase decat distributia normala (kurtoza excesiva pozitiva) (Cont, 2001). Prin urmare, respingerea normalitatii nu este neasteptata si nu invalideaza analiza, cu conditia ca numarul de observatii sa fie suficient de mare pentru a invoca teoreme de tip limita centrala.

4.8 Rolul reziduurilor in analiza ulterioara

Reziduurile $\hat{\varepsilon}_t$ obtinute din modelul VAR(1) reprezinta componentele neanticipate ale evolutiei fiecarui sector la momentul t, curatate de efectele autoregresive. In termeni economici, ele pot fi

interpretate ca *socuri* sau informatii noi care afecteaza simultan piata la momentul t.

Matricea de covarianta $\hat{\Sigma}$ a acestor reziduuri masoara dependenta *contemporana* dintre socuri, adica relatiile dintre sectoare care nu pot fi explicate prin evolutia lor istorica proprie. Aceasta matrice este intrarea principala pentru etapa urmatoare: estimarea matricei de precizie prin graphical lasso.

Un avantaj major al filtrarii VAR este separarea clara a doua tipuri de dependenta. Dependenta temporala (cum valorile trecute ale sectorului j influenteaza evolutia sectorului i) este capturata de matricea A_1. Dependenta contemporana (cum socurile simultane sunt corelate intre sectoare) este capturata de Σ. Aceasta separare este esentiala pentru constructia unei retele financiare interpretabile (Lütkepohl, 2005; Friedman et al., 2008).

Capitolul 5

Estimarea matricei de precizie prin graphical lasso

Dupa eliminarea dependentei temporale prin modelul VAR, atentia se muta asupra structurii de dependenta contemporana dintre reziduuri. Obiectivul este estimarea matricei de precizie $\Theta = \Sigma^{-1}$, ale carei elemente nenule definesc reteaua financiara.

5.1 Limitele estimarii directe

O prima idee ar fi sa estimam Θ prin inversarea matricei de covarianta empirica $\hat{\Sigma}$. Aceasta abordare are insa limitari serioase:

1. *Instabilitate numerica*: cand n este de aceeasi ordine cu T, $\hat{\Sigma}$ poate fi prost conditionata, iar $\hat{\Sigma}^{-1}$ amplifica erorile de estimare.
2. *Lipsa de sparsitate*: inversa empirica este in general densa, producand un graf complet greu de interpretat.
3. *Supraajustare*: o matrice de precizie densa include inevitabil relatii slabe sau accidentale care nu reflecta structura reala a datelor.

In contextul acestei lucrari, cu $n = 11$ sectoare si $T \approx 1900$ observatii, raportul $n/T \approx 0.006$ este favorabil, dar sparsitatea este totusi dorita pentru interpretabilitate. Metoda graphical lasso rezolva ambele probleme (Friedman et al., 2008).

5.2 Problema de optimizare penalizata

Metoda graphical lasso (GLasso), propusa de (Friedman et al., 2008), estimeaza matricea de precizie prin maximizarea log-verosimilitatii penalizate:

$$\hat{\Theta} = \arg\max_{\Theta \succ 0} \Big[\log\det(\Theta) - \operatorname{tr}(\hat{S}\,\Theta) - \rho\,\|\Theta\|_1 \Big], \tag{5.1}$$

unde:

- $\hat{S}$ este matricea de covarianta empirica a reziduurilor VAR,
- $\rho > 0$ este parametrul de regularizare,
- $\|\Theta\|_1 = \sum_{i \neq j} |\theta_{ij}|$ este norma ℓ_1 aplicata elementelor extra-diagonale (diagonala nu este penalizata).

5.2.1 Interpretarea termenilor

Termenul $\log\det(\Theta) - \mathrm{tr}(\hat{S}\,\Theta)$ reprezinta log-verosimilitatea gaussiana (pana la o constanta) in functie de Θ. Maximizarea sa fara penalizare ar produce $\hat{\Theta} = \hat{S}^{-1}$, adica inversa empirica. Termenul de penalizare $-\rho\|\Theta\|_1$ forteaza elementele extra-diagonale mici spre zero, producand o matrice rara (Friedman et al., 2008).

5.2.2 Convexitate si existenta solutiei

Propozitie 5.1. *Problema de optimizare* (5.1) *este strict concava in* $\Theta \succ 0$ *si admite o solutie unica* $\hat{\Theta}$.

Demonstraţie. Functia obiectiv este suma a doua componente: $\log\det(\Theta)$, strict concava pe conul pozitiv definit, si $-\mathrm{tr}(\hat{S}\,\Theta) - \rho\|\Theta\|_1$, concava. Prin urmare, functia obiectiv este strict concava pe domeniul $\Theta \succ 0$, ceea ce implica unicitatea solutiei optime. □

5.2.3 Algoritm de rezolvare

Problema (5.1) este rezolvata prin algoritmul de coordonate-ciclice propus de (Friedman et al., 2008). Ideea este de a optimiza alternant in fiecare coloana/linie a lui Θ, mentinand celelalte fixe. Fiecare subproblema se reduce la un lasso standard, rezolvabila eficient. Convergenta algoritmului la solutia globala este garantata de convexitatea problemei.

In R, metoda este implementata prin functia `glasso()` din pachetul `glasso` (Friedman et al., 2019), apelata in scriptul `01_var_glasso_network.R`.

5.3 Selectia parametrului de regularizare

Parametrul ρ controleaza fundamental rezultatul:

- $\rho \to 0$: $\hat{\Theta} \to \hat{S}^{-1}$, graf complet.

- $\rho \to \infty$: $\hat{\Theta} \to \mathrm{diag}(\hat{S})^{-1}$, graf fara nicio muchie.

Alegerea valorii optime $\hat{\rho}$ este realizata in scriptul `03_glasso_selection.R` prin doua criterii complementare.

5.3.1 Criteriul BIC pentru graphical models

Criteriul BIC adaptat pentru modele grafice gaussiene (Yuan and Lin, 2007) este:

$$\mathrm{BIC}(\rho) = -T\Big[\log\det(\hat{\Theta}_\rho) - \mathrm{tr}(\hat{S}\,\hat{\Theta}_\rho)\Big] + \ln(T)\cdot|\hat{E}_\rho|, \tag{5.2}$$

unde $|\hat{E}_\rho|$ este numarul de elemente extra-diagonale nenule ale lui $\hat{\Theta}_\rho$ (numarul de muchii estimate). Valoarea optima este:

$$\hat{\rho} = \arg\min_{\rho>0} \mathrm{BIC}(\rho).$$

5.3.2 Analiza pe grila de valori

Selectia este realizata pe o grila logaritmica de valori $\rho \in \{0.001, 0.002, \ldots, 0.5\}$. Pentru fiecare valoare, se estimeaza $\hat{\Theta}_\rho$ si se calculeaza $\mathrm{BIC}(\rho)$ si densitatea retelei:

$$\mathrm{densitate}(\rho) = \frac{|\hat{E}_\rho|}{n(n-1)/2}.$$

Compromisul dintre fidelitatea fata de date si parsimonia modelului este esential: o retea excesiv de densa este greu de interpretat, iar una excesiv de rara poate pierde relatii relevante.

5.4 Proprietati statistice ale estimatorului GLasso

Propozitie 5.2 (Consistenta, (Ravikumar et al., 2011))**.** *Sub conditii de regularitate asupra structurii reale a lui Θ^* si cu $\rho \sim \sqrt{\ln n/T}$, estimatorul GLasso satisface:*

$$\|\hat{\Theta}_\rho - \Theta^*\|_F = O_P\left(\sqrt{\frac{n\ln n}{T}}\right),$$

si recupereaza structura corecta a grafului cu probabilitate care tinde la 1.

Aceasta proprietate garanteaza ca, pentru un numar suficient de mare de observatii, structura retelei estimate converge la structura adevarata a dependentelor conditionale.

5.5 De la matricea de precizie la retea

Odata estimata $\hat{\Theta}$, reteaua financiara este definita astfel:

- **Noduri**: $V = \{1, \ldots, 11\}$, corespunzand celor 11 sectoare.
- **Muchii**: $\{i, j\} \in E \iff \hat{\theta}_{ij} \neq 0$ si $i \neq j$.
- **Ponderi**: $w_{ij} = |\hat{\theta}_{ij}|$, reprezentand intensitatea dependentei conditionale.

Prin constructie, aceasta retea nu reflecta corelatii brute, ci dependente conditionale: o muchie intre sectoarele i si j indica o legatura directa care persista dupa controlul pentru toate celelalte sectoare. Aceasta proprietate este cea care face reteaua informativa din punct de vedere economic (Lauritzen, 1996; Friedman et al., 2008).

5.6 Legatura cu implementarea empirica

In analiza principala si in analiza pe ferestre temporale se foloseste aceeasi valoare a penalizarii, pentru a pastra comparabilitatea intre rezultatele obtinute. Astfel, modificarile observate in structura retelei de la o fereastra la alta pot fi atribuite mai usor schimbarilor din date si nu unei modificari a parametrului de regularizare.

Aceasta decizie metodologica este importanta in special in capitolul dedicat ferestrelor temporale, unde interesul principal este compararea topologiei retelei in timp, nu recalibrarea separata a modelului pentru fiecare subesantion.

Capitolul 6

Analiza retelei financiare

Dupa estimarea matricei de precizie prin graphical lasso, urmatorul pas este constructia si analiza retelei financiare asociate. In aceasta reprezentare, fiecare nod corespunde unui sector, iar o muchie intre doua noduri semnifica prezenta unei dependente conditionale directe. Aceasta transformare dintr-un obiect matricial intr-un graf permite o analiza structurala bogata, imposibila prin simpla inspectie a matricei numerice.

6.1 Constructia retelei

Reteaua financiara este construita in scriptul `01_var_glasso_network.R` utilizand pachetul `igraph` (Csardi and Nepusz, 2006). Procedura este urmatoarea:

1. Se extrag indicii (i, j) cu $\hat{\theta}_{ij} \neq 0$ si $i < j$ (pentru a evita dublarea muchiilor, deoarece $\hat{\Theta}$ este simetrica).
2. Se construieste graful neorientat ponderat $G = (V, E, w)$ cu $w_{ij} = |\hat{\theta}_{ij}|$.
3. Rezultatele sunt exportate in fisierele `edges.csv` si `top10_edges.csv` pentru analiza si prezentare.

6.2 Proprietati globale ale grafului

6.2.1 Densitatea retelei

Densitatea masoara fractia de muchii existente din totalul posibil (Newman, 2010):

$$d(G) = \frac{|E|}{n(n-1)/2}, \tag{6.1}$$

unde $n(n-1)/2 = 55$ este numarul maxim de muchii pentru $n = 11$ noduri. Densitatea reflecta compromisul realizat prin selectia parametrului ρ: un graf cu densitate moderata este preferabil unuia complet sau gol.

6.2.2 Componenta conexa

Un aspect important al retelei este daca toti nodurile sunt conectati intr-o singura componenta sau exista sectoare izolate. Existenta unei singure componente conexe indica ca toate sectorele sunt conectate, direct sau indirect, prin lantul de dependente conditionale. Aceasta proprietate este relevanta pentru analiza propagarii socurilor (Newman, 2010)..

6.2.3 Diametrul grafului

Diametrul $\mathrm{diam}(G)$ este lungimea celui mai lung drum minim (drum geodezic) din graf (Newman, 2010):

$$\mathrm{diam}(G) = \max_{i,j \in V} d(i, j),$$

unde $d(i, j)$ este distanta geodezica (numarul minim de muchii) intre i si j. Un diametru mic indica o retea in care informatia se propaga rapid intre orice doi participanti.

6.3 Masuri de centralitate

Masurile de centralitate cuantifica importanta fiecarui nod in structura retelei si sunt calculate in scriptul `05_centrality_measures.R`. Rezultatele sunt exportate in fisierul `centrality.csv`.

6.3.1 Degree centrality

Degree-ul unui nod este numarul de muchii incidente (Newman, 2010):

$$\deg(i) = |\mathcal{N}(i)| = |\{j : \{i, j\} \in E\}|. \tag{6.2}$$

In contextul retelei financiare, un sector cu degree ridicat este conectat direct cu multi alti sectori. Aceasta pozitie ii confera o influenta mai mare in sistem si un potential mai mare de a propaga sau absorbi socuri.

6.3.2 Strength (gradul ponderat)

Strength ia in considerare si intensitatea conexiunilor (Newman, 2010):

$$s_i = \sum_{j \in \mathcal{N}(i)} |\hat{\theta}_{ij}|. \tag{6.3}$$

Un sector cu strength ridicat nu doar ca are multi vecini, dar dependentele conditionale cu acestia sunt si puternice. Strength este o masura mai informativa decat degree-ul simplu in contextul retelelor ponderate.

6.3.3 Betweenness centrality

Betweenness centrality masoara importanta unui nod ca intermediar structural (Freeman, 1977):

$$C_B(i) = \sum_{\substack{s,t \in V \\ s \neq i \neq t}} \frac{\sigma(s,t \mid i)}{\sigma(s,t)}, \tag{6.4}$$

unde $\sigma(s,t)$ este numarul de drumuri geodezice de la s la t, iar $\sigma(s,t \mid i)$ este numarul celor care trec prin i.

Un sector cu betweenness ridicat controleaza fluxul de informatie intre parti diferite ale retelei. Eliminarea unui astfel de nod ar fragmenta reteaua si ar perturba semnificativ conectivitatea sistemului. Din perspectiva riscului sistemic, sectoarele cu betweenness ridicat sunt deosebit de importante.

6.3.4 Eigenvector centrality

Eigenvector centrality tine cont nu doar de numarul conexiunilor unui nod, ci si de importanta vecinilor sai (Bonacich, 1987). Fie $W \in \mathbb{R}^{n \times n}$ matricea de adiacenta ponderata a grafului. Eigenvector centrality satisface:

$$\lambda_{\max} x_i = \sum_{j=1}^{n} W_{ij} x_j, \tag{6.5}$$

unde $\lambda_{\max}$ este valoarea proprie dominanta a lui W (Perron-Frobenius). Un sector conectat la sectoare importante capata un scor ridicat, chiar daca nu are neaparat multe conexiuni.

6.4 Interpretarea structurii grafului

6.4.1 Sectoare centrale vs. periferice

Combinarea celor patru masuri de centralitate permite clasificarea sectoarelor in mai multe categorii:

- **Noduri centrale (hub-uri)**: sectoare cu degree, strength si eigenvector centrality ridicate. Acestea sunt conectate direct cu mai multi participanti si la noduri importante.

- **Intermediari structurali**: sectoare cu betweenness ridicat care joaca rolul de punte intre parti diferite ale retelei.
- **Noduri periferice**: sectoare cu putine conexiuni slabe, care au un rol mai limitat in propagarea informatiei.

6.4.2 Diferenta fata de analiza de corelatie

Este important de subliniat ca reteaua bazata pe matricea de precizie difera fundamental de o retea bazata pe corelatii. In analiza de corelatie, doua sectoare cu corelatie ridicata ar fi conectate, chiar daca acea corelatie este mediata complet de un factor comun. In reteaua noastra, o muchie exista numai daca dependenta dintre doua sectoare persista dupa controlul pentru toate celelalte sectoare (Lauritzen, 1996; Friedman et al., 2008).

Aceasta proprietate poate fi ilustrata printr-un exemplu simplu: sectoarele XLK (tehnologie) si XLY (bunuri discretionare) pot parea corelate pentru ca ambele sunt sensibile la ciclul economic. Daca aceasta co-miscare este complet explicata de un al treilea sector (de exemplu, XLF - financiar), atunci in matricea de precizie $\hat{\theta}_{XLK,XLY}$ va fi zero si nu va exista o muchie directa intre ele.

6.4.3 Grupuri de sectoare

Chiar si fara o metoda formala de detectie a comunitatilor, structura vizuala a grafului poate sugera existenta unor grupuri de sectoare mai strans conectate. Din perspectiva economica, se poate anticipa o grupare naturala a unor sectoare in:

- *Sectoare ciclice*: XLK, XLF, XLY, XLI - sensibile la ciclul economic.
- *Sectoare defensive*: XLU, XLP, XLV - mai stabile in perioade de recesiune.
- *Sectoare cu caractere mixte*: XLE, XLB, XLRE, XLC.

Daca structura retelei reflecta aceasta clasificare, aceasta constituie o validare a metodologiei: reteaua recupereaza cunoasterea economica existenta printr-o procedura complet data-driven.

Capitolul 7

Rezultate

Acest capitol prezinta si interpreteaza rezultatele obtinute in urma aplicarii pipeline-ului metodologic descris in capitolele anterioare. Accentul este pus in primul rand pe semnificatia statistica a structurii estimate, din punct de vedere al metodelor matematice si statistice utilizate.

7.1 Rezultatele modelului VAR(1)

7.1.1 Selectia ordinului

Criteriul BIC a indicat un model VAR de ordin $\hat{p} = 1$ ca optim. Aceasta alegere este compatibila cu proprietatile frecvent observate ale randamentelor zilnice financiare, unde dependenta liniara pe termen scurt este in general relativ redusa. Din aceasta perspectiva, un lag de o zi poate fi suficient pentru a surprinde componenta dinamica liniara relevanta, mentinand in acelasi timp modelul parsimonios (Fama, 1970; Tsay, 2010; Lütkepohl, 2005).

7.1.2 Stabilitate si diagnostice

Verificarea stabilitatii modelului a confirmat ca toate valorile proprii ale matricei de coeficienti $\hat{A}_1$ au modul strict mai mic decat 1, deci modelul este stabil. Testul Portmanteau nu a detectat autocorelare reziduala semnificativa pana la lag 10, validand specificatia VAR(1). Testul ARCH a detectat efecte de heteroscedasticitate conditionala, ceea ce este plauzibil in contextul seriilor financiare. Acest rezultat sugereaza prudenta in interpretarea inferentei clasice, dar nu invalideaza utilizarea modelului VAR ca etapa de filtrare a dependentei temporale liniare.

Din punct de vedere metodologic, aceste rezultate au importanta deoarece valideaza utilizarea reziduurilor VAR ca intrare pentru etapa de estimare a matricei de precizie. In absenta unei filtrari adecvate a dinamicii temporale, reteaua estimata ulterior ar combina efecte de dependenta contemporana cu efecte autoregresive, ceea ce ar reduce claritatea interpretarii statistice.

Figura 7.1: Diagnostice de stabilitate de tip OLS-CUSUM pentru ecuatiile modelului VAR(1).

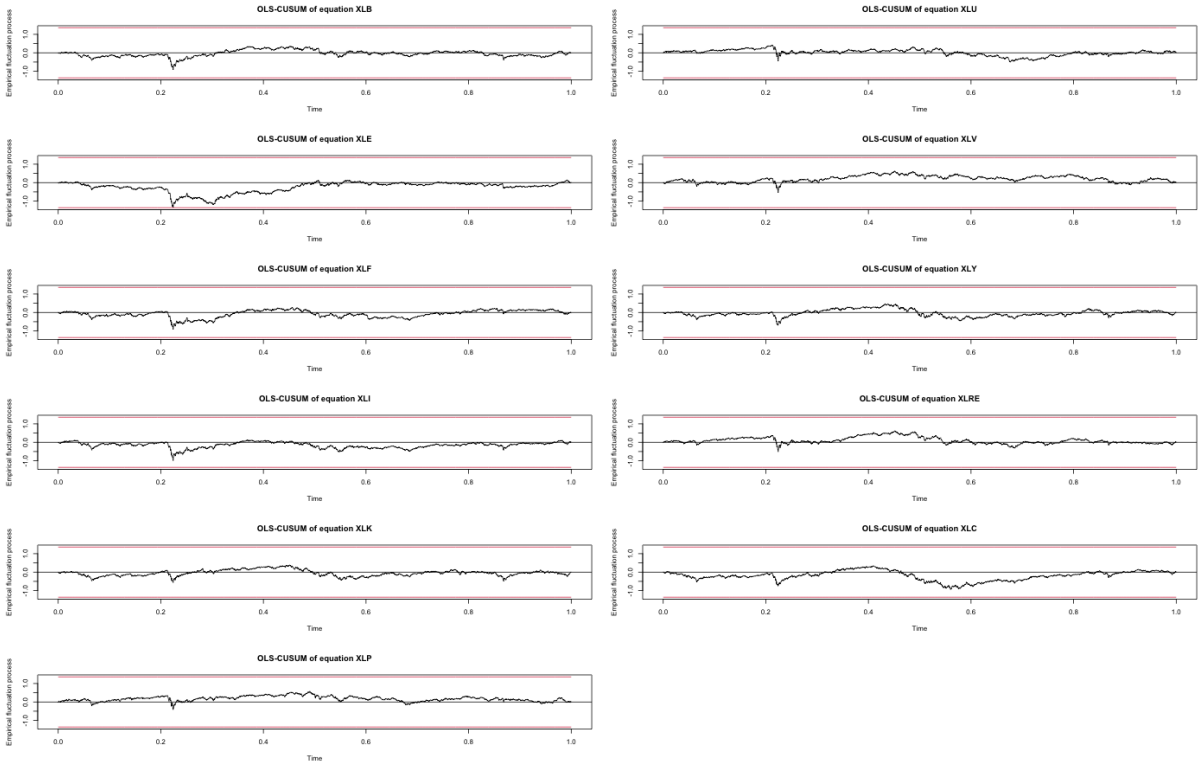

Sursa: figura generata prin scriptul `R/02_var_diagnostics.R`, fisierul `outputs/var_stability_cusum.png`.

Figura 7.1 sugereaza ca traiectoriile statisticilor OLS-CUSUM raman in interiorul limitelor critice pentru toate ecuatiile, ceea ce este compatibil cu ipoteza de stabilitate a specificatiei estimate pe intervalul analizat.

7.1.3 Matricea de covarianta a reziduurilor

Matricea $\hat{\Sigma} \in \mathbb{R}^{11\times 11}$ a reziduurilor VAR(1) descrie structura de co-variatie contemporana ramasa dupa filtrarea dependentei temporale liniare. Prezenta unor elemente extra-diagonale nenule arata ca, dincolo de dinamica pe lag-uri, sectoarele continua sa prezinte dependente simultane semnificative.

Din punct de vedere matematic, pozitivitatea definita a acestei matrici este esentiala, deoarece permite trecerea la etapa urmatoare de estimare a matricei de precizie. In plus, faptul ca inversarea numerica este stabila sustine fezabilitatea aplicarii metodei graphical lasso asupra acestei structuri empirice.

7.2 Rezultatele Graphical Lasso

Aplicarea metodei graphical lasso asupra matricei de covarianta a reziduurilor produce o matrice de precizie rara (Friedman et al., 2008), ceea ce permite trecerea de la o descriere matriciala la una grafica. Din punct de vedere statistic, acesta este unul dintre rezultatele centrale ale lucrarii: multe legaturi aparente dintre sectoare dispar atunci cand se conditioneaza pe intregul sistem.

Aceasta observatie arata ca simpla corelatie dintre randamente nu trebuie interpretata automat ca relatie directa. O parte dintre co-miscarile observate sunt efecte indirecte, mediate prin alte sectoare, iar metoda graphical lasso permite tocmai filtrarea acestor dependente indirecte.

7.2.1 Selectia parametrului de regularizare

Sensibilitatea metodei graphical lasso fata de parametrul de regularizare ρ a fost analizata pe o grila de valori, utilizand un criteriu de tip BIC si monitorizand densitatea retelei estimate. Aceasta analiza a avut rolul de a evidentia compromisul dintre fidelitatea fata de date si parsimonia structurii estimate.

Figura 7.2: Evolutia densitatii retelei in functie de parametrul de regularizare ρ.

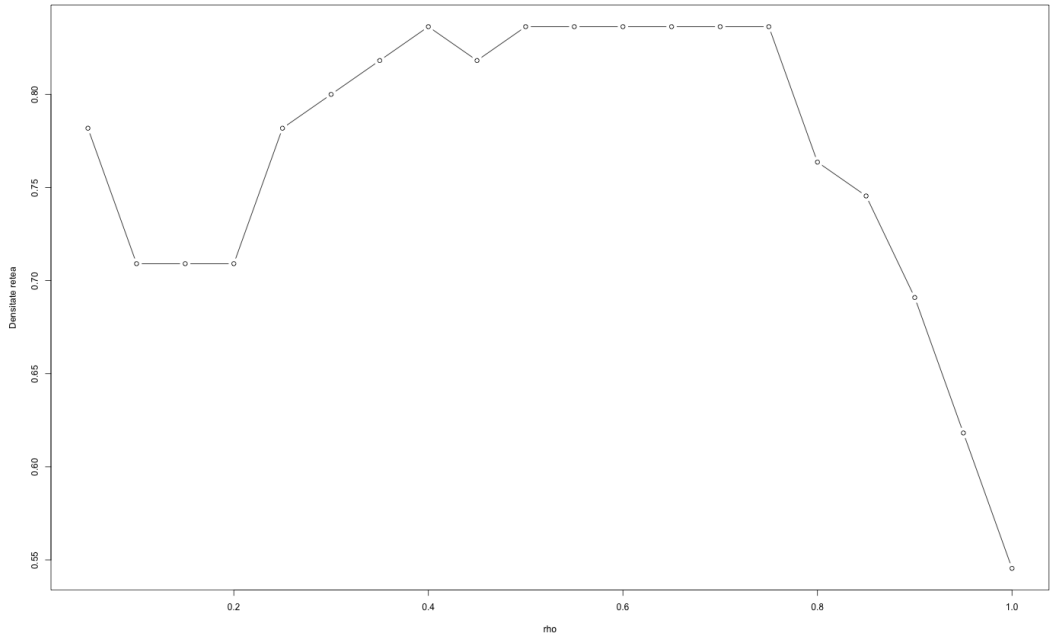

Sursa: figura generata prin scriptul `R/03_glasso_selection.R`, fisierul `outputs/glasso_density_curve.png`.

Figura 7.2 arata ca densitatea retelei scade pe masura ce penalizarea creste, ceea ce este in acord cu rolul lui ρ de a forta sparsitatea matricei de precizie estimate.

In analiza empirica principala este utilizata o valoare fixa a penalizarii, aleasa astfel incat reteaua rezultata sa ramana suficient de rara pentru a fi interpretabila. Din aceasta perspectiva, analiza pe grila nu este folosita doar ca procedura numerica, ci si ca instrument de justificare metodologica a nivelului de regularizare adoptat.

7.2.2 Sparsitatea matricei de precizie

Matricea de precizie estimata $\hat{\Theta}$ contine elemente extra-diagonale nule, spre deosebire de inversa empirica directa a matricei de covarianta, care tinde sa fie mult mai densa. Aceasta raritate structurala este rezultatul direct al penalizarii de tip ℓ_1 si reprezinta una dintre proprietatile centrale ale metodei graphical lasso.

Din punct de vedere statistic, zerourile din $\hat{\Theta}$ sunt importante deoarece indica absenta dependentei conditionale directe intre anumite perechi de sectoare, dupa controlul pentru toate celelalte variabile din sistem (Lauritzen, 1996; Friedman et al., 2008). Aceasta este diferenta esentiala fata de o analiza bazata doar pe corelatii perechi.

7.2.3 Interpretarea elementelor nenule

Elementele nenule ale lui $\hat{\Theta}$ pot fi impartite in doua categorii dupa semnul lor:

- $\hat{\theta}_{ij} < 0$: dependenta conditionala negativa - sectoarele tind sa se miste in directii opuse dupa controlul pentru celelalte sectoare. Acest tip de relatie poate indica efecte de substitutie sau competitie pentru capital intre sectoare.
- $\hat{\theta}_{ij} > 0$: dependenta conditionala pozitiva - sectoarele se misca impreuna dupa controlul pentru celelalte sectoare, sugerand expunere la factori comuni sau complementaritate economica.

7.3 Structura retelei financiare

7.3.1 Vizualizarea grafului

Reteaua financiara rezultata are $n = 11$ noduri si $|\hat{E}|$ muchii. Vizualizarea grafica din Figura 7.3 a fost produsa cu pachetul `igraph` (Csardi and Nepusz, 2006), folosind un layout circular stabil, adecvat pentru etichete lungi si pentru comparatia vizuala dintre sectoare.

Observatia vizuala principala este neuniformitatea structurii: anumite noduri au mai multe conexiuni si sunt plasate in centrul grafului, in timp ce altele sunt mai periferice. Aceasta neuniformitate este primul semn al existentei unor sectoare cu rol sistemic diferentiat.

Figura 7.3: Reteaua financiara estimata pe baza reziduurilor VAR si a metodei graphical lasso.

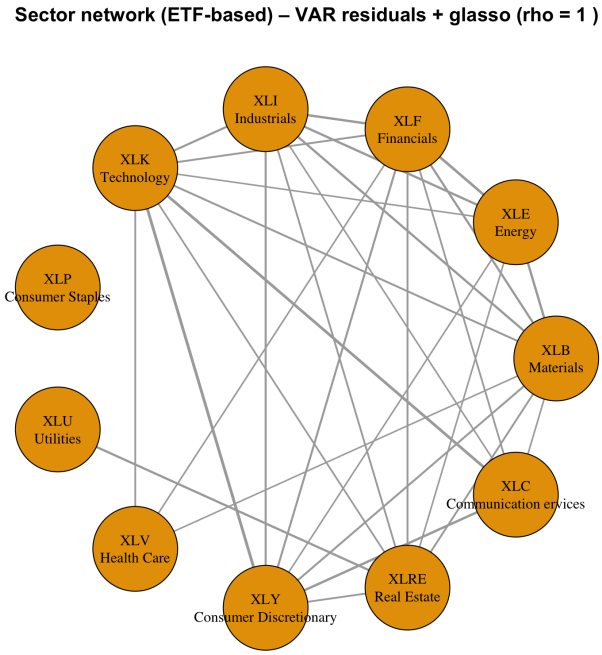

Sursa: figura generata prin scriptul `R/01_var_glasso_network.R`, fisierul `outputs/network.png`.

7.3.2 Cele mai importante muchii

Fisierul `top10_edges.csv` contine muchiile cu cea mai mare intensitate in valoare absoluta. Aceste legaturi sunt de interes special, deoarece ele corespund celor mai puternice dependente conditionale directe estimate in retea.

Din punct de vedere economic, este rezonabil ca printre aceste muchii sa apara legaturi intre sectoare cu expuneri apropiate la ciclul economic, la conditii de finantare sau la factori comuni de piata. Totusi, in aceasta lucrare accentul ramane pe interpretarea statistica a faptului ca doar un numar restrans de relatii directe domina structura estimata.

7.4 Masuri de centralitate: rezultate

7.4.1 Degree centrality

In reteaua partial-corr estimata pe intregul esantion, XLF (Financials) inregistreaza cel mai mare degree ($d = 9$), urmat de XLK (Technology), XLB (Materials) si XLRE (Real Estate), toate cu $d = 8$. La polul opus, XLU (Utilities) are $d = 2$, iar XLP (Consumer Staples) este izolat ($d = 0$), ceea ce indica absenta oricarei dependente conditionale directe cu celelalte sectoare

la nivelul de regularizare adoptat. Aceasta separare dintre sectoarele ciclice (XLF, XLK, XLI) si cele defensive (XLU, XLP, XLV) este consistenta cu literatura financiara care documenteaza roluri diferite in ciclul economic (Tsay, 2010).

7.4.2 Strength (grad ponderat)

La nivelul strength-ului (suma ponderilor absolute ale muchiilor), ordinea se modifica partial fata de degree. XLK urea pe primul loc (s = 0,746), urmat de XLF (s = 0,725) si XLY (Consumer Discretionary, s = 0,674). Faptul ca XLK depaseste XLF la strength, desi XLF are degree mai mare, indica ca legaturile XLK sunt, in medie, mai intense. XLV (Health Care) si XLU raman la coada ierarhiei ($s < 0{,}13$), sugerand nu doar putine conexiuni, ci si dependente conditionale de intensitate redusa.

7.4.3 Betweenness centrality

XLK ocupa primul loc si la betweenness, reflectand pozitia sa de intermediar central pe drumurile geodezice ale retelei. XLRE (Real Estate) se situeaza pe locul 2, un rezultat aparent contra-intuitiv, explicabil prin aceea ca XLRE functioneaza ca punte intre grupul sectoarelor ciclice si periferia retelei. Sectoarele cu betweenness nul (XLU, XLP, XLB, XLC) nu se afla pe niciun drum geodezic, deci socurile nu tranziteaza prin ele catre alte sectoare.

7.4.4 Eigenvector centrality

Eigenvector centrality confirma dominanta XLK (rangul 1), urmata de XLF (rangul 2) si XLY (rangul 3). Aceasta metrica recompenseaza conexiunile cu noduri deja centrale, consolidand imaginea unui nucleu format din sectoarele ciclice majore. XLU si XLV au valori de eigenvector centrality aproape de zero, ceea ce le plaseaza in afara acestui nucleu.

7.5 Ranking sectorial: reteaua partial-corr

Figura 7.4 sintetizeaza intr-un singur heatmap rangurile obtinute de fiecare sector pe toate cele cinci dimensiuni de centralitate. Culoarea mai inchisa corespunde unui rang mai bun (mai mic), iar valorile numerice din celule permit citirea directa a pozitiei fiecarui sector.

Figura 7.4: Ranking sectorial pe baza masurilor de centralitate ale retelei partial-corr (eșantion complet, 2018–2026).

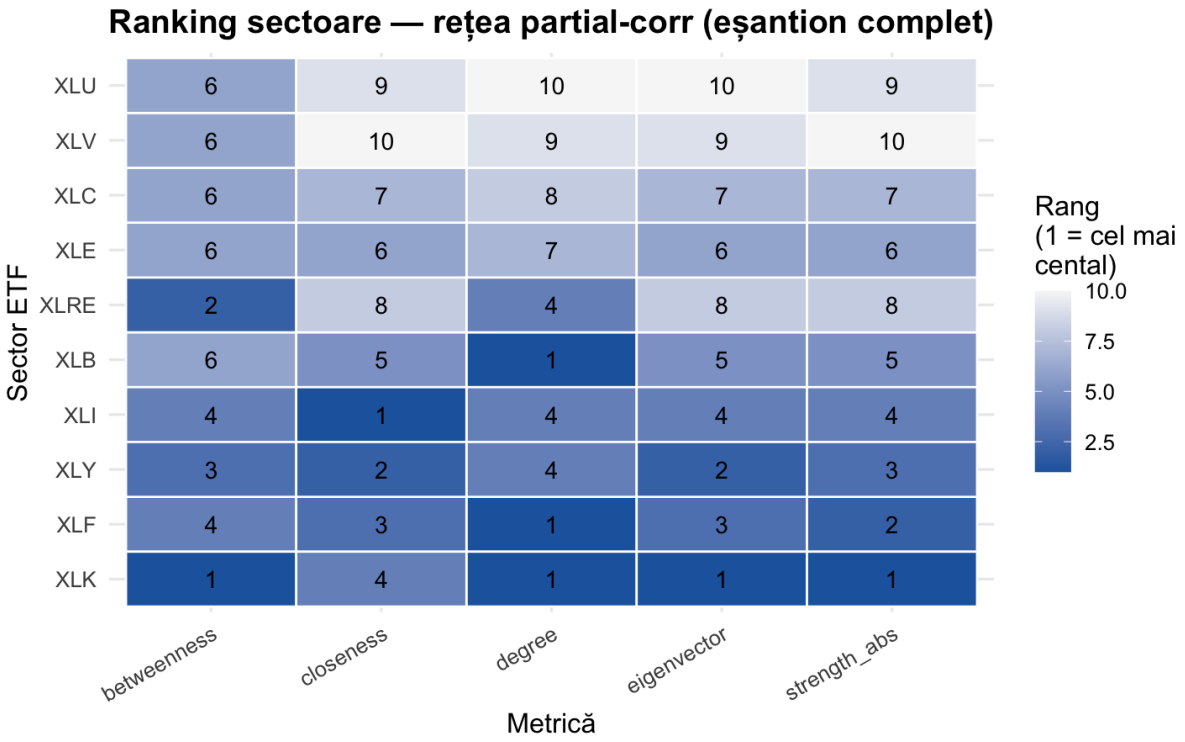

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

Heatmap-ul evidentiaza trei clustere distincte. Primul este nucleul central format din XLK si XLF, care ocupa pozitii de top pe aproape toate dimensiunile: XLK conduce pe betweenness, eigenvector si strength, in timp ce XLF detine primul loc la degree. Al doilea grup de sectoare cu centralitate medie include XLY, XLI si XLB, cu ranguri intre 2 si 5 pe cele mai multe metrici. Al treilea grup periferic cuprinde XLU, XLV si XLC, cu ranguri consistente de 7–10. Aceasta stratificare reflecta clivajul clasic dintre sectoare ciclice (cu rol central in reteaua de dependente conditionale) si sectoare defensive sau specifice (cu pozitie periferica).

7.6 Ranking sectorial: reteaua Granger

In reteaua Granger, interpretarea rangurilor difera structural fata de reteaua partial-corr, deoarece muchiile sunt directionate si captureaza cauzalitate predictiva, nu co-miscare contemporana. Figura 7.5 prezinta ranking-urile pentru cele patru metrici relevante.

Figura 7.5: Ranking sectorial pe baza masurilor de centralitate ale retelei Granger (eșantion complet, 2018–2026).

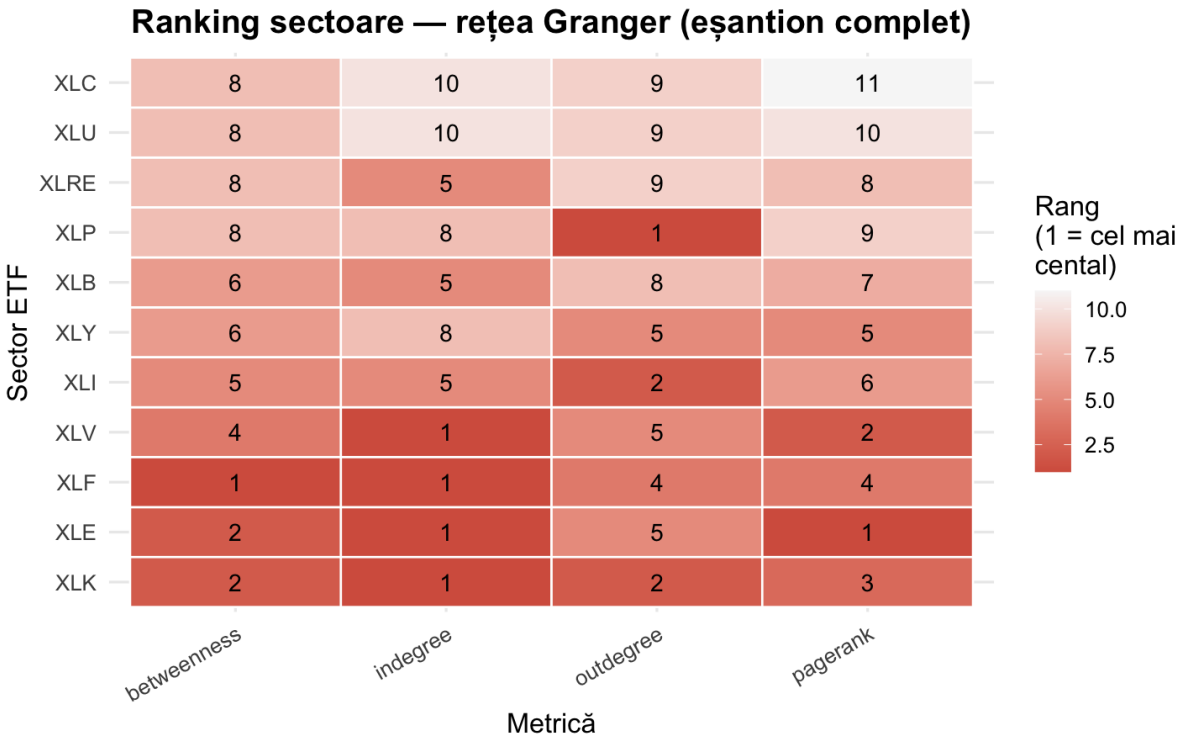

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

Primul loc la PageRank ii revine XLE (Energy, PR = 0,163), urmat de XLV (Health Care, PR = 0,158) si XLK (PR = 0,120). PageRank-ul ridicat al XLE reflecta faptul ca este tinta unor fluxuri de cauzalitate Granger provenite de la sectoare ele insele importante: pretul energiei este determinat de conditii macroeconomice largi, inregistrate de sectoarele ciclice, si nu de factori sectoriali izolati. XLF (Financials), cu rang egal 1 la in-degree, out-degree si betweenness, este cel mai activ intermediar directional: transmite semnale catre opt sectoare si le receptioneaza de la cinci. Un rezultat notabil este XLP (Consumer Staples) cu out-degree rang 1 (impartit cu XLF si XLI), ceea ce sugereaza ca miscarile din sectorul bunurilor de consum de baza contin informatii predictive pentru un numar ridicat de alte sectoare, in ciuda caracterului sau defensiv. La polul opus, XLU (Utilities) nu Granger-cauzeaza niciun alt sector (out-degree = 0) si are PageRank minim, confirmand rolul sau de nod terminal in reteaua de cauzalitate predictiva.

7.7 Interpretare statistica a rezultatelor

Din punct de vedere statistic, rezultatele sustin trei concluzii principale:

1. **Dependenta conditionala este rara**: nu toate sectoarele sunt dependente conditional intre ele. Multe din corelatiile observate direct intre randamente sunt mediate de al treilea sector

si dispar cand se conditioneaza pe intregul sistem.

2. **Structura este neuniforma**: distributia centralitatii intre sectoare este asimetrica, cu cateva sectoare dominante si mai multe periferice. Aceasta heterogenitate are implicatii directe pentru analiza riscului sistemic.

3. **Metodologia produce rezultate interpretabile**: reteaua recupereaza clasificari economice cunoscute (ciclice vs. defensive) printr-o procedura data-driven, sustinand indirect adecvarea metodologica a abordarii utilizate.

Aceste rezultate nu trebuie interpretate ca relatii cauzale, ci ca structuri de dependenta conditionala estimate pe perioada analizata. Robustetea lor la schimbari de metoda sau de esantion este discutata in capitolele urmatoare.

Capitolul 8

Analiza pe ferestre temporale

Analiza prezentata in capitolele anterioare estimeaza o singura retea financiara folosind toate observatiile disponibile. Aceasta abordare *statica* are avantajul utilizarii eficiente a datelor, dar ascunde potential modificarile structurale ale pietei de-a lungul timpului. Piata financiara americana a traversat in esantionul analizat mai multe faze distincte, caracterizate prin niveluri diferite de volatilitate si grade diferite de interconectare sectoriale.

In acest capitol este prezentata o extensie *dinamica* a analizei, bazata pe ferestre temporale rulante. Aceasta permite investigarea stabilitatii structurii retelei si identificarea perioadelor in care dependentele conditionale se modifica semnificativ.

8.1 Metodologia ferestrelor temporale

8.1.1 Definitia ferestrei rulante

Fie w dimensiunea ferestrei (in zile tranzactionate) si s pasul de deplasare. Definim o succesiune de subperioade:

$$\mathcal{I}_k = \{t_k, t_k + 1, \ldots, t_k + w - 1\}, \quad k = 1, 2, \ldots, K, \tag{8.1}$$

unde $t_k = t_1 + (k - 1) \cdot s$, iar $K = \lfloor (T - w)/s \rfloor + 1$ este numarul total de ferestre. Pentru fiecare fereastra $\mathcal{I}_k$ se repeta intreaga procedura:

1. Se estimeaza un model VAR(1) pe observatiile din $\mathcal{I}_k$.
2. Se calculeaza matricea de covarianta $\hat{\Sigma}^{(k)}$ a reziduurilor.
3. Se estimeaza matricea de precizie $\hat{\Theta}^{(k)}$ prin GLasso, folosind aceeasi valoare a parametrului de regularizare ca in analiza principala, pentru a pastra comparabilitatea intre ferestre.
4. Se construieste reteaua $G^{(k)} = (V, E^{(k)}, w^{(k)})$.
5. Se calculeaza indicatori de centralitate, cu accent pe *strength_abs*.

Aceasta procedura este implementata in scripturile `06_time_window_network.R` si `08_sector_rankings.R`, unde ultima extinde analiza cu metrici suplimentare (betweenness, eigenvector centrality) si cu reteaua Granger estimata dinamic.

8.1.2 Alegerea dimensiunii ferestrei

Alegerea lui w presupune un compromis fundamental:

- *Ferestre mici* (de exemplu, $w = 120$ zile ≈ 6 luni): permit surprinderea schimbarilor rapide ale structurii pietei, dar reduc numarul de observatii disponibile per fereastra, crescand incertitudinea estimatiei.
- *Ferestre mari* (de exemplu, $w = 500$ zile ≈ 2 ani): ofera estimatii mai stabile, dar pot obscura schimbarile structurale rapide.

In proiect, fereastra a fost aleasa astfel incat sa mentina un raport $w/n \gg 1$ (unde $n = 11$ este numarul de sectoare), conditie necesara pentru estimarea stabila a modelului VAR si a matricei de covarianta.

8.2 Indicatori dinamici ai retelei

8.2.1 Evolutia strength-ului sectorial (reteaua partial-corr)

Figura 8.1 prezinta evolutia in timp a strength-ului pentru fiecare sector, calculat in fiecare fereastra rulanta. Liniile verticale punctate marcheaza trei evenimente de referinta: criza COVID (martie 2020), invazia Ucrainei (februarie 2022) si criza bancara americana (martie 2023).

Figura 8.1: Evolutia strength-ului sectorial (reteaua partial-corr) pe ferestre rulante de 252 de zile tranzactionate (pas lunar).

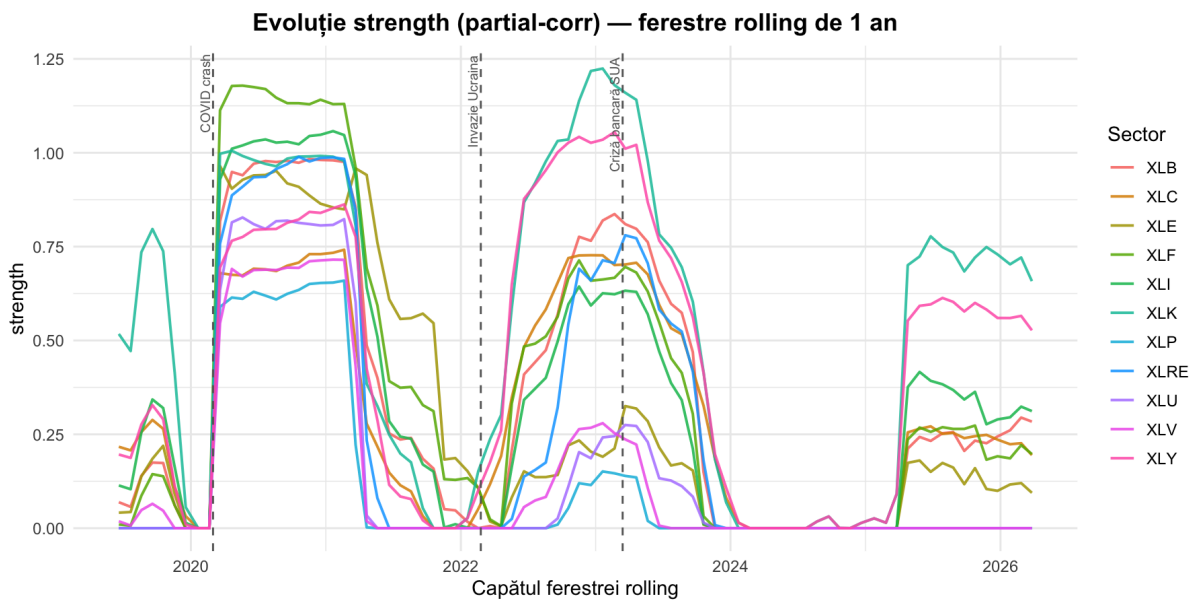

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

Doua caracteristici structurale sunt vizibile in grafic. In primul rand, exista o crestere brusca a strength-ului pentru toate sectoarele in fereastra care cuprinde criza COVID (capatul ferestrei in jurul lunii martie 2020). Aceasta semnaleaza o crestere a intensitatii dependentelor conditionale in perioadele de stres, fenomen documentat in literatura ca *correlation breakdown* (Longin and Solnik, 2001; Ang and Chen, 2002). In al doilea rand, XLK (Technology) are cel mai ridicat strength in perioada pre-COVID, dar este devansat de XLF (Financials) in perioada acuta a crizei, sugerand ca sectorul financiar devine nodul cu cele mai intense dependente conditionale in momentele de presiune sistemica.

8.2.2 Evolutia PageRank-ului sectorial (reteaua Granger)

Figura 8.2 prezinta evolutia PageRank-ului in reteaua Granger estimata pe ferestre rulante. Spre deosebire de strength (care masoara co-miscarea contemporana), PageRank-ul Granger captureaza importanta in transmiterea predictiva a informatiei.

Figura 8.2: Evolutia PageRank sectorial (reteaua Granger) pe ferestre rulante de 252 de zile tranzactionate (pas lunar).

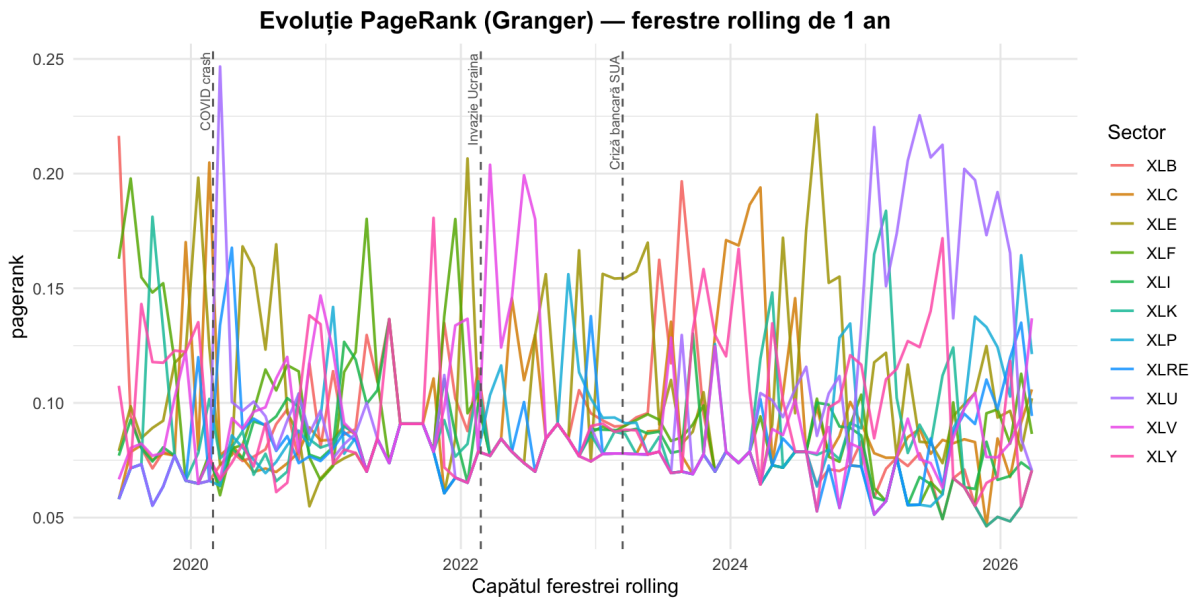

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

Reteaua Granger prezinta o volatilitate mai ridicata a rangurilor comparativ cu reteaua partial-corr. Aceasta este asteptata, deoarece relatiile de cauzalitate predictiva sunt mai fragile temporal decat co-miscarile contemporane. In jurul crizei COVID, XLF si XLV (Health Care) isi mentin pozitii de top la PageRank, sugerand ca aceste sectoare raman cele mai predictibile din perspectiva macroeconoimca si in perioade de turbulenta. Dupa 2022, profilul PageRank se modifica: XLU (Utilities) si XLP (Consumer Staples) dobandesc o importanta crescuta, in concordanta cu rotatia catre sectoare defensive observata pe pietele de capital in contextul ciclului monetar restrictiv.

8.2.3 Evolutia out-degree-ului (reteaua Granger)

Figura 8.3 prezinta evolutia out-degree-ului, metrica care cuantifica numarul de sectoare catre care un nod transmite cauzalitate Granger semnificativa. Un out-degree ridicat indica un sector care contine informatii predictive utile pentru un numar mare de alti participanti ai pietei.

Figura 8.3: Evolutia out-degree sectorial (reteaua Granger) pe ferestre rulante de 252 de zile tranzactionate (pas lunar).

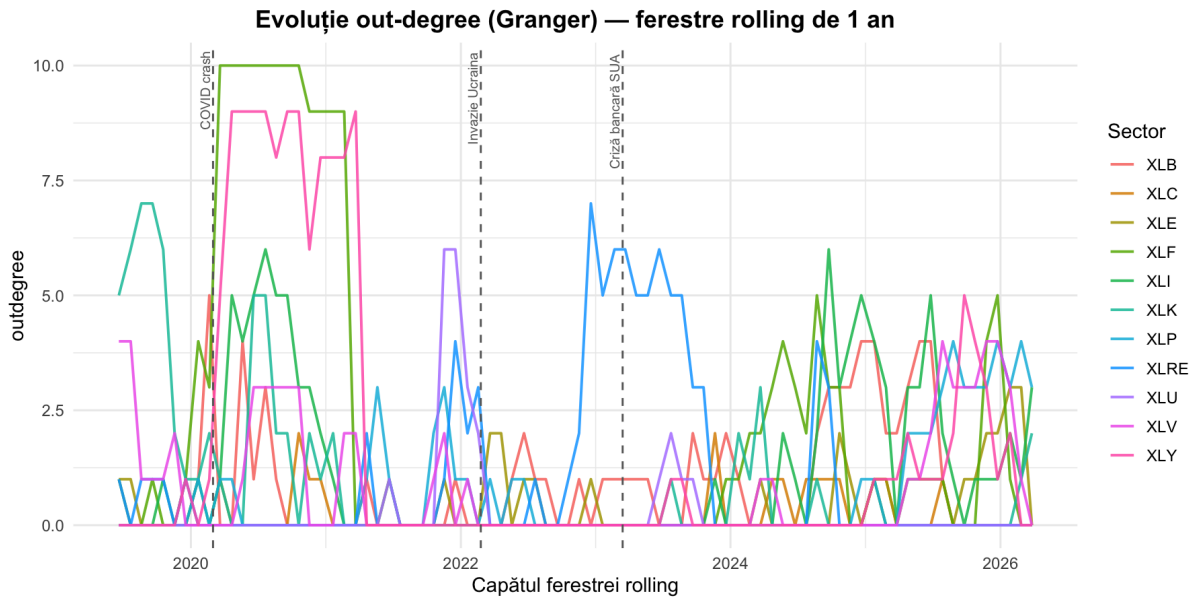

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

Out-degree-ul prezinta varfuri clare in fereastra COVID, unde XLF si XLI (Industrials) inregistreaza valorile maxime, reflectand cresterea temporara a puterii predictive a sectoarelor ciclice in conditii de instabilitate macroeconomica. Acest comportament este consistent cu ipoteza ca in perioade de stres, dinamica sectorului financiar si a celui industrial contine informatii relevante despre directia generala a economiei (Diebold and Yilmaz, 2014).

8.3 Analiza pe sub-esantioane

8.3.1 Motivatie si definirea perioadelor

Analiza pe intregul esantion furnizeaza o imagine agregata care poate obscura modificarile structurale asociate unor regimuri economice distincte. In consecinta, in aceasta sectiune reteaua este re-estimata complet pe trei sub-esantioane definite pe criterii economice:

- **Pre-COVID** (iunie 2018 – decembrie 2019, $T = 386$ observatii): perioada de expansiune

economica relativ stabila, caracterizata prin volatilitate redusa si randamente pozitive in sectoarele ciclice.

- **COVID** (ianuarie 2020 – decembrie 2021, $T = 505$ observatii): perioada dominata de socul pandemic, de interventiile fiscale si monetare masive si de recuperarea ulterioara.
- **Post-COVID** (ianuarie 2022 – ianuarie 2026, $T = 1016$ observatii): perioada de normalizare macroeconomica, cu ciclu monetar restrictiv si rotatie sectoriala catre defensive.

Pentru fiecare sub-esantion, procedura completa (VAR(1), graphical lasso, testele Granger, calculul centralitatilor) este re-aplicata de la zero. Penalizarea ρ este mentinuta constanta la valoarea din analiza principala pentru a pastra comparabilitatea.

8.3.2 Reteaua partial-corr: stabilitatea ierarhiei

Figura 8.4 compara rangurile sectoriale dupa strength pe cele trei sub-esantioane.

Figura 8.4: Ranking dupa strength (reteaua partial-corr) pe sub-esantioane.

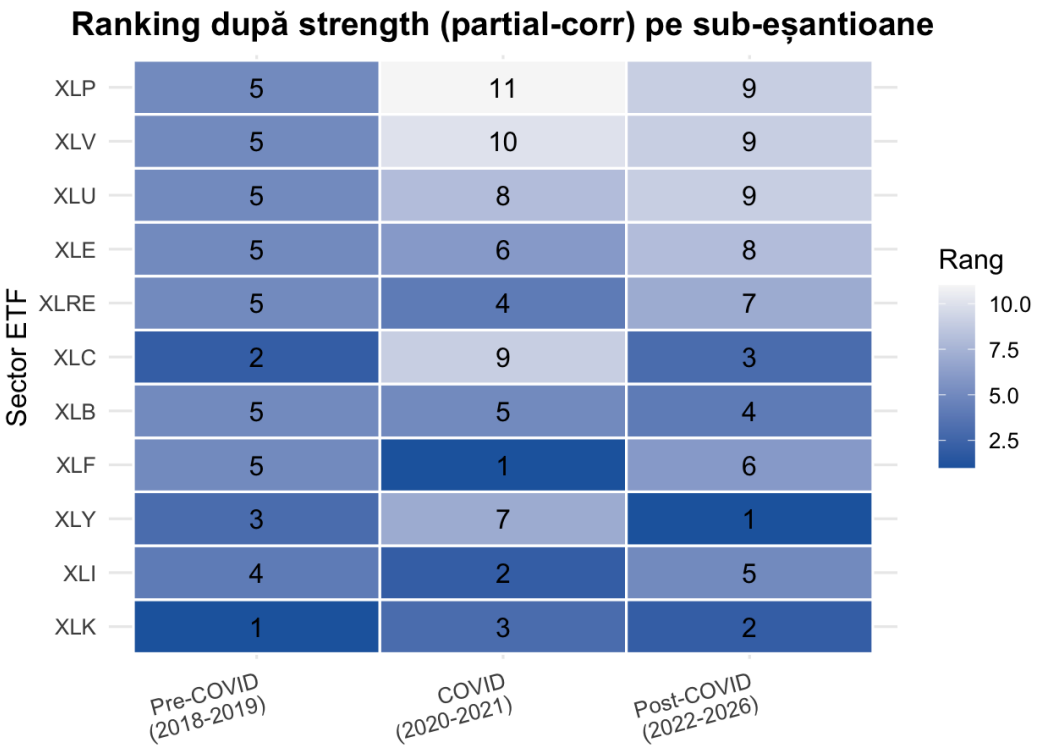

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

Rezultatele releva modificari substantiale intre perioade. In pre-COVID, XLK (Technology) ocupa primul loc, reflectand rolul sau central in bull market-ul alimentat de revolutia digitala, urmat de XLC (Communication Services, rang 2) si XLY (Consumer Discretionary, rang 3). In

perioada COVID, XLF (Financials) urca de la rangul 5 la rangul 1, iar XLI (Industrials) ocupa locul 2. Aceasta rotatie reflecta faptul ca, in criza, sectorul financiar devine punctul central al sistemului de dependente conditionale: incertitudinea privind bilanturile bancilor, politica Fed si conditiile de creditare se propaga simultan catre toate celelalte sectoare, generand un strength ridicat pentru XLF.

In perioada post-COVID, ierarhia se redistribuie din nou: XLY (Consumer Discretionary) devine sectorul cu cel mai ridicat strength, urmat de XLK (rang 2) si XLC (rang 3). Sectoarele defensive XLU, XLV si XLP isi mentin pozitia de coada de ierarhie pe tot parcursul celor trei perioade.

8.3.3 Reteaua Granger: rotatia ierarhiei predictive

Figura 8.5 compara rangurile sectoriale dupa PageRank in reteaua Granger pe cele trei sub-esantioane.

Figura 8.5: Ranking dupa PageRank (reteaua Granger) pe sub-esantioane.

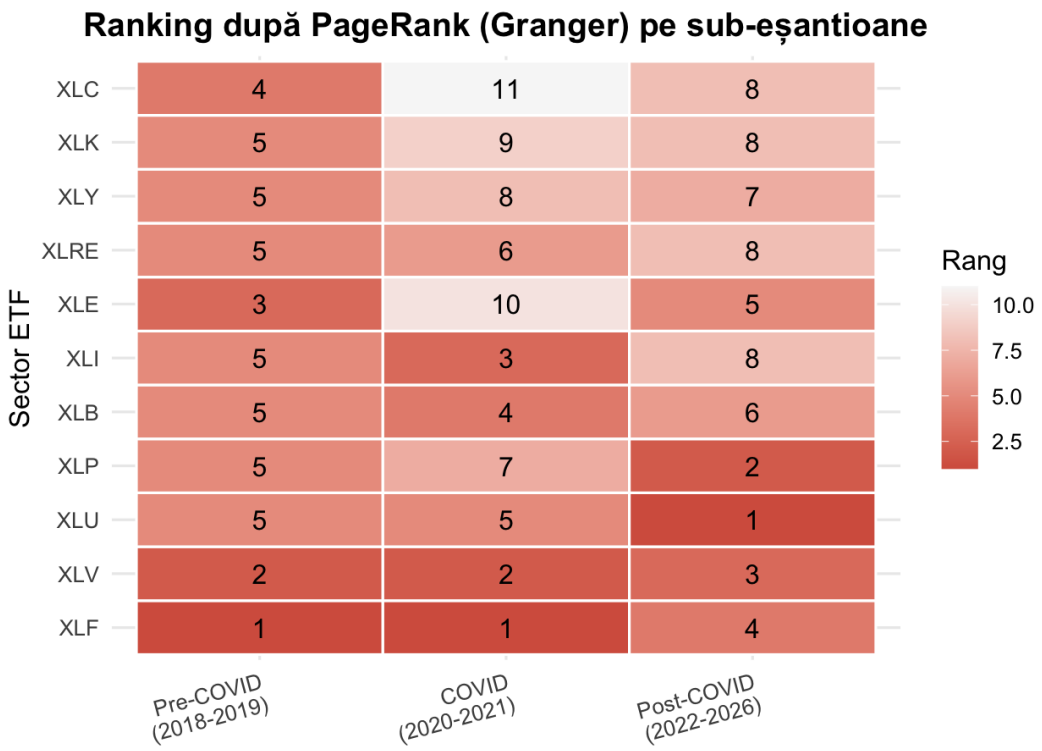

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

In pre-COVID si COVID, XLF si XLV detin constant primele doua locuri la PageRank, indicand ca sectorul financiar si cel de sanatate sunt consistent cele mai predictibile de catre restul pietei. Aceasta stabilitate este notabila: reteaua Granger, care este mai volatila decat cea partial-corr, mentine totusi aceleasi doua sectoare la varf in doua perioade consecutive cu dinamici macroeconomice complet diferite.

Schimbarea majora apare in post-COVID: XLU (Utilities) urea pe primul loc la PageRank (de la rangul 5 in ambele perioade anterioare), urmat de XLP (Consumer Staples, rang 2). Aceasta inversare a ierarhiei semnifica ca, in contextul unui ciclu de dobanzi ridicate, miscarile din sectoarele sensibile la rata dobanzii (utilitati, consum de baza) sunt cel mai puternic determinate de dinamica ansamblului pietei, captata prin cauzalitate Granger.

Figura 8.6 ofera perspectiva complementara din unghiul out-degree-ului, care identifica sectoarele cu putere predictiva maxima.

Figura 8.6: Ranking dupa out-degree (reteaua Granger) pe sub-esantioane.

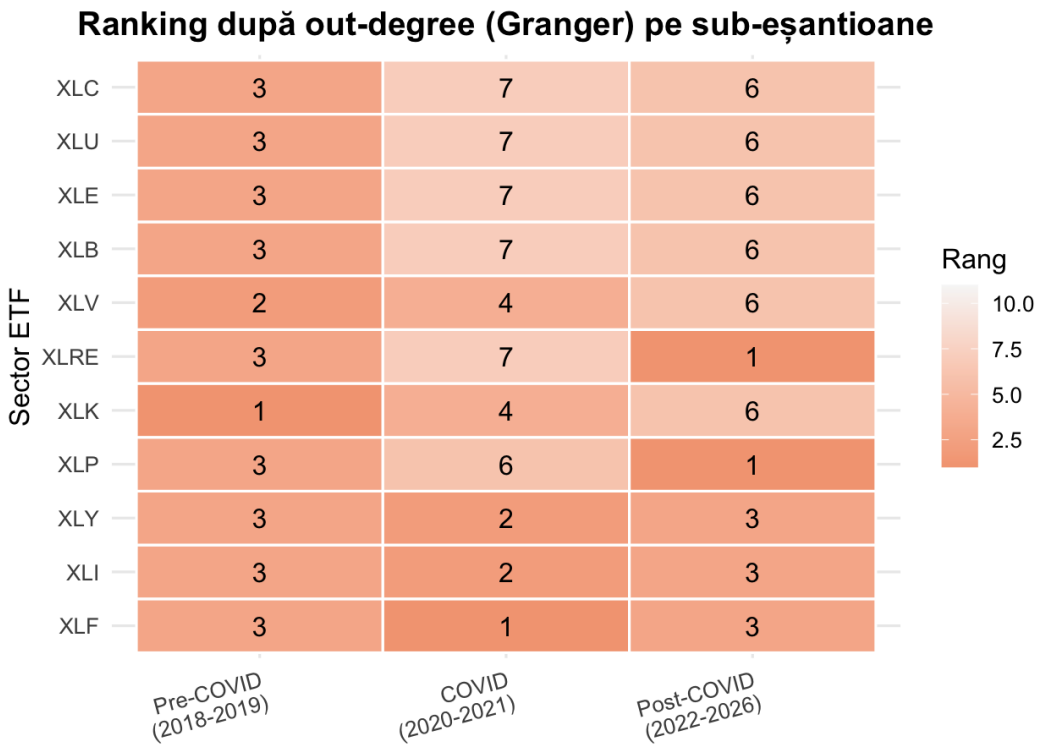

Sursa: figura generata prin scriptul `R/08_sector_rankings.R`.

In pre-COVID, XLK (Technology) are cel mai mare out-degree (rang 1), iar in COVID liderul devine XLF (rang 1 alaturi de XLI). In post-COVID, XLRE (Real Estate) si XLP (Consumer Staples) preiau pozitia de top la out-degree, sugerand ca traiectoria acestor sectoare contine informatii predictive deosebit de utile pentru restul pietei in contextul normalizarii monetare.

8.4 Interpretarea dinamica a rezultatelor

Analiza pe ferestre temporale adauga o dimensiune esentiala interpretarii structurii retelei. Ea arata ca pozitiile centrale ale sectoarelor nu trebuie privite ca proprietati complet fixe ale pietei, ci ca rezultate care pot varia in timp.

Din punct de vedere statistic, aceasta observatie este importanta deoarece sugereaza ca reteaua estimata pe intregul esantion reprezinta o agregare a unor configuratii locale diferite. In consecinta, analiza dinamica nu contrazice rezultatele statice, ci le completeaza, indicand in ce masura structura dependentei conditionale ramane stabila sau se modifica intre subperioade.

8.5 Limitele analizei dinamice

Analiza pe ferestre temporale presupune ipoteza implicita ca structura retelei este constanta in interiorul fiecarei ferestre. Aceasta ipoteza poate fi nerealista in perioade de schimbari rapide. O extensie mai riguroasa ar fi utilizarea unor modele cu parametri variabili continuu in timp (TVP-VAR), care insa depasesc scopul acestei lucrari Diebold and Yilmaz (2014).

De asemenea, rezultatele analizei dinamice depind de alegerea lui w si s. Robustetea concluziilor ar trebui verificata pentru mai multe valori ale acestor parametri, ceea ce constituie o directie naturala de dezvoltare ulterioara.

In ciuda acestor limite, analiza pe ferestre temporale este valoroasa pentru ca transforma reteaua dintr-un obiect static intr-un obiect dinamic, mai fidel naturii evolutive a pietelor financiare.

In plus, comparabilitatea intre ferestre depinde de mentinerea unei proceduri de estimare coerente de la o fereastra la alta. Din acest motiv, utilizarea aceleiasi penalizari in toate ferestrele are un rol metodologic important, deoarece reduce variatia artificiala indusa de recalibrari diferite ale parametrului de regularizare.

Capitolul 9

Discutii si limite

Rezultatele obtinute in aceasta lucrare sustin utilitatea combinarii modelelor VAR cu metoda graphical lasso pentru analiza structurii pietelor financiare. Totusi, orice analiza empirica trebuie insotita de o evaluare critica a limitelor sale metodologice si a domeniului de validitate al concluziilor.

9.1 Avantajele metodologice ale abordarii

Inainte de a discuta limitele, este util sa sintetizam avantajele distincte ale metodologiei adoptate fata de alternativele mai simple.

9.1.1 Separarea dependentei temporale de cea contemporana

Un avantaj fundamental al abordarii VAR + GLasso fata de o simpla analiza de corelatie este separarea clara a doua tipuri distincte de dependenta:

- *Dependenta temporala*: efectele valorilor trecute ale unui sector asupra evolutiei viitoare a altui sector, capturate de matricea $\hat{A}_1$.
- *Dependenta contemporana*: co-miscare simultana a socurilor, capturata de $\hat{\Sigma}$ si interpretata structural prin $\hat{\Theta}$.

O analiza bazata direct pe corelatiile randamentelor amesteca aceste doua efecte, producand o imagine distorsionata a relatiilor structurale.

9.1.2 Identificarea dependentelor conditionale

Al doilea avantaj este trecerea de la masuri de asociere bruta la dependente conditionale. Matricea de precizie permite separarea legaturilor directe de cele mediate prin variabile intermediare. Aceasta proprietate este esentiala in contextele unde este importanta identificarea canalelor directe de propagare a socurilor, spre deosebire de co-miscarea generala cauzata de factori comuni.

9.1.3 Parsimonie si interpretabilitate

Penalizarea ℓ_1 produce o retea rara, in care sunt retinute doar relatiile cu semnificatie statistica substantiala. Aceasta parsimonie este un avantaj practic: reteaua rezultata poate fi vizualizata, interpretata si discutata, spre deosebire de o matrice densa de coeficienti.

9.2 Limitele analizei

9.2.1 Dimensiunea esantionului

Esantionul utilizat, desi suficient pentru ilustrarea metodologiei, ramane limitat din perspectiva formularii unor concluzii foarte generale despre structura de lunga durata a pietei. Rezultatele trebuie interpretate in raport cu perioada concreta analizata si cu conditiile economice caracteristice acesteia.

O extensie naturala ar fi utilizarea unui esantion mai lung, care sa includa mai multe cicluri economice complete si sa permita evaluarea mai robusta a stabilitatii concluziilor.

9.2.2 Linearitatea modelului VAR

Modelul VAR presupune relatii liniare intre variabile. In piata financiara pot aparea:

- *Relatii neliniare*: dependentele dintre sectoare pot fi mai intense in perioade de stres (efect de *tail dependence*).
- *Schimbari de regim*: structura dependentei poate fi diferita in perioade de expansiune fata de contractie.
- *Efecte ARCH/GARCH*: volatilitatea conditionata variabila in timp nu este modelata de VAR standard.

Extinderi posibile includ modele VAR cu prag (TVAR), modele cu schimbari de regim Markov sau modele VAR-GARCH.

9.2.3 Selectia activelor si agregarea

Utilizarea ETF-urilor sectoriale implica o agregare a informatiei: comportamentul unui ETF reflecta media ponderata a companiilor din sector, nu comportamentul individual. La nivelul companiilor individuale, structura dependentei ar putea fi mai complexa si mai fragmentata.

De asemenea, selectia celor 11 sectoare standard GICS, desi exhaustiva, nu captureaza distinctii mai fine (de exemplu, intre subsectoare din tehnologie: hardware vs. software vs. semiconductori).

9.2.4 Dependenta de parametrul de regularizare

Reteaua finala depinde de alegerea parametrului de regularizare ρ. Chiar daca analiza pe grila si criteriul de tip BIC ofera un suport metodologic pentru alegerea nivelului de penalizare, structura exacta a retelei poate varia atunci cand ρ este modificat.

Din acest motiv, robustetea rezultatelor fata de variatii rezonabile ale parametrului de regularizare reprezinta o preocupare metodologica legitima. Aceasta observatie nu slabeste concluziile lucrarii, dar subliniaza faptul ca reteaua estimata trebuie inteleasa ca rezultat al unei proceduri de regularizare, nu ca obiect complet independent de alegerea parametrilor.

9.2.5 Absenta cauzalitatii

Reteaua de dependente conditionale nu implica relatii cauzale in sens economic. Faptul ca doua sectoare sunt conectate printr-o muchie nu inseamna ca unul il determina pe celalalt. Pentru inferenta cauzala ar fi necesare instrumente econometrice suplimentare (variabile instrumentale, discontinuitati de regresie, teste de cauzalitate Granger structurala) Lütkepohl (2005).

Scriptul `04_granger_network.R` exploreaza tocmai aceasta directie, construind o retea de cauzalitate Granger complementara retelei de dependente conditionale. Compararea celor doua retele poate oferi informatii suplimentare despre directia influentelor intre sectoare.

Figura 9.1: Reteaua de cauzalitate Granger obtinuta pentru modelul VAR(1).

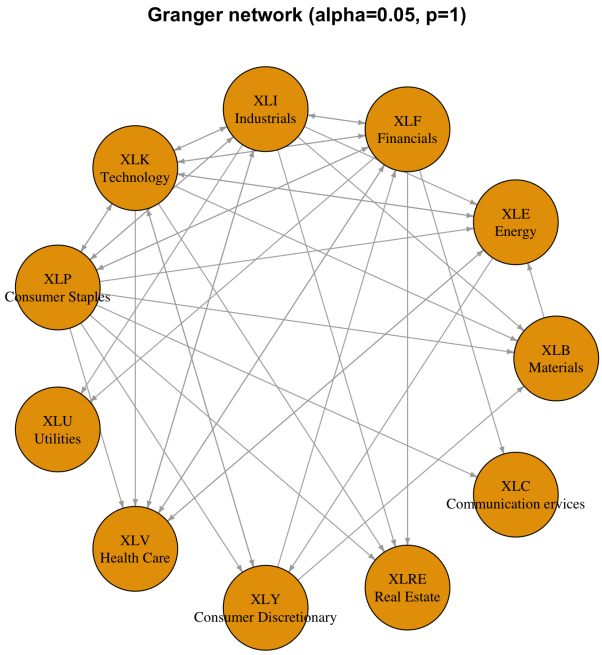

Sursa: figura generata prin scriptul `R/04_granger_network.R`, fisierul `outputs/granger_network.png`.

9.3 Directii de dezvoltare ulterioara

Pe baza limitelor identificate, pot fi propuse urmatoarele extensii:

1. **Extinderea esantionului**: includerea datelor de dinainte de 2018 pentru a acoperi cicluri economice mai complete.
2. **Modele cu volatilitate variabila**: combinarea VAR cu modele GARCH multivariat pentru a tine cont de heteroscedasticitate.
3. **Modele cu parametri variabili in timp (TVP-VAR)**: o alternativa mai riguroasa la analiza pe ferestre temporale Diebold and Yilmaz (2014).
4. **Compararea metodelor de estimare a retelei**: GLasso vs. CLIME vs. retele de corelatie partial, pentru a evalua robustetea structurii identificate.
5. **Analiza la nivel de companie**: coborarea de la ETF-uri sectoriale la actiuni individuale, pentru o granularitate mai mare.

Aceste directii nu diminueaza valoarea lucrarii de fata, ci sugereaza ca metodologia adoptata este suficient de flexibila pentru a fi extinsa si aprofundata in cercetari viitoare.

Capitolul 10

Concluzii

10.1 Sinteza metodologica

Lucrarea a avut ca obiectiv analiza structurii relatiilor dintre sectoarele pietei financiare prin combinarea a doua componente metodologice complementare: modelarea dependentei temporale printr-un model VAR si estimarea dependentei contemporane conditionale prin metoda graphical lasso. Aceasta separare este importanta deoarece permite distingerea intre efectele dinamice ale valorilor trecute si structura relatiilor directe dintre socurile contemporane.

Din punct de vedere al constructiei statistice, demersul a urmat un lant logic coerent. Mai intai, seriile de preturi au fost transformate in randamente logaritmice, adecvate pentru modelare stationara. Apoi, modelul VAR(1) a fost estimat pentru a extrage reziduurile, interpretate ca inovatii neanticipate. Pe baza matricei de covarianta a acestor reziduuri a fost estimata matricea de precizie penalizata, iar structura ei rara a fost interpretata drept o retea financiara. In etapa finala, aceasta retea a fost analizata prin masuri de centralitate si prin extensia dinamica pe ferestre temporale.

Un avantaj important al acestei abordari este faptul ca fiecare etapa are o justificare matematica si statistica precisa. Transformarea preturilor in randamente raspunde cerintelor de stationaritate si comparabilitate. Modelul VAR permite filtrarea dependentei temporale liniare, astfel incat etapa urmatoare sa nu amestece efectele pe lag-uri cu relatiile contemporane. Graphical lasso introduce un mecanism de regularizare care produce o structura rara si interpretabila, evitand dificultatile asociate unei matrici de precizie dense. In acest fel, reteaua rezultata nu este doar o reprezentare grafica atractiva, ci expresia unei structuri de dependenta conditionala estimate in mod riguros.

Din perspectiva implementarii, lucrarea a urmarit si criteriul reproductibilitatii. Pipeline-ul a fost organizat in scripturi separate pentru descarcarea datelor, preprocesare, estimarea modelului VAR, diagnostice, selectia parametrului de regularizare, constructia retelei si analiza pe ferestre temporale. Aceasta organizare nu are doar un rol tehnic, ci si unul metodologic: ea face posibila verificarea independenta a fiecarui pas si permite extinderea ulterioara a analizei fara a modifica logica de baza a proiectului.

10.2 Contributii principale

Principala contributie a lucrarii consta in formularea si implementarea unei proceduri reproductibile de trecere de la date financiare brute la o reprezentare grafica interpretabila a dependentei conditionale dintre sectoare. In mod concret, contributiile pot fi sintetizate astfel.

In primul rand, lucrarea construieste un cadru unitar care leaga teoria seriilor temporale multivariate de teoria grafurilor gaussiene. Astfel, analiza retelei nu este folosita doar ca instrument descriptiv, ci are o baza matematica precisa: absenta unei muchii corespunde anularii unui element extra-diagonal din matricea de precizie si, implicit, absentei dependentei conditionale directe.

In al doilea rand, lucrarea propune o implementare empirica clara, structurata in scripturi separate pentru descarcarea datelor, estimarea modelului VAR, diagnostice, selectia parametrului de regularizare, constructia retelei si analiza dinamica. Aceasta organizare creste reproductibilitatea si face posibila verificarea fiecarui pas in mod independent.

In al treilea rand, rezultatele sunt interpretate atat statistic, cat si economic. Accentul nu cade doar pe reprezentarea vizuala a grafului, ci pe semnificatia structurala a centralitatii, a raritatii retelei si a persistentei anumitor legaturi directe intre sectoare.

O alta contributie importanta este introducerea unei perspective dinamice prin analiza pe ferestre temporale. Aceasta extensie permite depasirea unei imagini strict statice asupra retelei financiare si sugereaza faptul ca structura dependentei conditionale se poate modifica in timp. Chiar daca analiza dinamica ramane, in aceasta lucrare, una exploratorie, ea arata ca metodologia propusa poate fi folosita nu doar pentru descrierea unei structuri medii pe intregul esantion, ci si pentru urmarirea evolutiei acesteia in contexte economice diferite.

Tot in planul contributiilor trebuie mentionat faptul ca lucrarea pune accentul pe interpretabilitate. Intr-un context in care modelele statistice pot deveni rapid foarte complexe, alegerea unei metode care produce o retea rara si care permite discutarea explicita a nodurilor centrale, a muchiilor dominante si a gradului de conectare dintre sectoare reprezinta un avantaj important. Din acest motiv, rezultatul final nu este doar o estimare numerica, ci o structura care poate fi discutata si inteleasa atat din punct de vedere statistic, cat si din punct de vedere economic.

10.3 Concluzii statistice si matematice

Rezultatele obtinute sustin ideea ca piata financiara sectoriala nu are o structura uniforma. Dupa filtrarea dependentei temporale, reteaua rezultata nu este completa, ceea ce arata ca o parte importanta a corelatiilor brute observate in date este mediata de alti factori sau de alte sectoare si nu corespunde unor relatii directe. Din acest punct de vedere, metodologia utilizata

este superioara unei simple analize de corelatie, deoarece ofera acces la structura dependentei conditionale si nu doar la intensitatea unor co-miscari perechi.

Masurile de centralitate evidentiaza faptul ca anumite sectoare ocupa pozitii mai importante in structura dependentei conditionale. Aceasta neuniformitate este relevanta pentru analiza riscului sistemic, deoarece socurile nu se propaga intr-un sistem omogen, ci printr-o arhitectura in care unele noduri pot avea rol de hub sau de intermediar. In consecinta, importanta unui sector nu depinde doar de marimea sa economica sau de vizibilitatea sa pe piata, ci si de pozitia sa in reteaua relatiilor conditionale estimate.

Analiza pe ferestre temporale sugereaza, de asemenea, ca structura retelei nu este complet stabila in timp. Chiar daca anumite trasaturi par persistente, importanta relativa a sectoarelor si gradul de interconectare pot varia in functie de contextul macroeconomic si financiar. Aceasta observatie sustine ideea ca retelele financiare trebuie tratate nu doar ca obiecte statice, ci si ca structuri evolutive. In acelasi timp, ea arata ca metodologia propusa poate surprinde nu doar configuratia medie a sistemului, ci si modificarile care apar in perioade caracterizate prin stres, ajustari monetare sau schimbari de regim in piata.

Din punct de vedere matematic, lucrarea confirma utilitatea interpretarii zerourilor din matricea de precizie ca absente ale dependentei conditionale directe. Aceasta legatura este esentiala, deoarece transforma o problema de estimare matriciala intr-una de analiza structurala. Reteaua financiara obtinuta nu este un obiect adaugat artificial peste rezultate, ci chiar forma naturala de interpretare a estimatorului rar al matricei de precizie. In acest sens, grafurile gaussiene ofera cadrul conceptual care face legatura dintre teoria probabilitatii, statistica multivariata si analiza de retea.

Din punct de vedere statistic, rezultatele obtinute arata si importanta regularizarii. Fara penalizarea de tip ℓ_1, matricea de precizie estimata ar fi mult mai densa si mult mai dificil de interpretat. Prin graphical lasso, structura este simplificata fara a pierde complet informatia relevanta, ceea ce face posibila identificarea unui numar restrans de relatii directe dominante. Aceasta combinatie dintre parsimonie si interpretabilitate este unul dintre cele mai importante avantaje ale metodologiei folosite.

In ansamblu, lucrarea arata ca metodele matematice si statistice moderne pot oferi o imagine mai riguroasa asupra organizarii interne a pietei financiare decat indicatorii descriptivi traditionali. Combinatia dintre modele VAR, estimarea rara a matricei de precizie si analiza de retea constituie un cadru solid, interpretabil si extensibil pentru studierea interdependentelor dintre sectoare.

10.4 Concluzie finala

Concluzia generala a lucrarii este ca dependenta dintre sectoarele pietei financiare nu poate fi redusa la o simpla colectie de corelatii perechi. Structura relatiilor dintre sectoare este mai subtila: o parte dintre legaturi sunt directe, altele sunt indirecte, iar importanta fiecarui sector depinde de pozitia sa in ansamblul sistemului. Din acest motiv, o abordare bazata pe dependenta conditionala si pe analiza de retea ofera o perspectiva mai bogata si mai riguroasa decat metodele descriptive clasice.

Rezultatele obtinute nu trebuie interpretate in sens cauzal si nici ca o descriere definitiva a pietei, ci ca o estimare structurata a modului in care dependentele dintre sectoare se organizeaza pe esantionul analizat. Cu toate acestea, ele sustin ideea ca reteaua financiara este un obiect util atat pentru intelegerea statistica a pietei, cat si pentru formularea unor intrebari mai fine despre stabilitate, propagarea socurilor si rolul sectoarelor centrale.

Prin urmare, lucrarea isi atinge obiectivul principal: arata ca un cadru bazat pe modele VAR, graphical lasso si analiza de retea poate transforma datele financiare brute intr-o reprezentare coerenta, interpretabila si relevanta matematic a structurii pietei sectoriale.

Bibliografie

Andrew Ang and Joseph Chen. Asymmetric correlations of equity portfolios. *Journal of Financial Economics*, 63(3):443–494, 2002. doi: 10.1016/S0304-405X(02)00068-5.

Phillip Bonacich. Power and centrality: A family of measures. *American Journal of Sociology*, 92(5):1170–1182, 1987. doi: 10.1086/228631.

Rama Cont. Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2):223–236, 2001. doi: 10.1080/713665670.

Gabor Csardi and Tamas Nepusz. The igraph software package for complex network research. *InterJournal, Complex Systems*, 1695, 2006.

Francis X. Diebold and Kamil Yilmaz. On the network topology of variance decompositions: Measuring the connectedness of financial firms. *Journal of Econometrics*, 182(1):119–134, 2014. doi: 10.1016/j.jeconom.2014.04.012.

Eugene F. Fama. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2):383–417, 1970. doi: 10.2307/2325486.

Linton C. Freeman. A set of measures of centrality based on betweenness. *Sociometry*, 40(1): 35–41, 1977. doi: 10.2307/3033543.

Jerome Friedman, Trevor Hastie, and Robert Tibshirani. Sparse inverse covariance estimation with the graphical lasso. *Biostatistics*, 9(3):432–441, 2008. doi: 10.1093/biostatistics/kxm045.

Jerome Friedman, Trevor Hastie, and Robert Tibshirani. *glasso: Graphical Lasso: Estimation of Gaussian Graphical Models*, 2019. URL `https://CRAN.R-project.org/package=glasso`. R package version 1.11.

Steffen L. Lauritzen. *Graphical Models*. Oxford University Press, 1996.

François Longin and Bruno Solnik. Extreme correlation of international equity markets. *Journal of Finance*, 56(2):649–676, 2001. doi: 10.1111/0022-1082.00340.

Helmut Lütkepohl. *New Introduction to Multiple Time Series Analysis*. Springer, Berlin, 2005.

MSCI and S&P Dow Jones Indices. *Global Industry Classification Standard (GICS) Methodology*, 2024. URL `https://www.msci.com/our-solutions/indexes/gics`.

Mark Newman. *Networks: An Introduction*. Oxford University Press, 2010.

Bernhard Pfaff. *Analysis of Integrated and Cointegrated Time Series with R*. Springer, 2nd edition, 2008.

Pradeep Ravikumar, Martin J. Wainwright, Garvesh Raskutti, and Bin Yu. High-dimensional

covariance estimation by minimizing ℓ_1-penalized log-determinant divergence. *Electronic Journal of Statistics*, 5:935–980, 2011. doi: 10.1214/11-EJS631.

Jeffrey A. Ryan and Joshua M. Ulrich. *quantmod: Quantitative Financial Modelling Framework*, 2024. URL `https://CRAN.R-project.org/package=quantmod`. R package version 0.4.26.

Ruey S. Tsay. *Analysis of Financial Time Series*. John Wiley & Sons, 3rd edition, 2010.

Ming Yuan and Yi Lin. Model selection and estimation in the Gaussian graphical model. *Biometrika*, 94(1):19–35, 2007. doi: 10.1093/biomet/asm018.

Anexe

10.5 Bibliografia figurilor si tabelelor

Figuri

Figura 7.1 a fost generata prin scriptul `R/02_var_diagnostics.R` si exportata ca `outputs/var_stability_c`

Figura 7.2 a fost generata prin scriptul `R/03_glasso_selection.R` si exportata ca `outputs/glasso_density`

Figura 7.3 a fost generata prin scriptul `R/01_var_glasso_network.R` si exportata ca `outputs/network.png`.

Figura 9.1 a fost generata prin scriptul `R/04_granger_network.R` si exportata ca `outputs/granger_network`

Tabele

Tabelul 3.1 a fost realizat pe baza selectiei ETF-urilor sectoriale utilizate in analiza, definite in scripturile `R/00_download_data.R` si `R/99_etf_labels.R`.

10.6 Fragmente relevante de cod

10.6.1 Descarcarea datelor si calculul randamentelor logaritmice

```
tickers <- c("XLB","XLE","XLF","XLI","XLK","XLP","XLU","XLV","XLY","XLRE","XLC")

start_date <- as.Date("2016-01-01")
end_date   <- Sys.Date()

get_one <- function(sym) {
  x <- suppressWarnings(getSymbols(sym, src = "yahoo",
                                   from = start_date, to = end_date,
                                   auto.assign = FALSE))
  Ad(x)
}

prices_list <- lapply(tickers, get_one)
names(prices_list) <- tickers

prices <- do.call(merge, c(prices_list, all = FALSE))
```

```
colnames(prices) <- tickers

returns <- 100 * diff(log(prices))
returns <- na.omit(returns)

dir.create("data", showWarnings = FALSE)
saveRDS(prices,  "data/prices_sectors.rds")
saveRDS(returns, "data/returns_sectors.rds")
```

10.6.2 Estimarea modelului VAR si extragerea reziduurilor

```
x
returns <- readRDS("data/returns_sectors.rds")
Y <- as.matrix(returns)

maxlags <- 10
sel <- VARselect(Y, lag.max = maxlags, type = "const")
p <- sel$selection[["SC(n)"]]

var_fit <- VAR(Y, p = p, type = "const")

saveRDS(returns, "outputs/returns.rds")
saveRDS(var_fit, "outputs/var_fit.rds")

resid_mat <- residuals(var_fit)
S <- cov(resid_mat)

saveRDS(resid_mat, "outputs/var_residuals.rds")
```

10.6.3 Estimarea matricei de precizie prin graphical lasso

```
rho <- 1.00
gl <- glasso(S, rho = rho)
Theta <- gl$wi

pcor <- -Theta / sqrt(outer(diag(Theta), diag(Theta)))
diag(pcor) <- 0
```

10.6.4 Constructia retelei financiare bazate pe corelatii partiale

```
adj <- (abs(Theta) > 1e-8) * 1
diag(adj) <- 0

W <- pcor
W[adj == 0] <- 0

g <- graph_from_adjacency_matrix(W, mode = "max",
                                 weighted = TRUE, diag = FALSE)

edges_df <- as_data_frame(g, what = "edges")
write.csv(edges_df, "outputs/edges.csv", row.names = FALSE)

png("outputs/network.png", width = 2600, height = 1600, res = 220)
plot(g)
dev.off()
```

10.6.5 Calculul masurilor de centralitate

```
edges_pc <- read.csv("outputs/edges.csv", stringsAsFactors = FALSE)

g_pc <- graph_from_data_frame(edges_pc, directed = FALSE)
E(g_pc)$weight <- edges_pc$weight

deg_pc <- degree(g_pc)
str_pc <- strength(g_pc, weights = abs(E(g_pc)$weight))

w_pc <- abs(E(g_pc)$weight)
dist_pc <- 1 / (w_pc + 1e-8)

bet_pc <- betweenness(g_pc, directed = FALSE, weights = dist_pc)
clo_pc <- closeness(g_pc, normalized = TRUE, weights = dist_pc)

eig_pc <- eigen_centrality(g_pc, directed = FALSE,
                           weights = abs(E(g_pc)$weight))$vector
```

10.6.6 Analiza pe ferestre temporale

```
window_size <- 252
step_size   <- 21

returns <- readRDS("outputs/returns.rds")

for (start_idx in seq(1, nrow(returns) - window_size, by = step_size)) {

  end_idx <- start_idx + window_size - 1
  Y <- coredata(returns[start_idx:end_idx, ])

  var_fit <- VAR(Y, p = 1, type = "const")
  resid_mat <- residuals(var_fit)
  S <- cov(resid_mat)

  rho <- 1.00
  gl <- glasso(S, rho = rho)
  Theta <- gl$wi

  pcor <- -Theta / sqrt(outer(diag(Theta), diag(Theta)))
  diag(pcor) <- 0
}
```